

latência do LLM (ms)

10^4

10^3

Qwen 3 4B

Gemma 4 E2B

