

latência do LLM (ms)

10^4

6×10^3

4×10^3

3×10^3

2×10^3

Qwen 3 4B

