

**MINISTÉRIO DA DEFESA
EXÉRCITO BRASILEIRO
DEPARTAMENTO DE CIÊNCIA E TECNOLOGIA
INSTITUTO MILITAR DE ENGENHARIA
CURSO DE GRADUAÇÃO EM ENGENHARIA CARTOGRÁFICA**

**VINICIUS HENEQUIM CORRÊA
DANIEL SANTANA**

**BUSCA DE GEOINFORMAÇÃO EM CATÁLOGO DE DADOS ESPACIAIS
UTILIZANDO MODELOS DE LINGUAGEM DE GRANDE PORTE COM
TOOL CALLING**

**RIO DE JANEIRO
2026**

©2026

INSTITUTO MILITAR DE ENGENHARIA

Praça General Tibúrcio, 80 – Praia Vermelha

Rio de Janeiro – RJ CEP: 22290-270

Este exemplar é de propriedade do Instituto Militar de Engenharia, que poderá incluí-lo em base de dados, armazenar em computador, microfilmar ou adotar qualquer forma de arquivamento.

É permitida a menção, reprodução parcial ou integral e a transmissão entre bibliotecas deste trabalho, sem modificação de seu texto, em qualquer meio que esteja ou venha a ser fixado, para pesquisa acadêmica, comentários e citações, desde que sem finalidade comercial e que seja feita a referência bibliográfica completa.

Os conceitos expressos neste trabalho são de responsabilidade do(s) autor(es) e do(s) orientador(es).

Corrêa, Vinicius Henequim; Santana, Daniel.

Busca de Geoinformação em Catálogo de Dados Espaciais Utilizando Modelos de Linguagem de Grande Porte com Tool Calling / Vinicius Henequim Corrêa e Daniel Santana. – Rio de Janeiro, 2026.

150 f.

Orientador(es): Ivanildo Barbosa.

Projeto Final de Curso (graduação) – Instituto Militar de Engenharia, Engenharia Cartográfica, 2026.

1. Modelos de Linguagem de Grande Porte. 2. Tool Calling. 3. Catálogo de Dados Espaciais. 4. Geoinformação. 5. Ollama. 6. LangChain. 7. Avaliação de Modelos. i. Barbosa, Ivanildo (orient.) ii. Título

VINICIUS HENEQUIM CORRÊA
DANIEL SANTANA

BUSCA DE GEOINFORMAÇÃO EM CATÁLOGO DE DADOS ESPACIAIS
UTILIZANDO MODELOS DE LINGUAGEM DE GRANDE PORTE COM
TOOL CALLING

Projeto Final de Curso apresentado ao Curso de Graduação em Engenharia Cartográfica do Instituto Militar de Engenharia, como requisito parcial para a obtenção do título de Bacharel em Engenharia Cartográfica.

Orientador(es): Ivanildo Barbosa, DSc

Rio de Janeiro

2026

A Cristo Rei.

RESUMO

O acervo cartográfico da Diretoria de Serviço Geográfico (DSG) é organizado por nomenclaturas técnicas (Índice de Nomenclatura, Mapa Índice, escalas e tipos de produto do Sistema Cartográfico Nacional), que tendem a restringir o uso por não especialistas. Na Engenharia Cartográfica, o trabalho atende à disseminação da informação geoespacial, a etapa que leva o acervo ao usuário. O protótipo de busca em linguagem natural do 1º Centro de Geoinformação (1º CGEO) usava Saída Estruturada, um só modelo local (Phi-4 14B) e um dicionário de normalização, sem protocolo de avaliação. Este trabalho reescreveu o *backend* em Python e trocou a Saída Estruturada pelo *Tool Calling* nativo na **camada de tradução linguística**, que converte a consulta livre em parâmetros de busca. Um *pipeline* reproduzível avaliou quatro modelos abertos, executados localmente pelo Ollama, num *dataset* de 310 consultas com gabarito definido por manual e auditado. Numa só chamada, a Saída Estruturada acertou mais em três dos quatro modelos, e só o *Tool Calling* recusou consultas fora do domínio. O método do protótipo acertou 58,8%, sem diferença significativa em relação aos três melhores modelos com *Tool Calling*, menores e mais de quinze vezes mais rápidos. A especificação v3, desenvolvida nas 310 consultas e num lote de validação de 1.929, corrigiu as descrições, acrescentou um validador que devolve ao modelo os erros dos parâmetros e deu só ao *Tool Calling* ferramentas auxiliares determinísticas. Num lote de teste de 945 consultas novas, com a configuração e a comparação principal fixadas antes da rodada, o *Tool Calling* v3 com o Gemma 4 E4B acertou 94,4%, contra 87,8% da Saída Estruturada com as mesmas descrições e o mesmo validador. Com o Gemma 4 E2B e o Qwen 3 4B, a v3 também melhorou as duas abordagens (a Saída Estruturada numa comparação exploratória), mas a abordagem que acertou mais dependeu do modelo. No teste A/B, o *Tool Calling* (Modo A) acertou mais que a Saída Estruturada (Modo B) em 8 dos 24 pares e menos em 8, com 8 empates, recusou melhor e não ganhou em tempo de processamento. Recomenda-se o *Tool Calling* v3 com o Gemma 4 E4B; em GPU modesta, o Qwen 3 4B com a Saída Estruturada v3 ou o Gemma 4 E2B com o *Tool Calling* v3. O trabalho entregou o *backend* em Python com *Tool Calling* nativo, o *dataset* auditado, os lotes de validação e de teste, o *pipeline* reproduzível com o teste A/B e a recomendação operacional. As consultas são sintéticas, e as ferramentas e o validador seguem o manual que define o gabarito. O diferencial estruturante da solução é o conhecimento especializado do engenheiro cartógrafo, codificado no manual, nas descrições, nas ferramentas e no validador.

Palavras-chave: Modelos de Linguagem de Grande Porte. *Tool Calling*. Catálogo de Dados Espaciais. Disseminação da Informação Geoespacial. Geoinformação. Ollama. LangChain. Avaliação de Modelos.

ABSTRACT

The cartographic collection of the Brazilian Army Geographic Service Directorate (DSG) is organized by technical nomenclatures (the Nomenclature Index, the Index Map, and the scales and product types of the National Cartographic System) that tend to restrict use by non-specialists. Within Cartographic Engineering, the work addresses the dissemination of geospatial information, the stage that brings the collection to its users. The natural-language search prototype of the 1st Geoinformation Center (1º CGEO) used Structured Output, a single local model (Phi-4 14B), and a normalization dictionary, without an evaluation protocol. This work rewrote the backend in Python and replaced Structured Output with native Tool Calling in the **natural-language translation layer**, which converts the free-form query into search parameters. A reproducible pipeline evaluated four open models run locally through Ollama on a 310-query dataset whose ground truth follows an annotation manual and was audited. In a single call, Structured Output was more accurate for three of the four models, and only Tool Calling declined out-of-domain queries. The prototype's method reached 58.8%, with no significant difference from the three best models with Tool Calling, which are smaller and more than fifteen times faster. Specification v3, developed on the 310 queries and on a validation batch of 1,929, corrected the descriptions, added a validator that returns parameter errors to the model, and gave deterministic auxiliary tools to Tool Calling only. On a test batch of 945 new queries, with the configuration and the main comparison fixed before the run, Tool Calling v3 with Gemma 4 E4B reached 94.4%, against 87.8% for Structured Output with the same descriptions and the same validator. With Gemma 4 E2B and Qwen 3 4B, v3 also improved both approaches (Structured Output in an exploratory comparison), but which approach was more accurate depended on the model. In the A/B test, Tool Calling (Mode A) was more accurate than Structured Output (Mode B) in 8 of the 24 pairs and less accurate in 8, with 8 ties, declined better, and gained nothing in processing time. Tool Calling v3 with Gemma 4 E4B is recommended; on modest GPUs, Qwen 3 4B with Structured Output v3 or Gemma 4 E2B with Tool Calling v3. The work delivered the Python backend with native Tool Calling, the audited dataset, the validation and test batches, the reproducible pipeline with the A/B test, and the operational recommendation. The queries are synthetic, and the tools and the validator follow the manual that defines the ground truth. The key differentiator of the solution is the cartographic engineer's specialized knowledge, encoded in the manual, the descriptions, the tools, and the validator.

Keywords: Large Language Models. Tool Calling. Spatial Data Catalog. Geospatial Information Dissemination. Geoinformation. Ollama. LangChain. Model Evaluation.

LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo do mecanismo de <i>Tool Calling</i>	23
Figura 2 – Exemplo simplificado de definição de ferramenta para busca em catálogo de produtos cartográficos	24
Figura 3 – Estrutura Analítica do Projeto (EAP)	30
Figura 4 – Arquitetura do protótipo de busca do 1º CGEO	31
Figura 5 – Arquitetura da solução aprimorada de busca	36
Figura 6 – Distribuição da latência da tradução nas rodadas completas, em escala logarítmica, por modelo	142
Figura 7 – Acurácia por consulta, por categoria e por modelo, nas rodadas completas dos modelos locais	143

LISTA DE QUADROS

Quadro 1 – Requisitos da solução, onde são atendidos e como foram verificados . .	33
Quadro 2 – Mapeamento entre limitações do protótipo e soluções adotadas	34
Quadro 3 – Classificação dos componentes do sistema final em relação ao protótipo	35
Quadro 4 – Cronograma de execução do projeto	39
Quadro 5 – Etapas do estudo, configurações avaliadas e conjunto de cada medida .	41
Quadro 6 – Configurações recomendadas por cenário de implantação	84
Quadro 7 – Leituras aceitas para as expressões de tempo relativo (D = data de referência da execução)	101
Quadro 8 – Grupos de consultas do <i>dataset</i> e aspectos da tradução que exercitam	128
Quadro 9 – Decisões de adjudicação da auditoria do <i>dataset</i>	130

LISTA DE TABELAS

Tabela 1 – Comparativo entre consulta técnica e consulta em linguagem natural . . .	17
Tabela 2 – Modelos avaliados, com suporte a <i>Tool Calling</i> no Ollama	26
Tabela 3 – Composição do <i>dataset</i> de avaliação por origem e família	44
Tabela 4 – Resultados da auditoria do <i>dataset</i>	45
Tabela 5 – Métricas e critérios usados para escolher o modelo e a abordagem . . .	51
Tabela 6 – Ameaças à validade do gabarito e das consultas	60
Tabela 7 – Ameaças à validade das comparações e das medidas	61
Tabela 8 – Ferramentas de inteligência artificial empregadas como apoio nos processos metodológicos	63
Tabela 9 – Comparativo de desempenho entre os modelos avaliados	64
Tabela 10 – Tool Calling e Saída Estruturada sobre as mesmas consultas	68
Tabela 11 – Especificações v1 e v2 com o Gemma 4 E4B no lote de validação e nas 310 consultas	71
Tabela 12 – Degraus da v3, controle e referências v1/v2 com o Gemma 4 E4B no lote 2 (teste)	75
Tabela 13 – Comparações pareadas no lote 2 (Gemma 4 E4B)	76
Tabela 14 – Decomposição do acerto no lote 2 entre a primeira decisão do modelo e a correção pelo retorno do código	78
Tabela 15 – Teste A/B entre o <i>Tool Calling</i> (A) e a Saída Estruturada (B), com o mesmo modelo, as mesmas consultas, a mesma especificação e o mesmo ambiente	81
Tabela 16 – Concordância por campo entre o gabarito e a anotação independente (leitura preferencial, após a adjudicação)	129
Tabela 17 – Estrutura de cada entrada do <i>dataset</i> de avaliação	131
Tabela 18 – Consultas por categoria e por camada (métricas principais; uma consulta pode ter mais de uma categoria)	131
Tabela 19 – Frequência de cada campo na leitura preferencial do gabarito (métricas principais)	132
Tabela 20 – Do alvo ao lote final, por família, no lote de validação	132
Tabela 21 – Concordância na anotação às cegas do lote de validação	132
Tabela 22 – Do alvo ao lote final, por família, no lote 2 (teste)	133
Tabela 23 – Concordância na anotação às cegas do lote 2 (teste)	133
Tabela 24 – Ambiente de execução de cada rodada, na estação de referência (camadas P e N)	136
Tabela 25 – Ambiente de execução de cada rodada	137
Tabela 26 – Latência da tradução, em milissegundos, por modelo	142

Tabela 27 – Teste de McNemar exato entre pares de modelos	143
Tabela 28 – F1- <i>score</i> por categoria de consulta e por modelo	143
Tabela 29 – Acurácia por camada de origem das consultas	144
Tabela 30 – F1- <i>score</i> por campo do <i>schema</i> de busca, por modelo	144
Tabela 31 – Comparativo de desempenho entre os modelos avaliados, na estação de referência (camadas P e N)	144
Tabela 32 – Latência da tradução, em milissegundos, por modelo, na estação de referência (camadas P e N)	145
Tabela 33 – Teste de McNemar exato entre pares de modelos, na estação de refe- rência (camadas P e N)	145
Tabela 34 – Tool Calling e Saída Estruturada sobre as mesmas consultas, na estação de referência (camadas P e N)	146
Tabela 35 – Mesmo modelo nas rodadas completas e na estação de referência (ca- madas P e N, primeira repetição)	147
Tabela 36 – Qwen 3 4B executado duas vezes na estação de referência, com os mesmos pesos, prompt, ferramenta e data de referência (camadas P e N)147	147
Tabela 37 – Comparativo de desempenho entre os modelos avaliados, na referência em nuvem (Groq)	147
Tabela 38 – F1- <i>score</i> por categoria de consulta e por modelo, na referência em nu- vem (Groq)	148
Tabela 39 – Comparações pareadas no lote 1 e nas 310 consultas (Gemma 4 E4B) .	148
Tabela 40 – Arquitetura em duas etapas e regra do objeto vazio, simuladas com as rodadas do Gemma 4 E4B, ao lado das quatro configurações executadas149	149
Tabela 41 – Acurácia por categoria no lote de validação (Gemma 4 E4B)	150
Tabela 42 – F1 por campo no lote de validação (Gemma 4 E4B)	150

LISTA DE ABREVIATURAS E SIGLAS

1º CGEO	1º Centro de Geoinformação
API	<i>Application Programming Interface</i> (Interface de Programação de Aplicações)
BDGEx	Banco de Dados Geográficos do Exército
CGEO	Centro de Geoinformação
CPU	<i>Central Processing Unit</i> (Unidade Central de Processamento)
CSW	<i>Catalogue Service for the Web</i>
DSG	Diretoria de Serviço Geográfico
EAP	Estrutura Analítica do Projeto
ET-PCDG	Especificação Técnica para Produtos de Conjuntos de Dados Geoespaciais
GPU	<i>Graphics Processing Unit</i> (Unidade de Processamento Gráfico)
IA	Inteligência Artificial
IBGE	Instituto Brasileiro de Geografia e Estatística
IC	Intervalo de confiança
INDE	Infraestrutura Nacional de Dados Espaciais
INOM	Índice de Nomenclatura
JSON	<i>JavaScript Object Notation</i>
LLM	<i>Large Language Model</i> (Modelo de Linguagem de Grande Porte)
MGB	Perfil de Metadados Geoespaciais do Brasil
MI	Mapa Índice
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
OGC	<i>Open Geospatial Consortium</i>
OM	Organização Militar

PFC	Projeto Final de Curso
p.p.	Pontos percentuais
REST	<i>Representational State Transfer</i>
RF	Requisito funcional
RNF	Requisito não funcional
SCN	Sistema Cartográfico Nacional
SE	Saída Estruturada (<i>Structured Output</i>)
SIG	Sistema de Informação Geográfica
SQL	<i>Structured Query Language</i>
TC	<i>Tool Calling</i> (Chamada de Ferramentas)
UF	Unidade da Federação
VRAM	<i>Video Random Access Memory</i> (memória da GPU)
WCS	<i>Web Coverage Service</i>
WFS	<i>Web Feature Service</i>
WMS	<i>Web Map Service</i>

SUMÁRIO

1	INTRODUÇÃO	16
1.1	Contextualização	16
1.2	Problema	16
1.3	Motivação	17
1.4	O Protótipo do 1º CGEO	18
1.5	Objetivos	18
1.5.1	Objetivo Geral	18
1.5.2	Questões do Trabalho	19
1.5.3	Entregáveis	19
1.6	Delimitação do Trabalho	19
1.7	Percurso e Estrutura do Trabalho	20
2	REFERENCIAL TEÓRICO	22
2.1	Catálogos de Dados Espaciais	22
2.2	<i>Tool Calling</i>	22
2.2.1	<i>Tool Calling</i> versus Saída Estruturada	23
2.3	Modelos de Linguagem de Grande Porte e Execução Local	24
2.3.1	Vantagens e Desvantagens da Execução Local	25
2.3.2	Ollama e Modelos com Suporte a <i>Tool Calling</i>	25
2.4	Orquestração com LangChain	26
2.5	Métricas de Avaliação	26
2.6	Trabalhos Relacionados	27
3	DESENVOLVIMENTO DA SOLUÇÃO	30
3.1	Análise do Protótipo do 1º CGEO	30
3.1.1	Arquitetura e Contribuições	30
3.1.2	Limitações	31
3.2	Requisitos	32
3.3	Planejamento da Migração	32
3.4	Arquitetura da Solução v1	32
3.4.1	API	32
3.4.2	Orquestração e Ferramenta de Busca	34
3.4.3	Persistência	35
3.4.4	Consultas sem Resposta no Acervo	36
3.5	<i>Pipeline</i> de Avaliação	37
3.5.1	Registro de Abordagens e Implantação	37

3.6	Cronograma	38
4	METODOLOGIA	40
4.1	Desenho do Estudo	40
4.2	Modelos Avaliados	42
4.3	Conjuntos de Avaliação	42
4.3.1	As 310 Consultas	42
4.3.2	Manual de Anotação e Leituras Múltiplas	43
4.3.3	Auditoria das 310 Consultas	44
4.3.4	Lotes de Validação e de Teste	46
4.4	Protocolo de Avaliação	48
4.4.1	Ambientes de Execução	48
4.4.2	Configuração dos Modelos	48
4.4.3	Métricas e Testes Estatísticos	49
4.4.4	Reprodutibilidade	50
4.5	CrITÉRIOS de Decisão sobre o Modelo e a Abordagem	50
4.6	Etapas do Estudo	53
4.6.1	Escolha do Modelo com a Solução v1	53
4.6.2	<i>Tool Calling</i> v1, Saída Estruturada e Método do Protótipo	53
4.6.3	Especificação v2 no Lote 1	54
4.6.4	Especificação v3 e Teste no Lote 2	55
4.6.5	Extensão da v3 a Outros Modelos	57
4.6.6	Teste A/B entre o Modo A e o Modo B	57
4.7	Confiabilidade da Avaliação	58
4.8	Uso de Ferramentas de Inteligência Artificial	62
5	RESULTADOS	64
5.1	Escolha do Modelo com a Solução v1	64
5.1.1	Categorias, Camadas e Campos	65
5.1.2	Modos de Falha	65
5.1.3	Estação de Referência	66
5.1.4	Referência em Nuvem	67
5.2	<i>Tool Calling</i> v1, Saída Estruturada e Método do Protótipo	67
5.3	Especificação v2 no Lote 1	70
5.4	Teste da v3 no Lote 2	74
5.5	Extensão da v3 a Outros Modelos	79
5.6	Evidências sobre os Ganhos do <i>Tool Calling</i> no Teste A/B (Modo A × Modo B)	80
5.7	Discussão e Recomendação	83
5.7.1	Recomendação e Implantação	83

5.7.2	Quando o Acervo Não Tem a Resposta	85
5.7.3	O Que Continua Difícil	85
6	CONCLUSÃO	86
6.1	Síntese e Objetivos Atendidos	86
6.2	Respostas às Questões do Trabalho	87
6.3	Limitações e Lacunas do Trabalho	89
6.4	Trabalhos Futuros e Pontos de Melhoria	90
6.5	O Conhecimento do Engenheiro Cartógrafo como Diferencial Estruturante .	91
	REFERÊNCIAS	92
	APÊNDICE A – DATASET DE AVALIAÇÃO	98
A.1	Manual de anotação	98
A.2	Consultas do protótipo (P01–P22)	103
A.3	Consultas redigidas pelos autores (N01–N40)	109
A.4	Geração programática da camada G	116
A.5	Consultas simples geradas por <i>templates</i> (G-S)	117
A.6	Consultas compostas geradas por <i>templates</i> (G-C)	119
A.7	Consultas com código MI/INOM geradas por <i>templates</i> (G-M)	121
A.8	Consultas com tempo relativo geradas por <i>templates</i> (G-T)	123
A.9	Consultas com ordenação geradas por <i>templates</i> (G-O)	124
A.10	Consultas ambíguas/informais adicionais (G-A)	126
A.11	Consultas amplas, com muitos produtos (G-P)	127
A.12	Consultas de fronteira do domínio (G-F)	127
A.13	Requisitos exercitados pelas consultas	128
A.14	Auditoria do <i>dataset</i>	128
A.15	Estrutura, composição e concordância dos conjuntos	131
	APÊNDICE B – ESPECIFICAÇÃO DOS AMBIENTES DE EXECUÇÃO	134
B.1	Estação de referência	134
B.1.1	Comandos PowerShell de coleta	134
B.1.2	Saída coletada	135
B.2	Rodadas completas em GPU de nuvem	136
B.3	Referência em nuvem (Groq)	137
	APÊNDICE C – REPOSITÓRIO DE CÓDIGO E REPRODUÇÃO DOS EXPERIMENTOS	138
C.1	Comandos do <i>pipeline</i> de avaliação	141

	APÊNDICE D – RESULTADOS COMPLEMENTARES	142
D.1	Rodadas completas das 310 consultas	142
D.2	Estação de referência	144
D.3	Referência em nuvem	147
D.4	Lote 1 (validação)	147

1 INTRODUÇÃO

1.1 Contextualização

A geoinformação tem papel estratégico na defesa, no planejamento territorial, na gestão ambiental e na tomada de decisão do Estado brasileiro. O Decreto n.º 6.666/2008 instituiu a Infraestrutura Nacional de Dados Espaciais (INDE), que organiza, em âmbito federal, o acesso integrado aos dados geoespaciais produzidos e mantidos pelos órgãos governamentais (BRASIL, 2008).

No Exército Brasileiro, a Diretoria de Serviço Geográfico (DSG) tem por missão orientar, no âmbito do Exército, as atividades referentes a imagens e informações geográficas, visando à produção cartográfica nas suas mais diversas formas, ao estabelecimento de normas e instruções, ao suprimento e à manutenção do material a seu cargo e às atividades decorrentes de convênios com órgãos da Administração Pública (DIRETORIA DE SERVIÇO GEOGRÁFICO DO EXÉRCITO BRASILEIRO, 2025b). Para cumprir essa missão, a DSG mantém o Banco de Dados Geográficos do Exército (BDGEx), criado para disponibilizar na Internet os dados geoespaciais da instituição, como determina o decreto da INDE (XAVIER; MEYER; LUNARDI, 2014). Pelo BDGEx, o acervo cartográfico oficial fica disponível ao público militar e à sociedade civil (DIRETORIA DE SERVIÇO GEOGRÁFICO DO EXÉRCITO BRASILEIRO, 2025a). Cinco Centros de Geoinformação (CGEO) subordinados (em Porto Alegre, Brasília, Olinda, Manaus e Rio de Janeiro) produzem esse acervo segundo a Especificação Técnica para Produtos de Conjuntos de Dados Geoespaciais (ET-PCDG) (BRASIL. Ministério da Defesa. Exército Brasileiro. Diretoria de Serviço Geográfico, 2016) e o Perfil de Metadados Geoespaciais do Brasil (Perfil MGB) (BRASIL. Comissão Nacional de Cartografia (CONCAR), 2009), de adesão obrigatória para as Organizações Militares produtoras de dados geoespaciais.

Os produtos são indexados em catálogos compatíveis com os padrões do *Open Geospatial Consortium* (OGC), em particular o *Catalogue Service for the Web* (CSW) (OPEN GEOSPATIAL CONSORTIUM, 2007). O catálogo armazena os metadados num modelo de dados rígido, e uma consulta em texto livre, com sinônimos e abreviações, precisa ser traduzida para os seus campos técnicos.

1.2 Problema

A busca em catálogos institucionais de dados espaciais exige que o usuário conheça as convenções técnicas que organizam o acervo. No acervo da DSG, ele precisa saber usar o Índice de Nomenclatura (INOM) e o Mapa Índice (MI), identificar as escalas disponíveis

(1:1.000, 1:2.000, 1:5.000, 1:10.000, 1:25.000, 1:50.000, 1:100.000 e 1:250.000), conhecer os tipos de produto do Sistema Cartográfico Nacional (SCN), como “SCN Carta Topográfica Matricial”, “SCN Carta Topográfica Vetorial” e “SCN Carta Ortoimagem Banda P Pol HH”, e reconhecer o Centro de Geoinformação responsável por cada folha.

A interface atual faz **busca por texto simples** (*full-text search*) nos campos do banco, sem compreensão de linguagem natural, e só encontra o produto quem digita os termos técnicos do acervo. A Tabela 1 compara os dois modos de consulta.

Tabela 1 – Comparativo entre consulta técnica e consulta em linguagem natural

Modo atual (busca por texto simples)	Modo desejado (linguagem natural)
O usuário precisa digitar termos técnicos exatos que combinem com os campos do banco: “SCN Carta Topográfica Matricial 1:25.000 Rio de Janeiro 2023”	“mapas do Rio de Janeiro em 25k publicados em 2023”

Fonte: Adaptado de 1º Centro de Geoinformação (2025).

Essa barreira técnica tende a restringir o uso do acervo por analistas, gestores e tomadores de decisão que precisam de informação geoespacial, mas não têm formação em cartografia. O mesmo problema aparece na descoberta de dados em geoportais e catálogos de dados espaciais em geral (HU et al., 2015; LI et al., 2025).

1.3 Motivação

A produção de geoinformação passa pela aquisição, pelo processamento e pela disseminação dos dados. A parte da Engenharia Cartográfica que este trabalho atende é a **disseminação da informação geoespacial**, a etapa que leva o acervo já produzido a quem precisa dele. A barreira descrita acima está nessa etapa, porque o produto está catalogado, mas só o encontra quem domina as nomenclaturas do acervo. O trabalho busca reduzir essa barreira e tornar o catálogo da DSG utilizável por quem não é especialista. Para isso, converte as convenções do acervo (INOM, MI, escalas do SCN, tipos de produto, CGEOs e regras de tempo) em instruções e verificações do sistema de busca. Esse conhecimento do engenheiro cartógrafo é o diferencial discutido na Seção 6.5.

Os Modelos de Linguagem de Grande Porte (LLMs, do inglês *Large Language Models*) conseguem interpretar intenções implícitas, normalizar variações linguísticas e traduzir descrições informais para estruturas formais (BROWN et al., 2020; WEI et al., 2022). No *Tool Calling* (chamada de ferramentas), o modelo recebe a descrição de funções externas e decide se chama alguma delas e com quais argumentos (SCHICK et al., 2023; QIN et al., 2024). Na Saída Estruturada (*Structured Output*), ele sempre devolve um objeto no formato pedido. A Seção 2.2.1 detalha a diferença.

O Ollama (OLLAMA, 2023) é uma plataforma que executa modelos de código aberto, como os das famílias Qwen, Llama, Gemma e Mistral, em *hardware* local, sem depender de serviço de nuvem. No Exército, a execução local atende às restrições de privacidade e de segurança da informação e dispensa o custo recorrente dos serviços em nuvem.

1.4 O Protótipo do 1º CGEO

O 1º Centro de Geoinformação (1º CGEO) desenvolveu um protótipo de busca em linguagem natural sobre o acervo (1º CENTRO DE GEOINFORMAÇÃO, 2025). O protótipo, que usa o Phi-4 14B (14 bilhões de parâmetros) via Ollama com Saída Estruturada, confirmou a viabilidade da abordagem para o domínio cartográfico nacional. Ele tem seis limitações, que motivaram este trabalho:

1. *backend* em Node.js;
2. tradução só por Saída Estruturada;
3. um único modelo, escolhido sem comparação com alternativas;
4. dicionário de normalização fixo no código;
5. *fallback* por expressões regulares quando o modelo falha;
6. 22 casos de teste, sem métricas formais de avaliação.

A Seção 3.1.2 detalha cada uma.

1.5 Objetivos

1.5.1 Objetivo Geral

Este trabalho tem por objetivo aprimorar a **camada de tradução linguística** da solução de busca em linguagem natural sobre o acervo cartográfico da DSG, a parte do sistema que converte a consulta livre do usuário em parâmetros estruturados de busca, para facilitar a disseminação do acervo a usuários não especialistas. A partir do protótipo do 1º CGEO, o trabalho reimplementa o *pipeline* com *Tool Calling* nativo, compara-o com a Saída Estruturada nos mesmos modelos e nas mesmas consultas (teste A/B, Seção 5.6), avalia modelos abertos executáveis localmente via Ollama e define métricas que permitem aferir e comparar a tradução.

1.5.2 Questões do Trabalho

O trabalho responde a quatro questões:

- Q1. O *Tool Calling* melhora a tradução em relação à Saída Estruturada e ao método do protótipo, em acurácia e em tempo de processamento?
- Q2. Como saber se o gabarito e as consultas medem a tradução de forma confiável?
- Q3. O que acontece quando não há carta que atenda ao pedido?
- Q4. Que modelo e que abordagem recomendar à DSG, e em que *hardware*?

A Seção 6.2 responde a cada uma, com a Q1 desdobrada em três itens (protótipo, teste A/B e origem do ganho).

1.5.3 Entregáveis

O projeto entregou:

1. *backend* em Python (FastAPI e LangChain) com *Tool Calling* nativo, as três versões da tradução, v1, v2 e v3 (Seções 3.4, 4.6.3 e 4.6.4), e um registro que reúne as configurações avaliadas (Seção 3.5.1);
2. *dataset* de 310 consultas, com manual de anotação e auditoria do gabarito (Seção 4.3 e Apêndice A);
3. dois lotes de consultas novas, um de validação e um de teste, com o gabarito de cada consulta fixado antes de ela ser redigida (Seção 4.3.4);
4. *pipeline* de avaliação reprodutível, com o teste A/B (Seções 3.5 e 4.6.6);
5. relatório comparativo de quatro modelos locais, com três modelos em nuvem só como referência, por não rodarem localmente, e a recomendação de modelo e de abordagem (Capítulo 5 e Seção 5.7.1);
6. repositório público do projeto (Apêndice C).

1.6 Delimitação do Trabalho

O objeto avaliado é a tradução da consulta em parâmetros de busca, comparada com um gabarito de parâmetros, e não a lista de produtos que o banco devolve. A execução da busca no PostgreSQL/PostGIS, a resolução de nomes geográficos e as *bounding boxes* das cartas são herdadas do protótipo e não são medidas. A integração com o banco é

demonstrada sobre dados sintéticos, mas não é avaliada. Os valores citados nas consultas dos lotes vêm dos metadados públicos do BDGEx e da lista de municípios do IBGE (Seção 4.3.4). Ficam fora do escopo:

- a avaliação da recuperação em nível de produto;
- a resolução avançada de nomes geográficos, que depende de recursos externos, como a malha do IBGE e o Nominatim;
- a interface gráfica (*frontend*) para o usuário final;
- a implantação em produção na DSG;
- a pesquisa de opinião ou a avaliação qualitativa com usuários;
- o treinamento ou ajuste fino (*fine-tuning*) de modelos de linguagem;
- a busca por coordenadas sem referência nominal a um lugar;
- idiomas além do português.

Quando a busca é legítima e nenhum produto atende aos filtros, a resposta é uma mensagem fixa com os critérios usados, que não depende do modelo e não é pontuada (Seção 3.4.4). Quando o pedido está fora do domínio do catálogo, o correto é não buscar, e esse caso é pontuado (categoria F do *dataset*, Seção 4.3.1).

1.7 Percurso e Estrutura do Trabalho

O trabalho partiu do protótipo e construiu uma solução de uma chamada ao modelo, a solução v1, que troca a Saída Estruturada pelo *Tool Calling* com uma única ferramenta, `buscar_catálogo`. Para medi-la, construiu-se um *dataset* de 310 consultas com gabarito auditado. A v1 foi avaliada com quatro modelos locais, entre os quais se escolheu o Gemma 4 E4B (etapa 1), e comparada com a Saída Estruturada nos mesmos modelos e com o método do protótipo (etapa 2). Numa só chamada, o *Tool Calling* recusou melhor os pedidos fora do catálogo, mas não extraiu melhor os parâmetros. Para confirmar esse resultado com dados independentes, construiu-se o lote 1 (validação), de 1.929 consultas. A partir dos erros da v1, criou-se a especificação v2, que leva às descrições as convenções do manual de anotação e dá às duas abordagens uma forma de recusar (etapa 3). No lote 1, a Saída Estruturada v2 acertou mais que o *Tool Calling* v2. A análise dos erros levou à v3, que corrige as descrições e acrescenta ferramentas auxiliares, um pedido de esclarecimento respondido por um usuário simulado, a recusa contestada e um validador que devolve ao modelo os erros encontrados. Desenvolvida nas 310 e no lote 1, a v3 foi congelada e testada no lote 2 (teste), de 945 consultas nunca lidas no desenvolvimento.

Nesse lote, o *Tool Calling* v3 com o Gemma 4 E4B superou o controle, a Saída Estruturada v3, que recebe as mesmas descrições e o mesmo validador (etapa 4). A mesma v3 foi executada com o Gemma 4 E2B e o Qwen 3 4B (etapa 5). O teste A/B reúne todas as comparações entre as duas abordagens com o mesmo modelo e as mesmas consultas (etapa 6). A recomendação de modelo e de abordagem e a implantação no *backend* fecham o percurso.

O Capítulo 2 reúne os fundamentos. O Capítulo 3 analisa o protótipo, define os requisitos e descreve a solução v1, o *pipeline* de avaliação e o registro de abordagens. O Capítulo 4 apresenta o desenho do estudo, os conjuntos de avaliação, o protocolo e os critérios que definem o melhor modelo e a melhor abordagem (Seção 4.5). Ele descreve ainda o desenho de cada etapa, a confiabilidade da avaliação (Seção 4.7) e os processos em que foram usadas ferramentas de inteligência artificial, com a ferramenta e a finalidade de cada uso (Seção 4.8). O Capítulo 5 traz os resultados na ordem das etapas, inclusive o teste A/B entre o *Tool Calling* nativo (Modo A) e a Saída Estruturada validada pela biblioteca Pydantic (Modo B), com as evidências sobre os ganhos do *Tool Calling* em acurácia e tempo de processamento (Seção 5.6). O Capítulo 6 responde às questões, confirma o atingimento dos objetivos, aponta as limitações e lacunas e os pontos de melhoria para trabalhos futuros e discute o conhecimento especializado do engenheiro cartógrafo como diferencial estruturante (Seção 6.5).

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os catálogos de dados espaciais, o *Tool Calling* e a Saída Estruturada, a execução local de LLMs e a orquestração com o LangChain, as métricas de avaliação e os trabalhos relacionados.

2.1 Catálogos de Dados Espaciais

A produção cartográfica brasileira é regida pelo Sistema Cartográfico Nacional (SCN), instituído pelo Decreto-Lei n.º 243/1967, que fixa as diretrizes e bases da cartografia brasileira e as escalas-padrão da cartografia sistemática terrestre (BRASIL, 1967). O Decreto n.º 89.817/1984 estabeleceu as normas técnicas da cartografia nacional, inclusive os padrões de exatidão (BRASIL, 1984). As folhas da cartografia sistemática são identificadas pelo Índice de Nomenclatura (INOM), um código alfanumérico como SF-22-Y-D-II-4, e pelo número do Mapa Índice (MI), como 2901 ou 2965-2-NE. A Especificação Técnica para Produtos de Conjuntos de Dados Geoespaciais (ET-PCDG) (BRASIL. Ministério da Defesa. Exército Brasileiro. Diretoria de Serviço Geográfico, 2016), mantida pela DSG, detalha os requisitos técnicos dos produtos, como cartas topográficas, cartas ortoimagem, modelos digitais de elevação e ortoimagens.

O Decreto n.º 6.666/2008 inclui a disseminação e o uso dos dados geoespaciais entre os objetivos da INDE (BRASIL, 2008). A INDE é constituída por *nós* provedores, pontos de acesso institucionais que catalogam e disponibilizam dados conforme o Perfil MGB (BRASIL. Comissão Nacional de Cartografia (CONCAR), 2009). Os *nós* e o BDGEx são os instrumentos dessa disseminação, e o catálogo de metadados é o ponto em que o usuário descobre os produtos disponíveis. A INDE e o BDGEx adotam os padrões do OGC para disponibilizar os dados, entre eles os serviços *Web Map Service* (WMS), *Web Feature Service* (WFS), *Web Coverage Service* (WCS) e *Catalogue Service for the Web* (CSW). O CSW (OPEN GEOSPATIAL CONSORTIUM, 2007) é o padrão internacional para publicar e descobrir metadados de recursos geoespaciais. Suas operações de consulta, como *GetRecords*, buscam por título, data, tipo, área de abrangência geográfica e palavras-chave.

2.2 *Tool Calling*

O *Tool Calling* (também chamado *Function Calling*) é a capacidade de um LLM de reconhecer que a resposta a uma consulta exige uma função externa e de gerar a chamada dessa função, com os argumentos em JSON (SCHICK et al., 2023; QIN et al., 2024).

O modelo passa a ser o componente que decide, num sistema que executa ferramentas determinísticas, como consultas a bancos de dados, chamadas a APIs e execução de código.

A Figura 1 mostra o fluxo. O sistema de orquestração (por exemplo, o LangChain) recebe a chamada gerada pelo modelo, executa a função e devolve o resultado ao modelo, que formula a resposta ao usuário. Este trabalho avalia a tradução, da consulta até a chamada da ferramenta com os seus argumentos.




Figura 1 – Fluxo do mecanismo de *Tool Calling*

Fonte: Elaborado pelos autores.

No protocolo adotado pelo Ollama e pelo LangChain, cada ferramenta é definida por um *schema* JSON com o nome da função, a sua descrição e os parâmetros aceitos, cada um com tipo e descrição. O modelo recebe essas definições junto com o *prompt* de sistema, as instruções fixas que a aplicação lhe envia. A Figura 2 mostra uma definição simplificada da ferramenta de busca, com quatro dos doze parâmetros listados na Seção 3.1.

2.2.1 *Tool Calling* versus Saída Estruturada

Na Saída Estruturada (*Structured Output*), o modelo devolve a resposta num objeto JSON que segue um *schema* predefinido, validado por bibliotecas como o Pydantic, em Python (COLVIN, 2019), ou o Zod, em TypeScript. O modelo só decide quais campos preencher e com que valores. Bibliotecas como o Instructor (LIU, 2023) conferem a saída contra o *schema* e repetem a chamada quando ela é inválida.

A Saída Estruturada tem duas limitações estruturais. A primeira é que ela sempre devolve um objeto no formato do *schema*. Mesmo com campos opcionais, toda consulta vira uma busca, e recusar exige um artifício no próprio *schema*, como um campo de recusa. A segunda é que o modelo não consulta ferramentas durante a resposta. Uma verificação só lhe chega como nova tentativa, depois de emitido o objeto inteiro, como no Instructor. É esse o arranjo do controle da v3 (Seção 4.6.4). Há ainda o risco de alucinações estruturadas, valores plausíveis sem apoio na consulta, inseridos para completar o *schema*, hipótese que a Seção 5.2 testa.


```

{
  "name": "buscar_catalogo",
  "description": "Busca produtos cartograficos no catalogo",
  "parameters": {
    "type": "object",
    "properties": {
      "keyword": {"type": "string",
        "description": "Codigo MI, INOM ou nome da carta"},
      "scale": {"type": "string",
        "enum": ["1:25.000", "1:50.000", "1:100.000", ...],
        "description": "Escala cartografica"},
      "state": {"type": "string",
        "description": "Nome do estado (normalizado)"},
      "productType": {"type": "string",
        "description": "Tipo de produto SCN"}
    }
  }
}

```

Figura 2 – Exemplo simplificado de definição de ferramenta para busca em catálogo de produtos cartográficos

Fonte: Elaborado pelos autores.

No *Tool Calling*, o modelo decide se e quando chama cada uma das ferramentas disponíveis. Ele pode responder sem chamar nenhuma ou encadear várias chamadas. Para este trabalho, o *Tool Calling* pode ser mais adequado, porque deixa o modelo tratar consultas ambíguas, escolher os parâmetros relevantes e encadear validações antes da busca. Essa vantagem só se estabelece empiricamente. O Capítulo 5 compara as duas abordagens numa só chamada (Seção 5.2), na v3, em que as duas recebem o validador e só o *Tool Calling* recebe as ferramentas auxiliares (Seção 5.4), e no teste A/B, em acurácia e em tempo de processamento (Seção 5.6).

2.3 Modelos de Linguagem de Grande Porte e Execução Local

Os LLMs, baseados na arquitetura *Transformer* (VASWANI et al., 2017), geram a resposta um *token* (fragmento de palavra) por vez, condicionados ao *prompt* de sistema, à consulta e ao que já geraram. O porte do modelo é o número de pesos, os parâmetros numéricos aprendidos no treinamento, contado em bilhões (B), como no Qwen 3 4B. A propriedade que mais importa aqui é seguir instruções em linguagem natural (*instruction following*), obtida pelo ajuste fino com instruções e com *feedback* humano (OUYANG et al., 2022). O *Tool Calling* depende dela, porque o modelo precisa entender a consulta, interpretar o *schema* das ferramentas e decidir como preenchê-lo.

2.3.1 Vantagens e Desvantagens da Execução Local

Executar os LLMs localmente, em vez de usar APIs de serviços em nuvem, traz vantagens para instituições como a DSG (OLLAMA, 2023). As consultas e os dados não trafegam por redes externas, o que pesa em organizações com restrições de sigilo. Não há custo recorrente por *token*. A organização mantém a versão exata do modelo em uso, o que permite auditá-lo. O sistema funciona sem conexão com a Internet.

A execução local tem também desvantagens:

- **Acesso limitado aos modelos de fronteira.** Os LLMs proprietários mais capazes não têm os pesos publicados e ocupam a maior parte das primeiras posições em *benchmarks* de chamada de funções, como o *Berkeley Function Calling Leaderboard* (BFCL) (PATIL et al., 2025).
- **Custo de infraestrutura.** O gasto passa do pagamento por uso para o *hardware*. A organização precisa adquirir e manter servidores com GPU e VRAM suficientes e arcar com energia, refrigeração e atualização de *drivers*.
- **Ciclo de atualização interno.** Cada nova versão de modelo exige repetir a avaliação sistemática.

2.3.2 Ollama e Modelos com Suporte a *Tool Calling*

O Ollama (OLLAMA, 2023) é uma plataforma de código aberto que instala, executa e gerencia modelos de linguagem localmente. Ele expõe uma API compatível com o padrão OpenAI, o que facilita a integração com *frameworks* como o LangChain. Para gerar as respostas, usa o `llama.cpp`, com os modelos no formato GGUF (GGML CONTRIBUTORS, 2023). O formato comporta quantizações como Q4_0 e Q4_K_M, que reduzem a precisão dos pesos de 16 para cerca de 4 bits com perda pequena de qualidade, como mostram métodos de quantização pós-treinamento em 4 bits (FRANTAR et al., 2023). Este trabalho usou quantizações de 4 bits, Q4_K_M ou a equivalente da *build* publicada de cada modelo (Seção 4.2), o que divide por cerca de quatro a memória de vídeo ocupada pelos pesos. Como ordem de grandeza, os pesos em 4 bits ocupam cerca de 0,5 GB por bilhão de parâmetros, e a memória do contexto, que cresce com o texto processado, se soma a eles.

A Tabela 2 lista os quatro modelos avaliados (Seção 4.2). Os tamanhos orientaram a escolha de modelos executáveis na estação de referência, com GPU de 4 GB de VRAM, em que nenhum dos quatro coube inteiro. O excedente roda na CPU (*offload*), o que aumenta a latência (Seção 4.4.1).

Tabela 2 – Modelos avaliados, com suporte a *Tool Calling* no Ollama

Modelo	Parâmetros	Tamanho aprox. (4 bits)	Organização
Gemma 4 E2B	2B efet.	~4 GB ^a	Google DeepMind
Gemma 4 E4B	4B efet.	~5,7 GB ^a	Google DeepMind
Qwen 3 4B	4B	~2,3 GB	Alibaba Cloud
Mistral Nemo 12B	12B	~6,6 GB	Mistral AI e NVIDIA

Fonte: Compilado pelos autores a partir de Ollama (2023) e da documentação oficial dos modelos.

Nota: ^a Tamanho da *build* com quantização consciente de treinamento (QAT, 4 bits) publicada no Ollama (`gemma4:e2b-it-qat` e `gemma4:e4b-it-qat`). “Efet.” indica parâmetros efetivos; o total armazenado é maior (4,6B no E2B, segundo o Ollama), o que explica, em parte, o tamanho acima da ordem de grandeza de 0,5 GB por bilhão de parâmetros.

2.4 Orquestração com LangChain

O LangChain (CHASE, 2022) é um *framework* de código aberto para aplicações com LLMs, com uma interface comum para modelos, *prompts* e ferramentas. Neste trabalho, ele liga a ferramenta de busca ao modelo, recolhe as chamadas de ferramenta que o modelo gera e é a interface única com os modelos no *pipeline* de avaliação. Trocar a classe do Ollama (`ChatOllama`) pela de um provedor em nuvem (`ChatOpenAI` ou `ChatAnthropic`) exige alteração mínima no código, e a escolha entre execução local e em nuvem passa a ser uma decisão gerencial. O LangGraph (LANGCHAIN AI, 2024), extensão que modela fluxos como grafos de estados, não foi necessário. Na v1, a tradução é uma única decisão do modelo, e o laço da v3 é curto, tem limites fixos e é escrito explicitamente (Seções 3.4.2 e 4.6.4).

2.5 Métricas de Avaliação

As métricas servem para escolher o modelo e a abordagem a implantar, diante do compromisso entre qualidade e latência, e para reavaliar a solução quando surgirem modelos novos, o que o *pipeline* de avaliação permite a custo baixo (Seção 3.5). As métricas adotadas vêm da literatura de recuperação de informação (MANNING; RAGHAVAN; SCHÜTZE, 2008). Elas medem a correção total, a correção por campo e o tempo. A acurácia é o critério principal, e as demais desempatam ou medem o custo (Seção 4.5). A comparação com o gabarito é feita campo a campo, e não byte a byte, com as regras de normalização da Seção 4.4.3.

A **acurácia** é a proporção de consultas em que o modelo extraiu corretamente todos os parâmetros esperados, sem acrescentar parâmetros ausentes do gabarito. Nas consultas em que o gabarito prevê não buscar, a resposta é correta quando o modelo não

chama a ferramenta de busca.

$$\text{Acurácia} = \frac{\text{Número de consultas completamente corretas}}{\text{Total de consultas}}.$$

É a métrica mais estrita, porque qualquer erro em qualquer parâmetro torna a consulta incorreta.

A análise por campo usa a **precisão**, o **recall** e o **F1-score**,

$$\text{Precisão} = \frac{TP}{TP + FP} \quad \text{Recall} = \frac{TP}{TP + FN} \quad F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}},$$

em que *TP* (*true positives*) são os campos com valor aceito, *FP* (*false positives*) os campos com valor errado ou que não deviam ser emitidos e *FN* (*false negatives*) os campos obrigatórios omitidos. A decisão de recusar uma consulta é avaliada com as mesmas medidas, como uma classificação (Seção 4.4.3).

A **latência** é o tempo da tradução, do envio da consulta ao modelo até a decisão final de busca, numa ou em várias chamadas ao modelo. Ela é reportada por ambiente de execução, com estatísticas da sua distribuição sobre as consultas (Seção 4.4.3).

2.6 Trabalhos Relacionados

O ponto de partida direto deste trabalho, o protótipo do 1º CGEO (1º CENTRO DE GEOINFORMAÇÃO, 2025), é analisado na Seção 3.1.

Interfaces de linguagem natural para bancos de dados.

Na formulação *text-to-SQL*, o modelo gera a consulta SQL completa a partir da pergunta e do esquema do banco. O *dataset Spider* (YU et al., 2018) consolidou essa avaliação, com cerca de dez mil perguntas sobre 200 bancos. Com os LLMs, a abordagem passou a depender sobretudo do *prompt*, e a ambiguidade e a subespecificação da linguagem natural estão entre os problemas centrais apontados pela literatura (LIU et al., 2025). Neste trabalho, a formulação é mais restrita. O modelo não escreve SQL nem vê o esquema do banco. Ele só preenche os parâmetros tipados de uma ferramenta fixa, e o *backend* monta com esses valores uma consulta SQL parametrizada. A restrição elimina o risco de SQL inválido ou injetado pelo modelo e permite validar cada argumento contra os enumerados do domínio. O custo é atender só às buscas que a ferramenta representa.

LLMs em geoinformação.

Mai et al. (2024) discutem as oportunidades e os desafios dos modelos de fundação para a inteligência artificial geoespacial, e Manvi et al. (2024) mostram que o conhecimento geográfico dos LLMs serve a tarefas de predição quando o *prompt* traz contexto

do OpenStreetMap. Os LLMs passaram também a comandar tarefas de Sistemas de Informação Geográfica (SIG). O LLM-Geo, SIG autônomo construído por Li e Ning (2023) sobre o GPT-4, gera e executa o código que coleta, analisa e visualiza dados espaciais, e o GeoGPT (ZHANG et al., 2024) planeja e encadeia ferramentas de SIG a partir de pedidos em linguagem natural. Nesses sistemas, o modelo tem alta autonomia. Neste trabalho, o modelo, aberto e executado localmente, só decide se busca e com quais argumentos, numa chamada na v1 e num laço curto com ferramentas auxiliares e um validador na v3, sempre com uma única ferramenta de busca.

Descoberta de dados geoespaciais.

A dificuldade de encontrar dados em geoportais é anterior aos LLMs. Hu et al. (2015) atribuem, em parte, à heterogeneidade dos metadados e propõem harmonização de tópicos e busca semântica em geoportais baseados em *Linked Data*. Com os LLMs, Ning et al. (2025) propõem um agente que escolhe a fonte de dados numa lista predefinida e gera o programa que a recupera, e Li et al. (2025) combinam LLMs e um grafo de conhecimento construído a partir de cinco grandes portais para responder a perguntas de descoberta de dados. No caso da DSG, o catálogo é único e já estruturado, e o problema se reduz a traduzir a intenção do usuário nos filtros desse catálogo. Por isso a solução dispensa grafo de conhecimento e geração de código.

Avaliação da chamada de ferramentas.

Os trabalhos sobre uso de ferramentas por LLMs trouxeram *benchmarks* próprios, como o API-Bank (LI et al., 2023), o ToolBench do ToolLLM (QIN et al., 2024), com mais de 16 mil APIs reais, e o APIBench do Gorilla (PATIL et al., 2024). O BFCL (PATIL et al., 2025) compara a chamada gerada com a esperada pela árvore sintática e avalia também a abstenção. Segundo ele, os melhores modelos vão bem em chamadas de um único turno, mas ainda não em memória, decisões dinâmicas e raciocínio de longo prazo. Esses *benchmarks*, na maioria em inglês, de domínio geral e com muitas ferramentas, não cobrem o cenário deste trabalho, que reúne uma única ferramenta de busca, consultas em português com o vocabulário da cartografia sistemática (MI, INOM, escalas, centros produtores) e modelos pequenos executados localmente. Por isso este trabalho construiu um *dataset* próprio, com gabarito auditado e comparação campo a campo semelhante, em espírito, à comparação estrutural do BFCL.

Ferramentas auxiliares e retorno.

No ReAct (YAO et al., 2023), o modelo alterna raciocínio e ações, e o resultado de cada ação alimenta o passo seguinte. A correção funciona quando o sinal vem de fora

do modelo. O CRITIC (GOU et al., 2024) verifica a saída com ferramentas e a revisa, e o *self-debugging* (CHEN et al., 2024) corrige consultas a partir do resultado da execução. A autocorreção sem sinal externo (MADAAN et al., 2023) pode não ajudar e até piorar o raciocínio (HUANG et al., 2024). O ToolSandbox (LU et al., 2025) aponta a normalização de argumentos, como datas relativas e lugares, entre as maiores dificuldades. O When2Call (ROSS; MAHABALESHWARKAR; SUHARA, 2025) mostra que decidir entre chamar, perguntar ou recusar é uma capacidade própria, fraca em modelos pequenos. O τ -bench (YAO et al., 2025) avalia diálogos com usuário simulado, e o CRITICTOOL (HUANG et al., 2025) classifica os erros de chamada que o modelo precisa perceber e corrigir.

Ajustar um sistema pelos erros de um conjunto rotulado arrisca torná-lo bom só nesse conjunto (sobreajuste). O risco vale para as lições que o modelo acumula a partir de sucessos e falhas, como no Reflexion (SHINN et al., 2023) e no ExpeL (ZHAO et al., 2024), e para a otimização automática de *prompts* (YANG et al., 2024; KHATTAB et al., 2024). Medir o resultado exige um conjunto de teste que o desenvolvimento não tenha visto (DWORK et al., 2015). A v3 (Seção 4.6.4) leva a um domínio restrito as ferramentas auxiliares determinísticas, a validação com retorno e o pedido de esclarecimento a um usuário simulado, acrescentados em degraus, e foi testada num lote que o desenvolvimento não leu.

3 DESENVOLVIMENTO DA SOLUÇÃO

O projeto seguiu a Estrutura Analítica do Projeto (EAP) da Figura 3, que cobre a construção do sistema e a sua avaliação. Este capítulo descreve a construção, e o Capítulo 4 detalha a avaliação.




Figura 3 – Estrutura Analítica do Projeto (EAP)

Fonte: Elaborado pelos autores.

3.1 Análise do Protótipo do 1º CGEO

3.1.1 Arquitetura e Contribuições

A Divisão de Levantamento “Gen Augusto Tasso Fragoso”, do 1º CGEO, desenvolveu o protótipo como prova de conceito do uso de LLMs locais na busca sobre o catálogo sob sua guarda (1º CENTRO DE GEOINFORMAÇÃO, 2025). O código é público, e os 22 casos de teste do protótipo formam a camada P do *dataset* de avaliação (Seção 4.3.1). A Figura 4 mostra as quatro camadas.

O *frontend*, em React com Leaflet, mostra os resultados num mapa do Brasil. O *backend*, em Node.js com Express, recebe a consulta pela rota `POST /api/natural-search`. Antes do LLM, um pré-processador normaliza variações de grafia com um dicionário fixo no código (“25k” → “1:25.000”). O núcleo é o Phi-4 14B




Figura 4 – Arquitetura do protótipo de busca do 1º CGEO

Fonte: Adaptado de 1º Centro de Geoinformação (2025).

(ABDIN et al., 2024), executado via Ollama, com Saída Estruturada pela biblioteca Instructor e *schema* em Zod. O *schema* pede um campo **reasoning**, em que o modelo justifica a extração, e os doze campos de busca (**keyword**, **scale**, **productType**, **state**, **city**, **supplyArea**, **project**, **publicationPeriod**, **creationPeriod**, **sortField**, **sortDirection** e **limit**). O *prompt* traz exemplos resolvidos (*few-shot prompting*). Se o LLM falhar mesmo após três novas tentativas, um *fallback* por expressões regulares tenta extrair do texto parte dos campos (escala, tipo de produto, área de suprimento, projeto, ordenação, limite e períodos). O PostgreSQL/PostGIS combina busca textual com operações espaciais e devolve GeoJSON. O repositório traz o esquema do banco (`init.sql`, quatro tabelas), mas não os dados do acervo.

O protótipo demonstrou que (i) LLMs locais são tecnicamente viáveis no domínio cartográfico, (ii) o Phi-4 14B extrai parâmetros de busca relevantes de consultas em português, (iii) *few-shot prompting* com Saída Estruturada produz resultados utilizáveis, o que este trabalho mediu na Seção 5.2, e (iv) a integração do LLM com o PostgreSQL/PostGIS para busca espacial funciona em ambiente controlado.

3.1.2 Limitações

O cliente apontou seis limitações do protótipo, que definem as frentes de aprimoramento:

1. **Backend em Node.js.** As bibliotecas de integração com LLMs (LangChain, LlamaIndex, Instructor) têm versões mais completas em Python.
2. **Apenas Saída Estruturada.** O modelo devolve sempre a estrutura predefinida e não pode encadear ferramentas nem reagir ao resultado de operações anteriores.

3. **Modelo único e defasado.** Com um só modelo, não há como comparar alternativas e escolher a mais adequada, num ecossistema que muda depressa.
4. **Dicionário fixo no código.** O pré-processador aplica 159 pares de substituição antes de o texto chegar ao LLM. Variações não previstas no desenvolvimento (“dois cgeo”, “25 mil”) falham em silêncio. A manutenção é manual, a partir dos erros vistos no *log*. Um termo do dicionário em contexto ambíguo pode ainda deturpar uma consulta legítima.
5. ***Fallback* por expressões regulares.** Sua presença indica falhas do LLM que não foram documentadas de forma sistemática, o que dificulta a análise de causa.
6. **Ausência de métricas de avaliação.** Os 22 casos de teste são pontuados por pesos atribuídos *ad hoc* aos campos esperados, sem penalizar campos preenchidos indevidamente, e não há protocolo para comparar modelos, *prompts* ou configurações.

3.2 Requisitos

Os requisitos vieram da análise do protótipo e das conversas com o cliente. O Quadro 1 traz cada um, a seção que o atende e como foi verificado. A latência (RNF2) depende do *hardware* e da carga do ambiente de implantação, que estão fora do escopo. Por isso ela é reportada por ambiente (Seção 4.4.1), sem limiar fixado *a priori*.

3.3 Planejamento da Migração

A estratégia foi a **substituição dirigida**. Os componentes responsáveis pelas limitações da Seção 3.1.2 foram substituídos, e o esquema do banco, os parâmetros de busca e a lógica das consultas espaciais foram aproveitados. O Quadro 2 liga cada limitação à solução adotada, e o Quadro 3 classifica cada componente do sistema final.

3.4 Arquitetura da Solução v1

A Figura 5 mostra as camadas da solução. A v2 e a v3 mudam só a camada de tradução (Seções 4.6.3 e 4.6.4). O padrão da API é hoje o *Tool Calling* v3 com o Gemma 4 E4B (Seção 3.5.1).

3.4.1 API

A API REST usa o FastAPI (RAMÍREZ, 2018), pela validação das requisições com Pydantic e pela documentação gerada automaticamente. A rota `POST /api/search`

Quadro 1 – Requisitos da solução, onde são atendidos e como foram verificados

Requisito	Descrição	Atendido em	Verificação
RF1	Receber consulta em linguagem natural por rota REST	Seção 3.4.1	Demonstrado na API sobre os dados sintéticos; testes automatizados da API
RF2	Traduzir a consulta nos doze parâmetros do <i>schema</i>	Seção 3.4.2	Avaliado no Capítulo 5
RF3	Executar a busca no PostgreSQL/PostGIS	Seção 3.4.3	Demonstrado sobre os dados sintéticos; não avaliado
RF4	Selecionar o modelo por requisição (só em desenvolvimento)	Seção 3.4.1	Implementado e coberto por teste da API; fora das métricas
RF5	Registrar, por consulta, os parâmetros, as chamadas, os tempos e os erros, para o cálculo das métricas	Seção 3.5	Registros e manifestos de todas as rodadas
RNF1	Execução totalmente local	Seções 3.4.2 e 4.2	Modelos locais; nuvem só como referência
RNF2	Latência compatível com uso interativo	Seção 4.4.1	Medida por ambiente, sem limiar fixado
RNF3	Conformidade com a ET-PCDG e o Perfil MGB na estrutura dos metadados	Seção 3.4.3	Esquema do protótipo reaproveitado; conformidade não verificada à parte
RNF4	Reprodutibilidade dos experimentos	Seção 4.4.4	Manifestos, <i>hashes</i> e repontuação
RNF5	Manutenibilidade	Seção 3.5.1	Testes automatizados e integração contínua
RNF6	Substituição do modelo por configuração	Seção 3.5.1	Modelo e abordagem escolhidos por configuração

Fonte: Elaborado pelos autores.

recebe a consulta e devolve os parâmetros extraídos, os produtos em GeoJSON, a resposta ao usuário, as latências e os erros. A rota `GET /api/health` informa a versão do Ollama, o estado do banco, o modelo e a abordagem no ar. O *pipeline* de avaliação chama diretamente a camada de tradução, sem passar pela API, para que a latência medida seja a da chamada ao modelo.

Seleção de modelo.

A requisição pode escolher o modelo (RF4) só no ambiente de desenvolvimento. Em operação, o modelo é fixado por configuração, porque trocar de modelo entre requisições recarrega pesos na VRAM.

Tratamento de falhas.

Na v1 e na v2, cada falha do LLM é registrada como métrica, sem novas tentativas nem *fallback* (limitação 5). As falhas se dividem em erros de infraestrutura (tempo esgotado, servidor ou modelo indisponível) e erros do modelo (argumentos fora do *schema*,

Quadro 2 – Mapeamento entre limitações do protótipo e soluções adotadas

#	Limitação	Solução adotada	Componente afetado
1	<i>Backend</i> em Node.js	Reimplementação em Python com FastAPI	Nova API REST
2	Apenas Saída Estruturada	<i>Tool Calling</i> nativo via LangChain	Serviço de LLM
3	Modelo único (Phi-4 14B)	Avaliação comparativa de quatro modelos atuais (Qwen 3 4B, Gemma 4 E2B, Gemma 4 E4B, Mistral Nemo 12B)	Configuração e testes
4	Pré-processamento manual	Normalização delegada ao LLM, orientada pelas descrições do <i>schema</i> da ferramenta	Remoção do pré-processador
5	<i>Fallback</i> via regex	Falhas registradas como métrica, sem <i>fallback</i> oculto	Serviço de LLM
6	Ausência de métricas	<i>Dataset</i> auditado com gabarito + <i>pipeline</i> de avaliação automatizado	Novo módulo de avaliação

Fonte: Elaborado pelos autores.

Nota: Soluções da v1. A v3 acrescenta, nas linhas 4 e 5, ferramentas auxiliares e o retorno de um validador (Seção 3.4.2).

chamada a ferramenta inexistente). Um *fallback* de produção fica como trabalho futuro (Seção 6.4).

3.4.2 Orquestração e Ferramenta de Busca

A orquestração usa o ChatOllama do LangChain (CHASE, 2022), com a configuração da Seção 4.4.2. Na v1, a tradução é uma única chamada ao modelo, e o ciclo completo (executar a ferramenta e devolver o resultado ao modelo para a resposta final) é escrito no próprio módulo de *pipeline*.

A ferramenta `buscar_catalogo` tem os doze parâmetros de busca, cada um com tipo e, quando cabe, a lista fechada de valores válidos (o enumerado). Dez deles trazem na descrição instruções de normalização. O *schema* fica num único módulo, que também serve para validar os argumentos do modelo e os enumerados do *dataset*, e o seu *hash* vai para o manifesto de cada rodada. Sem dicionário nem exemplos resolvidos no *prompt*, o modelo normaliza os termos guiado só pelas descrições, que substituem as 159 entradas do dicionário do protótipo (limitação 4).

A v1 expõe só `buscar_catalogo`, e a v2 acrescenta `recusar_consulta` (Se-

Quadro 3 – Classificação dos componentes do sistema final em relação ao protótipo

Componente	Categoria	Observação
Esquema do banco PostgreSQL/PostGIS	Reaproveitado	Mesmo esquema do protótipo (<code>init.sql</code> , quatro tabelas), sem alterações
Conjunto de parâmetros de busca	Reaproveitado	Os mesmos doze campos, compatíveis com a lógica das consultas SQL; enumerados recortados (9 tipos de produto e 9 projetos, contra 30 e 15 no protótipo) e grafados conforme a ET-PCDG
Lógica das consultas SQL	Reaproveitado	Portada de <code>search.ts</code> ; direção de ordenação restrita a <code>ASC</code> ou <code>DESC</code> ; aceita períodos com um só limite; sem o filtro por retângulo do mapa e a paginação, próprios do <i>frontend</i>
<i>Frontend</i> React/Leaflet	Fora do escopo	Não é parte deste trabalho
API REST	Reescrito	Node.js/Express → Python/FastAPI
Serviço de LLM	Reescrito	Saída Estruturada (Instructor/Zod) → <i>Tool Calling</i> (LangChain)
Camada de acesso ao banco	Reescrito	<code>pg-promise</code> → <code>psycopg</code>
Pré-processamento de termos	Eliminado	Função transferida ao LLM
<i>Fallback</i> com regex	Eliminado	Falhas viram métricas
Dados sintéticos do banco	Novo	Apenas para a demonstração ponta a ponta (Seção 3.4.3)
<i>Dataset</i> de avaliação	Novo	310 consultas com gabarito auditado (Cap. 4 e Ap. A)
<i>Pipeline</i> de avaliação	Novo	Execução, pontuação, conferência e relatórios (Seção 3.5)
Ferramentas auxiliares e validador (v3)	Novo	No pacote, no avaliador e na API, como abordagem padrão (Seção 4.6.4)
Registro de abordagens, testes e integração contínua	Novo	Registro único das configurações avaliadas, testes de regressão e guia de extensão (Seção 3.5.1)

Fonte: Elaborado pelos autores.

ção 4.6.3). A v3 (Seção 4.6.4) acrescenta `identificar_nome`, `normalizar_codigo`, `normalizar_escala`, `resolver_periodo` e `pedir_esclarecimento`. A v3 devolve parte da normalização ao código, em ferramentas que o modelo consulta quando precisa e num validador que confere a saída, e a consulta chega ao modelo sem reescrita prévia.

3.4.3 Persistência

O banco usa, sem alterações, o esquema do protótipo, em PostgreSQL com PostGIS (POSTGIS DEVELOPMENT TEAM, 2001). Como o protótipo não traz os dados




Figura 5 – Arquitetura da solução aprimorada de busca

Fonte: Elaborado pelos autores.

do acervo, a demonstração ponta a ponta usa dados sintéticos, gerados por *script* com semente fixa (27 unidades da federação representadas por retângulos numa grade, 14 municípios, cinco áreas de suprimento e 117 produtos). **Nenhuma métrica deste trabalho depende do banco**, porque a avaliação incide sobre os parâmetros extraídos pelo modelo. O Docker Compose sobe o PostgreSQL 16 com PostGIS 3.4.

A lógica portada do `search.ts` combina busca textual, códigos MI e INOM, filtros, períodos, interseções espaciais, ordenação e limite, com os ajustes do Quadro 3. As consultas são parametrizadas, e o modelo nunca escreve SQL.

Os enumerados do novo *schema* grafam alguns valores de modo diferente do protótipo (acentos, travessões e nomes). Os dados sintéticos seguem a grafia nova, e ligar a API ao banco do acervo exige conferir a grafia guardada nele. A resolução dos campos geográficos em geometrias fica fora do escopo (Seção 1.6).

3.4.4 Consultas sem Resposta no Acervo

O sistema distingue três desfechos, e em nenhum deles inventa um produto:

1. **Consulta fora do domínio do catálogo** (“cartas de Marte”). Não há busca. Na v1, o modelo não chama a ferramenta e responde em uma frase por que o pedido está fora do escopo. No *Tool Calling* v2 e v3, ele chama `recusar_consulta`, cujo argumento `motivo` é a frase dirigida ao usuário (na Saída Estruturada v2 e v3, a recusa é o campo `fora_do_escopo`). Na v3, a primeira recusa de uma consulta que cita um critério do catálogo volta ao modelo para confirmação (Seção 4.6.4). A categoria F do *dataset* mede esse comportamento.

2. **Busca com produtos.** A lista vem sempre do banco, e o modelo só a resume.
3. **Busca legítima sem produto.** A API devolve a lista vazia e uma mensagem fixa com os critérios usados, que sugere retirar ou ampliar algum deles, sem nova chamada ao modelo.

Nos pedidos com valores que a ferramenta não representa (“escala 1:10.000.000”, “cartas do estado 42”), o texto não determina o comportamento correto. O *dataset* os trata como casos observacionais, fora das métricas principais (Seção 5.1.2).

3.5 Pipeline de Avaliação

O *pipeline* de avaliação produz os números do Capítulo 5. Ele gera, da mesma fonte, o arquivo de consultas avaliado e as listagens do Apêndice A, validados contra o *schema*, e roda as checagens automáticas da auditoria do gabarito (Seção 4.3.3). Executa as consultas em ordem fixa, de forma sequencial e retomável, guarda a resposta, os tempos e os erros de cada consulta e repetição e grava um manifesto de reprodutibilidade por rodada (RNF4). A pontuação é sempre recalculada contra o gabarito vigente, e uma correção do gabarito não exige nova execução dos modelos. Antes da consolidação, ele confere os *hashes* e a completude das rodadas. Depois gera as tabelas, as figuras e os testes estatísticos, inclusive os dos lotes e do teste A/B. A referência em nuvem roda no mesmo avaliador, pelo Groq (Apêndice B.3). Os comandos estão no Apêndice C.1.

3.5.1 Registro de Abordagens e Implantação

Um módulo único, o registro de abordagens, reúne as nove configurações avaliadas no estudo, da solução v1 às especificações v2 e v3 e ao método do protótipo (Quadro 5). Os módulos das versões avaliadas ficam congelados, e um teste de regressão confere que o código atual reproduz os *hashes* de *prompt* e de ferramenta de todas as rodadas válidas.

A API escolhe a abordagem e o modelo por configuração (RNF6). O padrão é o *Tool Calling* v3 com o Gemma 4 E4B (Seção 5.7.1), e a v1 continua disponível. O `/api/health` mostra os *hashes* de *prompt* e de ferramenta e as rodadas feitas com a mesma configuração, o que permite verificar se o que está no ar foi o avaliado. Na API, o pedido de esclarecimento da v3 continua respondido pelo usuário simulado da avaliação (Seção 4.6.4), e levá-lo ao usuário real exige conversa em vários turnos (Seção 6.4). O índice de folhas do BDGEx, de que as ferramentas da v3 dependem, não está no repositório. Sem ele, a API sobe em modo degradado, com aviso, e o teste de regressão pula os casos da v3 (Apêndice C).

Um *Dockerfile* empacota a API. Os testes automatizados cobrem o *schema*, as consultas SQL, as métricas e a API, sem depender do Ollama nem do banco (RNF5), e a

integração contínua os roda a cada mudança (Apêndice C.1). Um guia de extensão exige que cada versão nova seja testada num conjunto ainda não usado, e uma v4 precisaria de um terceiro lote. Os autores implementaram muitas partes do sistema, e o restante do código e dos testes foi escrito com apoio do Claude Code, com os modelos Claude Opus 4.6 e Claude Opus 5.5, a partir da especificação deles (Tabela 8).

3.6 Cronograma

O projeto foi executado entre abril e outubro de 2026, em oito fases (Quadro 4). As fases F0, F1 e F5 correspondem aos pacotes de construção da EAP, e as fases F2, F3, F4 e F6 à avaliação, detalhada no Capítulo 4. A F6 aparece dividida pelas datas do histórico do repositório.

Quadro 4 – Cronograma de execução do projeto

Fase	Atividade	Período	Marco
F0	Análise do protótipo: código-fonte, dependências, esquema do banco e limitações documentadas	abr/2026	Limitações mapeadas
F1	Elicitação de requisitos e planejamento da migração (limitação → solução; componentes reaproveitados, reescritos e novos)	mai/2026	Requisitos e plano de migração
F2	Referencial teórico; seleção dos modelos; definição das métricas e do protocolo de avaliação	mai–jun/2026	Protocolo de avaliação
F3	Construção do <i>dataset</i> de avaliação: camadas P, N e G e respectivo gabarito (Apêndice A)	jun–jul/2026	310 consultas anotadas
F4	Prova de conceito do <i>Tool Calling</i> sobre consultas representativas, com modelo local e em nuvem	ago/2026	Viabilidade do <i>Tool Calling</i> demonstrada
F5	Implementação: API, orquestração, ferramenta <code>buscar_catalogo</code> , persistência e <i>pipeline</i> de avaliação, com testes automatizados	set/2026	Sistema ponta a ponta
F6a	Rodadas completas das 310 consultas, validação na estação de referência, referência em nuvem e auditoria do <i>dataset</i>	14–26/set/2026	Resultados da v1
F6b	Linhas de base com Saída Estruturada e método do protótipo; lote 1 e especificação v2	28/set/2026	Comparação das abordagens
F6c	Rodadas do lote 1; v3 congelada; lote 2 e teste da v3	29/set/2026	Teste da v3
F6d	Extensão da v3 a outros modelos; registro de abordagens e API com a v3; teste A/B; latência na estação	29–30/set/2026	Recomendação
F7	Redação dos resultados e da conclusão; preparação da defesa	set–out/2026	Defesa (out/2026)

Fonte: Elaborado pelos autores.

4 METODOLOGIA

Este capítulo descreve o desenho do estudo e de cada etapa, os conjuntos de avaliação, o protocolo de medição e os critérios de decisão.

4.1 Desenho do Estudo

O estudo teve seis etapas (Quadro 5). As etapas 1 e 2 escolheram o modelo da solução v1 do Capítulo 3 e a compararam com a Saída Estruturada e com o método do protótipo. As etapas 3 e 4 avaliaram as especificações v2 e v3, que não estavam previstas no início e nasceram dos resultados das etapas anteriores. As etapas 5 e 6 estenderam a v3 a outros modelos e reuniram as duas abordagens num teste A/B.

Cada especificação foi testada num conjunto que não serviu para desenvolvê-la. Um conjunto de teste é usado uma só vez, porque ajustar a especificação aos seus resultados o converteria em conjunto de desenvolvimento (DWORK et al., 2015). As 310 consultas escolheram o modelo e compararam as abordagens na v1, e os erros nelas orientaram a v2, avaliada no lote 1 (validação). A v3 foi desenvolvida nas 310 e no lote 1, com os ciclos numa amostra de 160 consultas dele, e testada uma vez no lote 2 (teste). As 62 consultas das camadas P e N (Seção 4.3.1) medem a latência na estação de referência (Seção 4.4.1).

Um número é chamado **dentro da amostra** quando foi medido num conjunto usado para desenhar ou ajustar a configuração. Ele fica como registro e não decide. Uma análise é **exploratória** quando não estava no plano de análise registrado antes do teste da v3 (Seção 4.6.4), foi feita depois do teste e não alterou a v3.

Quadro 5 – Etapas do estudo, configurações avaliadas e conjunto de cada medida

Etapa	Configuração	O que muda em relação à anterior	Onde foi medida e com que papel	Resultado
1. Escolha do modelo	<i>Tool Calling</i> v1	ferramenta buscar_catalogo ; <i>prompt</i> sem exemplos nem dicionário; uma chamada	quatro modelos locais nas 310, na T4, três repetições (decide); Qwen 3 4B, Gemma 4 E2B e, depois, Gemma 4 E4B nas 62 P e N da estação (latência); três modelos no Groq nas 310 (referência)	Seção 5.1
2. <i>Tool Calling</i> × Saída Estruturada	Saída Estruturada v1	o mesmo <i>prompt</i> sem as duas instruções sobre chamar a ferramenta; <i>schema</i> no <i>prompt</i> ; modo JSON; validação Pydantic; não tem como recusar	os mesmos modelos nas 310, uma repetição (decide); Groq; 62 P e N na estação	Seção 5.2
	Método do protótipo	Phi-4 14B; dicionário de 159 entradas; <i>prompt</i> original com dez exemplos; até três novas tentativas; <i>fallback</i> por <i>regex</i>	310 na T4, uma repetição	Seção 5.2
3. Especificação v2 no lote 1	<i>Tool Calling</i> v2	descrições com as convenções do manual; recusar_consulta ; proibido pedir esclarecimento	Gemma 4 E4B; lote 1 (decide); 310 (dentro da amostra)	Seção 5.3
	Saída Estruturada v2	as mesmas descrições; campo fora_do_escopo	idem	idem
	Duas etapas (simulada)	o <i>Tool Calling</i> v2 decide se busca e a Saída Estruturada v1 extrai; simulação <i>post hoc</i> sobre as rodadas	lote 1 e 310; lote 2 (referência)	idem
4. Teste da v3 no lote 2	degrau v3d	descrições corrigidas; ainda uma chamada; chamadas escritas como texto lidas como chamadas	Gemma 4 E4B no lote 2 (teste)	Seção 5.4
	degrau v3a	ferramentas auxiliares; pedido de esclarecimento a um usuário simulado; pedido para responder chamando uma ferramenta; laço de até seis chamadas	idem	idem
	<i>Tool Calling</i> v3	retorno do validador; recusa contestada	lote 2 (teste; decide); 310 e lote 1 (desenvolvimento, dentro da amostra); 62 P e N na estação (latência)	idem
	Controle (Saída Estruturada v3)	descrições v3, validador e recusa contestada como nova tentativa; sem ferramentas auxiliares, usuário simulado, pedido de resposta por ferramenta, leitura de texto e instrução de que lugar desconhecido não justifica recusa	lote 2 (teste); 310 (dentro da amostra); 62 P e N na estação	idem
5. Outros modelos	<i>Tool Calling</i> v1 e v3; Saída Estruturada v1 e controle	a mesma v3 congelada, com outros modelos	Gemma 4 E2B e Qwen 3 4B no lote 2 (comparação principal por modelo); 62 P e N na estação (latência da v3)	Seção 5.5
6. Teste A/B	Pares Modo A × Modo B	reúne as rodadas das etapas 1 a 5 com o mesmo modelo, as mesmas consultas, a mesma especificação e o mesmo ambiente	todos os conjuntos; rodadas novas só na estação, para a latência	Seção 5.6

Fonte: Elaborado pelos autores.

Nota: As rodadas dos lotes usaram a T4, com uma repetição. As quatro configurações v1 e v2 do Gemma 4 E4B rodaram também no lote 2, como referências.

4.2 Modelos Avaliados

Os modelos atendem a quatro critérios. Têm suporte nativo a *Tool Calling* no Ollama, conferido pela etiqueta do catálogo oficial (OLLAMA, 2023), têm versões quantizadas compatíveis com estações modestas, foram lançados ou atualizados entre 2024 e 2026 e diversificam arquiteturas e organizações. Foram avaliados quatro modelos abertos, executados localmente pelo Ollama:

1. **Qwen 3 4B**, da Alibaba Cloud (QWEN TEAM, 2025), *tag* `qwen3:4b-instruct-2507-q4_K_M`, com 4 bilhões de parâmetros e 2,3 GB, na *build* sem raciocínio interno (Seção 4.4.2);
2. **Gemma 4 E4B**, da Google DeepMind (GEMMA TEAM, 2026), *tag* `gemma4:e4b-it-qat`, com cerca de 4 bilhões de parâmetros efetivos, quantização consciente de treinamento e cerca de 5,7 GB;
3. **Gemma 4 E2B** (GEMMA TEAM, 2026), *tag* `gemma4:e2b-it-qat`, com cerca de 2 bilhões de parâmetros efetivos e 4,0 GB, alternativa de menor custo na mesma família;
4. **Mistral Nemo 12B**, da Mistral AI e da NVIDIA (MISTRAL AI, 2024), *tag* `mistral-nemo:12b`, com 12 bilhões de parâmetros e cerca de 6,6 GB, a faixa superior executável com *offload* parcial numa estação modesta.

O Phi-4 14B (ABDIN et al., 2024), modelo do protótipo, entra só na linha de base do método do protótipo (Seção 4.6.2).

Como referência, a mesma avaliação rodou em três modelos maiores servidos pelo Groq, `qwen/qwen3.8-27b`, `openai/gpt-oss-20b` e `openai/gpt-oss-120b` (QWEN TEAM, 2026; OPENAI, 2025). Eles têm pesos abertos, sob licença Apache 2.0, mas não são candidatos à implantação, porque o RNF1 exige execução local. Servem só para situar os modelos locais nas mesmas condições, e os seus resultados são reportados à parte.

4.3 Conjuntos de Avaliação

As 310 consultas e os dois lotes servem só para avaliação. Nenhum modelo foi treinado ou ajustado com eles, e cada modelo recebe as consultas uma a uma, sem exemplos resolvidos (*zero-shot*).

4.3.1 As 310 Consultas

Cada consulta registra o texto, a leitura preferencial do gabarito, as demais leituras aceitas, se o correto é buscar ou não e uma origem rastreável (Tabela 17, Apêndice A.15).

O arquivo avaliado e as listagens do Apêndice A saem da mesma fonte.

As consultas pertencem a seis categorias, alinhadas aos exemplos do protótipo e às demandas do cliente. São as **simples** (S, “cartas de São Paulo”), as **compostas** (C, “ortoimagens de Manaus em 1:50.000”), as **com código MI ou INOM** (M, “INOM SG-22-X-A”), as **com tempo relativo** (T, “nos últimos 3 meses”), as **com ordenação** (O, “as 3 cartas mais antigas”) e as **ambíguas ou informais** (A, com siglas e grafias sem acento). Uma consulta pode pertencer a mais de uma. A sétima, **fora do domínio** (F, “cartas de Marte”), não se combina com as demais e reúne as consultas em que o correto é não chamar a ferramenta (Tabela 18, Apêndice A.15).

As 310 consultas foram construídas em três camadas (Tabela 3):

1. **Camada P (protótipo, 22 consultas).** São as consultas do arquivo de casos de teste do protótipo, rastreadas até a linha de origem. A anotação original da equipe do 1º CGEO fica como leitura preferencial, as leituras alternativas acrescentadas seguem o manual, e as datas relativas viraram as regras nomeadas da Seção 4.3.2.
2. **Camada N (autores, 40 consultas).** Cobrem lacunas, em especial a categoria S, ausente na camada P, e exercitam ambiguidades e casos de fronteira do domínio.
3. **Camada G (geração programática, 248 consultas).** Modelos de frase do português corrente combinam catálogos fechados do domínio (27 UFs, 12 municípios, 8 escalas do SCN, 9 tipos de produto da ET-PCDG, 5 CGEOs, 9 projetos, códigos MI e INOM, 15 expressões de tempo e padrões de ordenação). O gabarito é conhecido por construção, porque a frase é montada a partir dos parâmetros que deve produzir. A geração é determinística (semente 42) e rejeita repetições, inclusive das camadas P e N. A família G-F traz sete consultas de fronteira, seis fora do domínio e uma observacional.

A camada G dá cobertura sistemática de combinações raras e volume para os testes estatísticos. A sua regularidade pode favorecer os modelos, e por isso a acurácia é desagregada por camada (Tabela 29, Apêndice D.1).

4.3.2 Manual de Anotação e Leituras Múltiplas

O gabarito segue um manual de anotação escrito (Apêndice A.1), com seis princípios (evidência explícita no texto, forma canônica, leituras múltiplas explícitas, tratamento das consultas fora do domínio, consistência e casos observacionais) e regras para cada um dos doze campos da ferramenta.

O princípio que mais pesa é o das leituras múltiplas, porque parte das consultas admite mais de uma resposta correta. “Cartas de São Paulo” pode se referir ao estado

Tabela 3 – Composição do *dataset* de avaliação por origem e família

Origem / família	Consultas	Observacionais	Com mais de uma leitura aceita
Protótipo do 1º CGEO (P)	22	0	11
Autores (N)	40	3	15
Geradas — simples (G-S)	61	0	0
Geradas — compostas (G-C)	55	0	3
Geradas — código MI/INOM (G-M)	28	0	0
Geradas — tempo relativo (G-T)	41	0	20
Geradas — ordenação (G-O)	19	0	16
Geradas — informais (G-A)	24	0	2
Geradas — amplas (G-P)	13	0	0
Geradas — fronteira (G-F)	7	1	0
Total	310	4	67

Fonte: Elaborada pelos autores a partir de `dataset.json`.

ou à capital, “últimos 3 meses” pode ser noventa dias ou três meses de calendário, e, em “as cartas mais recentes”, a ordem pode seguir a data de publicação ou a de criação. Um gabarito com uma só leitura contaria como erro uma resposta razoável e mediria a coincidência com a preferência do anotador. Nesses casos, o gabarito lista todas as leituras aceitas, por três mecanismos. O *valor alternativo* aceita mais de um valor no campo, o *campo opcional* pode faltar sem erro (`limit = 1` em “a carta mais recente”), e a *leitura estrutural alternativa* põe o mesmo trecho em campos diferentes (`state` ou `city`). As expressões de tempo relativo são regras nomeadas, resolvidas na data de referência de cada rodada, que o *prompt* informa ao modelo (Quadro 7, Apêndice A.1). Toda leitura aceita está escrita e justificada por uma regra do manual, e fora delas a comparação é estrita (Seção 4.4.3).

Oito consultas estão fora do domínio (N36, N37 e seis da família G-F). Nelas o correto é não chamar a ferramenta, e elas entram nas métricas, na categoria F. Quatro consultas são observacionais (N38, N39, N40 e GF007), porque o texto não determina o comportamento correto, como em “escala 1:10.000.000”. Elas são executadas e reportadas à parte. As métricas principais cobrem as 306 consultas restantes, das quais 67 admitem mais de uma leitura (Tabela 3). A Tabela 19 (Apêndice A.15) dá a frequência de cada campo no gabarito.

4.3.3 Auditoria das 310 Consultas

O gabarito das 310 passou por uma auditoria em três passos (Apêndice A.14):

1. **Checagens automáticas.** Conferem a unicidade das consultas, a validade dos valores, a resolução das regras de tempo em datas diversas, a rastreabilidade da

camada P e a consistência entre casos. Um **anotador por regras** aponta campo sem evidência na consulta, evidência sem campo e valor divergente.

2. **Anotação independente às cegas.** Um agente Claude (Anthropic), de uma família que não está entre as avaliadas, anotou do zero as 310 consultas, em dez blocos de 31 e em sessões independentes, só com o manual, a definição da ferramenta, a data de referência e o bloco, sem acesso ao gabarito.
3. **Adjudicação.** Cada divergência recebeu uma decisão registrada e justificada pelo manual (gabarito mantido, corrigido ou ampliado), com o gabarito anterior guardado.

A Tabela 4 dá a concordância em rigor crescente, da decisão de chamar a ferramenta ao valor de cada campo. Parte das medidas usa o kappa de Cohen (COHEN, 1960; ARTSTEIN; POESIO, 2008), que desconta da concordância entre duas anotações a que se esperaria ao acaso. Ele vale 1 na concordância perfeita e 0 na do acaso.

Tabela 4 – Resultados da auditoria do *dataset*

Verificação	Antes da adjudicação	Após
<i>Checagens automáticas</i>		
Problemas estruturais (ids, duplicatas, enumerados, datas)	—	0
Consultas da camada P conferidas na linha de origem	—	22/22
Apontamentos do anotador por regras sem resolução	—	0
Expressões com anotação inconsistente sem justificativa	—	0
<i>Anotação independente às cegas (310 consultas)</i>		
Decisão (chamar / não chamar / observacional)	302/310 (97,4%)	310/310 (100,0%)
kappa de Cohen	0,658	1,000
Leituras compatíveis nos dois sentidos	300/310 (96,8%)	309/310 (99,7%)
Leitura preferencial idêntica ^a	294/298 (98,7%)	294/298 (98,7%)
Presença de cada campo na leitura preferencial ^{a,b} (kappa)	0,999	0,999
Valor do campo, quando ambos o anotam ^a	534/537 (99,4%)	534/537 (99,4%)
Consulta com mais de uma leitura aceita ^a	296/298 (99,3%)	297/298 (99,7%)
kappa de Cohen	0,981	0,990
Consultas com divergência em alguma medida, sem decisão registrada	14	0
Revisão humana de amostra estratificada: gabarito confirmado	—	40/40 (100,0%)

Fonte: Elaborada pelos autores a partir de `data/auditoria/`. (a) Sobre as consultas em que gabarito e anotador pedem a chamada da ferramenta nas métricas principais. (b) Doze campos por consulta.

Para saber se o gabarito é bom, a auditoria mede a concordância de uma leitura feita do zero. Antes de qualquer correção, ela concordou com o gabarito em 99,4% dos valores de campo e encontrou leitura compatível em 300 das 310 consultas. Na decisão de chamar ou não a ferramenta, as duas anotações concordaram em 302 das 310 consultas, mas o kappa foi de 0,658 (1,000 depois da adjudicação). Como quase todas as consultas pedem busca, a concordância esperada ao acaso já é alta, e o kappa a desconta. As poucas divergências ficaram todas nas classes raras, de não buscar e de caso observacional, e por isso pesam muito.

A principal divergência foi de classificação. O gabarito tratava como observacionais oito consultas fora do domínio cujo comportamento o manual determina, e elas passaram à categoria F. As demais foram uma leitura ampliada (N33) e cinco divergências mantidas com justificativa. Somada uma decisão vinda das checagens automáticas, foram 15 consultas adjudicadas (Quadro 9, Apêndice A.14).

O anotador por regras foi escrito pelos autores e não é uma anotação independente. A anotação às cegas é independente do gabarito, mas foi feita por um modelo de linguagem, e não por uma pessoa. Ela serve para apontar divergências, que a adjudicação decide. Para compensar em parte essa limitação, um dos autores conferiu à mão uma amostra estratificada de 40 consultas (semente 42) e confirmou o gabarito de todas.

4.3.4 Lotes de Validação e de Teste

As 310 consultas têm três limites. As conclusões podem depender da regularidade da camada G, a recusa foi medida em só oito consultas F, e o desempenho do *Tool Calling* pode refletir mais a especificação que a abordagem. Para tratá-los, construiu-se o **lote 1 (validação)**, de 1.929 consultas novas. Nele os valores vêm de catálogos reais, o gabarito de cada consulta é fixado antes de o texto existir, e a consulta só entra se uma anotação às cegas for compatível com o gabarito.

Fontes e alvos.

Os metadados públicos do BDGEx foram coletados pelo serviço CSW em 28/09/2026. Dos 31.190 registros saem nomes de folha (7.838 distintos), códigos, escalas, tipos de produto, CGEOs e anos. A lista do IBGE fornece os 5.571 municípios. Foram sorteados 1.950 alvos (semente 2026) em oito famílias. Cada alvo fixa o gabarito segundo o manual, a grafia com que cada valor deve aparecer na consulta (a sua forma de superfície, como “25k” ou “3o cgeo”), o que a consulta não pode dizer, um registro de linguagem e uma persona. As extensões do manual para os lotes não alteram nenhuma anotação das 310 (Apêndice A.1).

Composição.

A categoria F tem 336 consultas, em dez subtipos, o que permite medir a recusa como classificação. A nova categoria das **subespecificadas** (E, 146 consultas) reúne pedidos sem nenhum critério representável no *schema*, como “cartas do Nordeste”, em que buscar sem filtros e não buscar são aceitos. Como prevê o manual (“pedir esclarecimento ou recusar”), a pontuação aceita qualquer não busca, inclusive a recusa, embora a especificação v2 diga que consultas vagas sobre o acervo não estão fora do escopo (Seção 4.6.3). O efeito dessa regra está na Seção 5.3.

Redação e filtro.

Quinze sessões independentes de agentes Claude redigiram as consultas, cada uma com 130 alvos, sem ver o gabarito. Checagens automáticas conferem as superfícies exigidas, e a deduplicação descarta repetições das 310 e do próprio lote. Outros 15 agentes anotaram do zero as consultas, embaralhadas e sem família, persona ou gabarito. Entra no lote a consulta compatível com o gabarito nos dois sentidos, isto é, a leitura do anotador está entre as aceitas pelo gabarito, e a leitura preferencial do gabarito está entre as que o anotador aceita. Uma amostra de 20% (390 consultas) recebeu uma segunda anotação, fora do filtro. Das 1.950 consultas redigidas, 1.929 (98,9%) formam o lote. Antes do filtro, o kappa na decisão foi de 1,000, e 99,8% das leituras foram compatíveis. Esses números são altos por construção, porque os alvos exigem superfícies explícitas, e redatores e anotadores são agentes da mesma família de modelos. Eles mostram que cada consulta sustenta o seu gabarito segundo o manual. Se pessoas leriam do mesmo modo não foi medido.

Lote 2 (teste).

O lote 2 seguiu a mesma receita, com metade do tamanho, outras sementes (2031 para os alvos) e outras sessões de agentes Claude. Dos 975 alvos ficaram 945 consultas (96,9%), 163 fora do domínio e 65 subespecificadas. Antes do filtro, o kappa na decisão foi de 1,000, com 99,6% de leituras compatíveis. Nenhuma consulta do lote 2 foi lida no desenvolvimento da v3 (DWORK et al., 2015). Os relatórios dos anotadores do lote 2 citaram trechos de algumas dezenas de consultas, e nada da v3 foi escrito ou alterado a partir deles. Nenhum exemplo das descrições, das ferramentas ou dos *prompts* coincide com uma consulta inteira do lote 2, e o que coincide é vocabulário do domínio, como “100k” e “mais recente”. A composição e a concordância dos lotes estão nas Tabelas 20, 21, 22 e 23 (Apêndice A.15).

4.4 Protocolo de Avaliação

Cada modelo executa todas as consultas em ordem fixa pelo *pipeline* de avaliação (Seção 3.5).

4.4.1 Ambientes de Execução

A **estação de referência**, que define o cenário de implantação modesta, tem processador Intel Core i7-12700H, 32 GB de RAM e GPU NVIDIA GeForce RTX 3050 Laptop com 4 GB de VRAM, sob Windows 11 (especificação e Tabela 24 no Apêndice B.1). Nenhum modelo coube inteiro nos 4 GB. O Ollama alocou na GPU 66% do Qwen 3 4B carregado e 38% do Gemma 4 E2B, e o restante executou na CPU. O Gemma 4 E4B, maior, também exige *offload* para a CPU.

As rodadas completas das 310, as linhas de base e os lotes rodaram numa GPU NVIDIA T4 do Google Colab, com 16 GB nominais e 15 GB utilizáveis (Tabela 25, Apêndice B.2). A T4 comporta cada modelo inteiro, o que separa o efeito do modelo do efeito do *offload*. A qualidade depende sobretudo do modelo, embora diferenças numéricas entre GPU e CPU possam alterar respostas isoladas. A latência depende do *hardware* e é reportada por ambiente.

Na estação, o Qwen 3 4B e o Gemma 4 E2B executaram as 62 consultas P e N com uma repetição, na mesma sessão, carregados a frio e com VRAM livre semelhante, para medir a latência e conferir as respostas com a T4. Depois, o Gemma 4 E4B e as configurações v3 dos três modelos rodaram ali, para a latência do teste A/B, com a GPU por vezes compartilhada com outros programas. O manifesto registra a VRAM livre e a parcela do modelo na GPU. A latência de dois modos só é comparada quando as duas rodadas têm a mesma GPU, a mesma versão do Ollama e a mesma parcela do modelo na GPU. Os ciclos de desenvolvimento da v3 também rodaram na estação, com o mesmo arquivo de modelo da T4.

Na referência em nuvem, os três modelos do Groq executaram as 310 consultas com uma repetição, dentro dos limites de taxa do provedor (Apêndice B.3).

4.4.2 Configuração dos Modelos

Todos os modelos rodaram com temperatura zero. A temperatura controla a aleatoriedade na escolha de cada *token*, e com zero o modelo escolhe sempre o mais provável. O limite de saída foi de 1024 *tokens*. Cada consulta foi enviada sem contexto de conversas anteriores e sem dicionário de normalização. Em cada configuração, todos os modelos receberam o mesmo *prompt* de sistema, com a data de referência. Na v3, cada retorno do validador fica registrado no traço da execução.

O raciocínio interno (*thinking*) foi desligado por parâmetro na chamada ao Ollama, para que as latências fossem comparáveis. O modo com raciocínio pode melhorar decisões com vários critérios, e esse ganho não foi medido. Na *build* padrão do Qwen 3 (`qwen3:4b`), o raciocínio não desligava, gerava centenas de *tokens* por consulta e, quando esgotava os 1024, impedia a chamada. Adotou-se por isso a *build* oficial sem raciocínio (*Qwen3-4B-Instruct-2507*), de mesmo porte e quantização. No Groq, o esforço de raciocínio foi o mínimo aceito por cada modelo (GROQ, 2026), `none` para o `qwen/qwen3.8-27b` e `low` para o `openai/gpt-oss-20b` e o `openai/gpt-oss-120b`, porque a família GPT-OSS não permite desligá-lo.

4.4.3 Métricas e Testes Estatísticos

As fórmulas estão na Seção 2.5.

Comparação com o gabarito.

A resposta é comparada campo a campo. Enumerados exigem igualdade exata. As *strings* livres (`keyword`, `state` e `city`) são comparadas após normalização de caixa, acentos e pontuação. Períodos exigem os mesmos limites, e `limit` é inteiro. Quando há leituras múltiplas, vale a de melhor casamento, e campos opcionais ausentes não contam como erro.

Acurácia por consulta.

Uma consulta está correta quando os parâmetros emitidos coincidem com uma leitura aceita, sem campo a mais nem a menos. A acurácia vem com intervalo de confiança de 95% pelo método de Wilson (WILSON, 1927), com o número de consultas como tamanho da amostra. Nas 310, a acurácia das tabelas é a média das três execuções de cada consulta. Os testes usam uma observação por consulta, a maioria das três repetições, porque repetições da mesma sessão quase sempre coincidem e contá-las como independentes exageraria a significância. As diferenças são calculadas sobre os acertos e podem diferir em 0,1 ponto percentual (p.p.) da subtração dos valores arredondados. Cada erro é classificado por tipo (campo inventado, omitido ou errado, erro misto, busca indevida ou ausente e argumento fora do *schema*), e os de infraestrutura ficam à parte.

Precisão, *recall* e F1 por campo.

As medidas seguem a Seção 2.5. O F1 médio é ponderado pelas ocorrências de cada campo no gabarito.

Recusa.

Na decisão de buscar, tratada como classificação e sem as subespecificadas, o positivo é a consulta fora do domínio, e o previsto positivo é não buscar. Daí saem a precisão, o *recall* e o F1 da recusa, a falsa recusa (não buscar numa consulta do domínio), o acerto nas subespecificadas e a acurácia no domínio, fora das categorias F e E.

Latência e chamadas.

Na v3 e no controle, a latência vai até a decisão final e inclui todas as chamadas, as ferramentas e o validador. Nas duas etapas (simulada), é a soma das duas chamadas quando há busca. O tempo da SQL fica à parte. Uma consulta de aquecimento carrega o modelo antes de cada rodada e fica fora das estatísticas, e as consultas rodam uma a uma, sem concorrência. Reportam-se o mínimo, a mediana, a média, o percentil 95 e o máximo por ambiente, além das chamadas ao modelo por consulta.

Os testes em termos simples.

O intervalo de Wilson dá a faixa plausível de uma proporção e funciona bem com amostras moderadas. O teste de McNemar exato (MCNEMAR, 1947; DIETTERICH, 1998) compara duas configurações nas mesmas consultas e olha só as consultas em que uma acerta e a outra erra. Se elas se dividem de modo desigual demais para ser acaso, a diferença existe. O *bootstrap* pareado sorteia, com reposição, 2.000 novos conjuntos das mesmas consultas e recalcula a diferença em cada um, o que dá o intervalo dela. A correção de Holm ajusta os *p*-valores quando se fazem várias comparações, para que a chance de algum falso positivo no conjunto não cresça.

4.4.4 Reprodutibilidade

Cada rodada registra em manifesto a *tag* e o *digest* do modelo no Ollama, as versões do Ollama e do LangChain, a configuração de inferência, a data de referência, o *hardware*, a revisão do código e os *hashes* SHA-256 do *dataset*, do *prompt* e da definição das ferramentas. A pontuação é sempre recalculada contra o gabarito vigente, de modo que uma correção de gabarito não exige nova execução, e uma consulta cujo texto tenha mudado sai da pontuação, com registro. Os dados, os registros de execução e os *scripts* estão no repositório (Apêndice C).

4.5 Critérios de Decisão sobre o Modelo e a Abordagem

As métricas não são combinadas num escore único, cujos pesos seriam arbitrários. A escolha do modelo e da abordagem segue uma regra com uma métrica principal, um

critério para dizer se uma diferença existe, uma ordem de desempates e o conjunto que decide cada pergunta, dado no Quadro 5. Só parte da regra foi fixada antes das rodadas de teste. O plano de análise da v3 (Seção 4.6.4) já definia a acurácia por consulta como medida da comparação principal, o teste de McNemar exato e o *bootstrap* pareado. O nível de significância, o mesmo em todo o trabalho, e a ordem dos desempates foram escritos depois das rodadas. A Tabela 5 resume o papel de cada medida.

Tabela 5 – Métricas e critérios usados para escolher o modelo e a abordagem

Métrica	O que mede	Papel na decisão	Onde é reportada
Acurácia por consulta, com IC 95% de Wilson	proporção de consultas em que a resposta coincide com uma leitura aceita, inclusive a não busca correta	critério principal	Tabelas 9, 11, 12 e 15
McNemar exato bicaudal, com uma observação por consulta	se a diferença de acurácia entre duas configurações, nas mesmas consultas, excede o que o acaso explica	decide se há diferença ($p < 0,05$) ou empate	Tabelas 13, 15, 27 e 39
Diferença com IC 95% por <i>bootstrap</i> pareado	tamanho da diferença de acurácia e de F1	descreve a magnitude; não decide sozinha	Tabelas 13, 15 e 39
Acurácia no domínio e ponto de equilíbrio	acerto fora das categorias F e E; proporção de consultas fora do domínio em que duas configurações se igualam	confere se a decisão depende da composição do conjunto	Seções 5.3 e 5.4
F1 ponderado dos campos, com precisão e <i>recall</i>	acerto parcial, campo a campo, e o lado do erro (campo a mais ou omitido)	primeiro desempate, pelo valor observado; diagnóstico	Tabelas 9 e 30
Recusa: precisão, <i>recall</i> , F1 e falsa recusa; acerto nas subespecificadas	se a decisão de buscar ou não está certa, e que tipo de erro a configuração comete	segundo desempate, pelo valor observado; custo declarado quando a acurácia decide	Tabelas 11, 12 e 15
Latência mediana e percentil 95	tempo da tradução no ambiente de cada rodada	custo: desempate e restrição do <i>hardware</i> de implantação	Tabelas 15, 26 e 32
Chamadas ao modelo por consulta	custo das configurações com laço (v3)	custo	Tabelas 12 e 15
Parcela do modelo na GPU	se o modelo cabe na VRAM do <i>hardware</i> de implantação	restrição do <i>hardware</i>	Tabela 24

Fonte: Elaborada pelos autores.

A métrica principal.

A busca só está certa se todos os parâmetros estiverem certos. Um campo a mais esconde produtos que atendem ao pedido, um campo a menos traz produtos que não atendem, e um valor errado leva a outro lugar, escala ou período. O F1 daria crédito

parcial a uma busca errada e por isso não decide, mas diz onde a configuração erra. A acurácia cobre também a decisão de buscar. Como ela depende da proporção de consultas fora do domínio, desconhecida no uso real, é reportada também só no domínio, e a recusa é medida à parte, como classificação. Uma decisão vale para outras composições do conjunto quando a vantagem se mantém no domínio. Quando a vantagem no domínio e a da recusa têm sinais contrários, a regra não escolhe e registra o ponto de equilíbrio, a proporção de consultas fora do domínio a partir da qual a ordem se inverte.

Quando uma diferença existe.

Duas configurações são comparadas nas mesmas consultas pelo McNemar exato e bicaudal, com uma observação por consulta (Seção 4.4.3). Há diferença quando o p -valor é menor que 0,05. Do contrário, há **empate**, e a decisão passa ao critério seguinte, ainda que uma configuração tenha acertado mais. Empate não é equivalência demonstrada. Ele diz que a diferença não se distingue do acaso com aquele número de consultas, e diferenças de alguns pontos percentuais podem passar sem ser detectadas. O *bootstrap* pareado mostra quanto uma configuração ganha e que diferenças os dados ainda admitem. A sobreposição de dois intervalos de Wilson não é usada como teste, porque ignora o pareamento. Nas nove comparações do plano do lote 2 (a principal, os quatro degraus e as do *Tool Calling* v3 e do controle com as duas referências), a significância foi conferida também com a correção de Holm, que o plano não previa. As demais não têm correção.

A ordem dos critérios.

Entre configurações empatadas na acurácia, quando o empate não depende da composição do conjunto, a decisão segue esta ordem:

1. o **F1 ponderado dos campos**, que diz qual delas erra menos parâmetros quando erra, com a precisão (campos a mais ou errados) e o *recall* (campos omitidos) para mostrar o lado do erro;
2. o **comportamento de recusa**, com a precisão, o *recall*, a falsa recusa e o acerto nas subespecificadas, porque a falsa recusa nega ao usuário uma busca legítima e a consulta fora do domínio que vira busca lhe devolve resultados sem relação com o pedido;
3. o **custo**, com a latência mediana e o percentil 95 no *hardware* de implantação, as chamadas ao modelo por consulta e a parcela do modelo que cabe na VRAM.

Os desempates comparam valores observados, sem teste. Como o RNF2 não tem limiar fixado *a priori* (Seção 3.2), a latência não elimina uma configuração. Ela desempata

e, quando o *hardware* é a restrição, justifica preferir a mais barata entre as empatadas, com as perdas declaradas. Sem limiar, não há regra que diga quando o *hardware* é a restrição. Esse juízo é dos autores, e por isso a recomendação é dada por cenário de *hardware*. Uma diferença significativa de acurácia não é revertida pelos critérios seguintes, que entram como custo. A acurácia por categoria não decide, mas indica a alternativa quando se sabe que tipo de consulta vai predominar. O plano não compara modelos entre si, e a escolha do modelo com a v3 não passou por teste pareado. Ela é uma observação (Seção 5.7.1).

4.6 Etapas do Estudo

As subseções a seguir descrevem o desenho de cada etapa, na ordem do Quadro 5, e as Seções 5.1 a 5.6 trazem os resultados na mesma ordem.

4.6.1 Escolha do Modelo com a Solução v1

A etapa 1 escolhe o modelo da solução v1 do Capítulo 3. Os quatro modelos locais executaram as 310 consultas com três repetições na T4, e as rodadas da estação e do Groq servem à latência e à referência (Quadro 5). A escolha segue os critérios da Seção 4.5, e o modelo escolhido com *Tool Calling* segue para as etapas 3 e 4.

4.6.2 *Tool Calling* v1, Saída Estruturada e Método do Protótipo

A etapa 2 mede o que rendeu a troca da Saída Estruturada pelo *Tool Calling*, principal mudança em relação ao protótipo, e responde à primeira questão do trabalho (Seção 1.5.2).

Saída Estruturada v1.

O *prompt* de sistema é o da v1, sem as duas instruções sobre chamar ou não a ferramenta, e pede um objeto JSON no formato do *schema* dos parâmetros, incluído no *prompt* com as mesmas descrições e enumerados. O Ollama é usado no modo JSON, e o objeto é validado pela mesma classe Pydantic que valida os argumentos da *tool call*. O modelo não tem como recusar, e toda consulta vira busca, como no protótipo. O *schema* chega como texto no *prompt*, fora do canal de ferramentas. Nos dois modos, os enumerados são informados, mas não impostos. Valores vazios para campos ausentes contam como ausentes, o que favorece a linha de base. A geração restrita ao *schema*, em que o Ollama só deixa o modelo escrever JSON conforme o *schema*, foi testada e descartada, porque os modelos fechavam os intervalos de datas logo depois do primeiro limite, um artefato que penalizaria a linha de base.

Método do protótipo.

Uma segunda linha de base reproduz a solução anterior, portada para Python, com o Phi-4 14B, o dicionário de 159 entradas, o *prompt* original em inglês com dez exemplos resolvidos, o *schema* com campo de justificativa, até três novas tentativas e o *fallback* por expressões regulares. Três diferenças são deliberadas. A temperatura é zero (no protótipo, 0,6), a ordenação padrão que o protótipo acrescenta a toda busca não conta como parâmetro extraído, e os estados e municípios não são validados contra o banco. A saída é traduzida para o vocabulário do trabalho pela correspondência usada no gabarito da camada P.

Execução.

As linhas de base rodaram com uma repetição. No Groq, a Saída Estruturada usou a data de referência e o esforço de raciocínio das rodadas com *Tool Calling*.

4.6.3 Especificação v2 no Lote 1

Os erros mais frequentes da v1 nas 310 contrariavam instruções que o *prompt* já dava ou convenções do manual que a descrição não informava (Seção 5.2). Para separar, num conjunto novo, o efeito da abordagem do efeito da especificação, a etapa 3 avaliou as duas abordagens numa **v2**, que muda só a especificação.

As descrições da v2 explicitam as convenções do manual (quando preencher cada campo, a forma canônica, o que não deduzir), sem os códigos de exemplo da v1 e com a lista das siglas das 27 UFs. No *Tool Calling*, a v2 acrescenta a ferramenta **recusar_consulta** e a instrução de chamar exatamente uma das duas, sem pedir esclarecimento. Na Saída Estruturada, ela usa as mesmas descrições, a mesma proibição e um campo **fora_do_escopo**, que torna a recusa representável. Tipos, enumerados e mecanismos não mudam. Restaram exemplos copiáveis, como “sf22yd” → “SF-22-Y-D” em **keyword**, que é o código da consulta N35 das 310 com o seu gabarito, e “a carta mais recente” → 1 em **limit**. A descrição de **state** trocou a regra com direção da v1 (“RJ” → “Rio de Janeiro”) por uma lista de pares, e os *prompts* perderam a frase que mandava normalizar siglas e grafias sem acento.

O texto que enquadra a recusa difere entre as duas v2. Só o *Tool Calling* é instruído a buscar “mesmo que de forma vaga”, e na Saída Estruturada recusar é responder **fora_do_escopo** “e nada mais”, embora a descrição do campo diga que “consultas vagas sobre o acervo não são fora do escopo”. A comparação entre as duas v2 mede, portanto, o mecanismo junto com esse texto, sobretudo na recusa.

O Gemma 4 E4B, escolhido na etapa 1 (Seção 5.1), executou na T4, com uma repetição, as quatro configurações v1 e v2 no lote 1 e as duas v2 nas 310 (dentro da amostra).

As **duas etapas (simulada)** combinam o *Tool Calling* v2, que decide se busca, com a Saída Estruturada v1, que extrai os parâmetros. A **regra do objeto vazio** conta como não busca a resposta da Saída Estruturada sem nenhum campo. As duas etapas e a regra do objeto vazio são simulações *post hoc* sobre as rodadas, sem chamada nova ao modelo. A regra do objeto vazio foi definida depois de ver os dados, e a latência das duas etapas é uma soma, sem medir cache nem sobreposição.

4.6.4 Especificação v3 e Teste no Lote 2

No lote 1, a Saída Estruturada v2 extraiu melhor os parâmetros, e o *Tool Calling* v2 recusou com mais precisão, numa comparação que mede o mecanismo junto com o texto de recusa (Seção 4.6.3). Os erros do *Tool Calling* v2 foram em boa parte de forma, reversíveis por código (Seção 5.3). A v3 testa o que o *Tool Calling* ganha quando chama funções no meio da resposta e recebe o retorno delas. As peças entram em degraus cumulativos, medidos numa só ordem no lote 2, do *Tool Calling* v1 ao v3, passando pela v2, pelo degrau v3d (descrições corrigidas, ainda numa chamada) e pelo degrau v3a (ferramentas auxiliares e usuário simulado, num laço de chamadas). Cada diferença é o efeito da peça dadas as anteriores.

Descrições corrigidas.

A sigla aparece só como entrada (“MT” → “Mato Grosso”), o limite no singular exige ordenação, o código vai sem prefixo nem sufixo, o município vai por extenso e o tipo de produto exige evidência na consulta.

Ferramentas auxiliares.

Quatro funções determinísticas podem ser chamadas antes da busca. A `identificar_nome` diz se um trecho é UF, município (lista do IBGE), folha do acervo (índice do BDGEx) ou região. A `normalizar_codigo` devolve o código MI ou INOM canônico e diz se ele consta no acervo. A `normalizar_escala` converte a escala para o enumerado do SCN, e a `resolver_periodo` resolve uma expressão de tempo pela tabela do manual. O *prompt* reserva a ferramenta `pedir_esclarecimento` às consultas sem nenhum critério, e quem responde é um **usuário simulado de resposta fixa**, que diz não ter outros detalhes e que a busca pode seguir. Cada consulta tem no máximo seis chamadas ao modelo, três buscas e duas perguntas.

Chamadas escritas como texto.

Nos três degraus do *Tool Calling* v3, inclusive no v3d, de uma chamada, as chamadas que o modelo escreve como texto (sintaxe de função, JSON ou formato nativo do Gemma) são lidas como chamadas. Na v1 e na v2, a mesma resposta conta como não busca. A partir do v3a, uma resposta só em texto recebe uma vez o pedido “Responda chamando uma ferramenta”. Essa leitura e esse pedido fazem parte do sistema medido e precisam acompanhar a v3 numa implantação.

Retorno do validador e recusa contestada.

Antes de executar, a busca confere os parâmetros e devolve ao modelo os erros de forma, que impedem a busca, e avisos de evidência, como campo sem trecho correspondente na consulta. Repetir os mesmos parâmetros depois de um aviso confirma a busca. Se a consulta cita um critério do catálogo (tipo de produto, código, escala, CGEO, projeto, UF ou município), a primeira recusa volta ao modelo com a lista desses critérios, e só a segunda vale. Essa regra contestaria 12 das 336 consultas F do lote 1. Para conferir que o validador não acusa respostas certas, ele foi aplicado à leitura preferencial do gabarito das consultas que admitem busca. A primeira versão acusou 51 das 1.593 do lote 1, e a congelada, 0 das 1.593 no lote 1 e 0 das 298 nas 310.

O que o resultado mede.

As ferramentas e o validador implementam as convenções que definem o gabarito, inclusive a mesma tabela de datas, e o resultado da v3 mede o modelo junto com esse código. Por isso a análise separa da resposta final a **primeira decisão**, que é a primeira busca ou recusa feita antes de qualquer retorno do validador. No *Tool Calling*, a primeira decisão já vem depois das ferramentas auxiliares, e o que o modelo faz só com a especificação aparece no degrau v3d.

Controle e referências.

O controle recebe as mesmas descrições, o mesmo validador e a mesma recusa contestada, aplicados como nova tentativa. Não recebe as ferramentas auxiliares, o usuário simulado, o pedido de resposta por ferramenta, a leitura das chamadas escritas como texto nem a instrução, dada só ao *Tool Calling*, de que lugar desconhecido não justifica recusa. Se ele empatar com a v3, o ganho é das descrições e do validador. Se ficar abaixo, a diferença mede o mecanismo junto com as peças que só o *Tool Calling* v3 tem, sem separá-los. Um controle que desse à Saída Estruturada o retorno das ferramentas auxiliares antes da resposta faria essa separação, e não foi executado. As referências, no lote 2, são a melhor configuração v1 ou v2 isolada e as duas etapas (simulada).

Desenvolvimento, congelamento e plano.

A v3 foi desenvolvida só com as 310 e o lote 1, com o Gemma 4 E4B local, em ciclos registrados sobre uma amostra estratificada de 160 consultas do lote 1, e os números desses ciclos são dentro da amostra. Uma variante com orientações escritas a partir dos erros de desenvolvimento (ZHAO et al., 2024) foi descartada antes do teste, por não ter efeito mensurável. As regras do validador também foram escritas em ciclos sobre os erros dessas consultas, e o risco de sobreajuste continua. É o lote 2 que mede quanto ele pesa. Antes da rodada de teste, a v3 foi congelada pelo *hash* SHA-256 dos *prompts*, das definições e do código e dos dados das ferramentas, sem o restante do pacote, e o caderno do Colab se recusa a rodar com outra versão. O plano de análise, versionado no repositório antes da rodada (Apêndice C), fixou a medida, os testes, a comparação principal, os degraus, as referências e a decomposição entre primeira decisão e resposta final. Qualquer outra análise do lote 2 é exploratória.

Alcance do teste.

Os dois lotes sortearam nomes e códigos das mesmas listas que as ferramentas consultam e exigem na consulta a superfície literal de cada valor, e o teste não mede o alcance das ferramentas fora dessas listas.

4.6.5 Extensão da v3 a Outros Modelos

Depois do teste com o Gemma 4 E4B, uma extensão do plano, também versionada antes das novas rodadas, repetiu no lote 2, com o Gemma 4 E2B e o Qwen 3 4B e a mesma v3 congelada, a comparação principal, o ganho da v3 sobre a v1 e a comparação entre o *Tool Calling* v1 e a Saída Estruturada v1. Essas rodadas têm os mesmos *hashes* de *prompt* e de ferramentas, mas usaram um *commit* posterior do código e o Ollama 0.35.0, contra 0.34.4 nas do Gemma 4 E4B. As latências dos dois grupos vêm, portanto, de versões diferentes do Ollama. O plano não compara modelos entre si (Seção 4.5). As configurações v3 dos três modelos rodaram também nas 62 consultas P e N da estação, para a latência.

4.6.6 Teste A/B entre o Modo A e o Modo B

A etapa 6 reúne num teste A/B as rodadas das duas abordagens feitas nas etapas 1 a 5, para responder se o *Tool Calling* rende mais que a Saída Estruturada.

Os dois modos.

No **Modo A**, o *Tool Calling* nativo, a definição das ferramentas em JSON Schema é ligada ao modelo pelo `bind_tools()` do LangChain. O modelo decide pelo canal de *tool calls* do Ollama ou do Groq se chama cada ferramenta e com quais argumentos, e na v3 a chamada escrita no texto também é lida. No **Modo B**, a Saída Estruturada, o JSON Schema dos mesmos parâmetros vai no *prompt*, e a resposta em modo JSON passa pela mesma classe Pydantic, que valida sem restringir a geração (Seção 4.6.2). Na v2 e na v3, o Modo B é a Saída Estruturada das Seções 4.6.3 e 4.6.4.

Os pares.

Cada par tem o mesmo modelo, as mesmas consultas, a mesma especificação e o mesmo ambiente. São 24 pares, 19 deles fora dos conjuntos de desenvolvimento e os demais dentro da amostra.

Ganho em acurácia.

É a diferença de acurácia por consulta, com o intervalo de 95% do *bootstrap* pareado, e o McNemar decide se ela existe (Seção 4.5). Nas 310, cada consulta vale pela maioria das três repetições, e por isso a acurácia do *Tool Calling* v1 na Tabela 15 difere ligeiramente da Tabela 10, que usa a média das execuções. As diferenças são Saída Estruturada menos *Tool Calling*, e valor negativo é vantagem do Modo A.

Ganho em tempo de processamento.

É medido pela latência mediana, pelo percentil 95 e pelas chamadas ao modelo por consulta, com a regra de comparabilidade da Seção 4.4.1. O Groq, cujo *hardware* não é controlado, fica de fora.

4.7 Confiabilidade da Avaliação

As métricas só valem se o gabarito estiver certo, se as consultas se parecerem com as que o sistema vai receber e se nem o gabarito nem a estatística favorecerem uma configuração por construção. As Tabelas 6 e 7 listam as ameaças a cada condição, o tratamento dado e o que fica como limitação.

O gabarito.

Ele segue regras escritas, aplicadas do mesmo modo a todas as configurações (Seções 4.3.2 e 4.3.3). As regras são dos autores e fixam convenções que outra equipe poderia

fixar de outro modo, como “última atualização” para a data de criação. A acurácia mede a conformidade a elas. Cada adjudicação partiu de uma divergência da anotação independente ou das checagens. Nenhuma partiu da resposta de um modelo avaliado, e toda correção repontua todas as rodadas (Seção 4.4.4).

Os lotes.

No lote final, a compatibilidade com a anotação do filtro é total por construção, porque o filtro descarta as consultas divergentes. A medida livre desse viés é a segunda anotação, feita fora do filtro. Ela foi compatível com o gabarito em 100,0% das 383 consultas da amostra que entraram no lote 1 e em 100,0% das 191 que entraram no lote 2. Nenhuma pessoa conferiu os lotes.

As consultas.

Todas as consultas são sintéticas, porque não há registro disponível de consultas reais de usuários do BDGEx. A distribuição das formulações é a que os redatores produzem, e a proporção real de consultas fora do domínio é desconhecida. Os resultados valem para consultas como essas.

Os erros e o viés de modelo.

Uma auditoria sorteou 160 execuções erradas do lote 1, 40 por configuração e estratificadas por família, e um único agente Claude as julgou pelo manual, sem conferência humana (resultado na Seção 5.3). Os erros do lote 2 tiveram só uma leitura exploratória. Modelos de uma só família, o Claude (Opus 5.5 e Fable 5.1), anotaram as 310, redigiram e anotaram os lotes e julgaram os erros. Essa família não está entre as avaliadas, o que evita que um modelo seja julgado por outro da mesma família, mas não que o modo de ler desses modelos se pareça mais com o de algum avaliado.

As limitações voltam na Seção 6.3.

Tabela 6 – Ameaças à validade do gabarito e das consultas, com o tratamento e as limitações

Ameaça à validade	Como foi tratada	O que fica como limitação
Gabarito errado ou com a preferência do anotador	manual escrito antes da anotação; leituras múltiplas explícitas; auditoria em três passos nas 310; nos lotes, gabarito por construção, anotação às cegas e filtro	a anotação independente das 310 foi feita por um modelo, e não por uma pessoa; a conferência humana cobriu 40 das 310 consultas e nenhuma dos lotes
Convenções do manual escolhidas pelos autores	manual publicado, com regras para cada campo (Apêndice A.1); convenções explicitadas nas especificações v2 e v3; sensibilidade às convenções que a v1 não informa	a acurácia mede a conformidade a essas convenções; outro manual daria outros números, e a v1 é penalizada por convenções que não lhe foram dadas
Gabarito ajustado às respostas dos modelos	gabarito definido pelo manual e pelo texto; adjudicações vindas da anotação independente e das checagens, com o gabarito anterior registrado; toda correção repontua todas as rodadas	parte das rodadas é anterior à adjudicação; a garantia é o registro de cada decisão, que pode ser revisto
Consultas regulares demais (camada G)	três camadas; acurácia por camada; lotes redigidos em oito registros de linguagem, com personas	a camada G é a maior parte das 310, e as métricas agregadas podem superestimar o desempenho
Consultas sintéticas, que podem não representar o uso real	valores de catálogos reais; redação controlada, com registros e personas sorteados, checagens automáticas e deduplicação	nenhuma consulta foi coletada de usuários; a distribuição das formulações é a que os redatores produzem
Um só modelo para anotar, redigir e julgar	redação e anotação em sessões independentes, sem acesso ao gabarito; segunda anotação fora do filtro; modelos avaliados de outras famílias	o anotador das 310, os redatores e anotadores dos lotes e o juiz dos erros são modelos da mesma família, também usada no desenvolvimento; leituras próprias dele passam pela auditoria e pelo filtro
Filtro que remove as consultas difíceis	descartes relatados por motivo; a segunda anotação mede o gabarito que ficou	os lotes medem consultas de gabarito defensável, não toda a variedade possível
Data de referência fixa	regras de tempo nomeadas, resolvidas na data de cada rodada, que o <i>prompt</i> informa ao modelo; resolução conferida em datas diversas, com anos bissextos e viradas de ano	cada rodada usou uma só data; o comportamento dos modelos em outras datas, como numa virada de mês ou de ano, não foi medido

Fonte: Elaborada pelos autores.

Tabela 7 – Ameaças à validade das comparações e das medidas, com o tratamento e as limitações

Ameaça à validade	Como foi tratada	O que fica como limitação
Comparação estrita que conta respostas inócuas como erro	leituras aceitas explícitas; auditoria das execuções erradas do lote 1; comparação das SQL	um único juiz, sem conferência humana; os erros do lote 2 não tiveram auditoria equivalente
Sobreajuste da especificação às consultas de desenvolvimento	teste em conjunto não lido; congelamento por <i>hash</i> ; checagem de contaminação; números de desenvolvimento marcados	o lote 2 segue a receita do lote 1: mede consultas novas, não outra distribuição de consultas
Análises e critérios escolhidos depois de ver os dados	plano versionado antes das rodadas, com a métrica, o teste e as comparações; análises fora do plano marcadas como exploratórias	o nível de significância e a ordem dos desempates não estavam no plano; as duas etapas e a regra do objeto vazio são simulações <i>post hoc</i>
Significância exagerada	uma observação por consulta; McNemar exato; correção de Holm nas nove comparações do plano do lote 2	comparações fora do plano e por subgrupo sem correção; empate não demonstra equivalência
Vencedor decidido pela composição do conjunto	acurácia no domínio e recusa reportadas à parte; ponto de equilíbrio	as proporções de F e E nos lotes são de desenho, e a real é desconhecida; em E, qualquer não busca conta como acerto
Acerto da v3 que é do código do domínio	controle com as mesmas descrições e o mesmo validador; degraus; primeira decisão $\times$ resposta final	o código codifica o manual, inclusive a tabela de datas do gabarito, e o resultado mede o modelo com ele; alcance fora das listas sorteadas não medido; usuário simulado de resposta fixa
Especificação desenvolvida com um só modelo	extensão do teste ao Gemma 4 E2B e ao Qwen 3 4B, fixada antes das rodadas, com a mesma v3 congelada	a v3 pode favorecer o Gemma 4 E4B; o plano não compara modelos, e a escolha do modelo com a v3 não passou por teste
Variação entre execuções	temperatura zero; três repetições nas 310, com a estabilidade medida; reexecução na estação	uma repetição por configuração nos lotes; as repetições de uma sessão não medem a variação entre sessões, maior na estação
Versões de <i>software</i> diferentes entre rodadas	manifesto com a <i>tag</i> , as versões e os <i>hashes</i> do <i>prompt</i> e das ferramentas; no teste A/B, latência só entre rodadas com a mesma GPU, a mesma versão do Ollama e a mesma parcela do modelo na GPU	a extensão do lote 2 usou outra versão do Ollama e outro <i>commit</i> ; a leitura das chamadas escritas como texto depende dessa versão
Qualidade e latência dependentes do ambiente	qualidade medida na T4 e conferida na estação; latência por ambiente; manifesto com a VRAM livre e a parcela do modelo na GPU	na estação, conferência e latência num subconjunto das consultas; latência sensível à ocupação da GPU

Fonte: Elaborada pelos autores.

4.8 Uso de Ferramentas de Inteligência Artificial

Os modelos de linguagem avaliados (Seção 4.2) são o objeto do estudo. Além deles, ferramentas de inteligência artificial apoiaram os processos metodológicos listados na Tabela 8, com a ferramenta, a finalidade e a forma de controle do resultado. Em nenhum desses processos a ferramenta definiu o gabarito. Nas 310 consultas, ele foi definido pelos autores segundo o manual de anotação, e a anotação por modelo serviu para medir a concordância e apontar divergências, adjudicadas pelos autores. Nos lotes, o gabarito foi fixado por construção, antes da redação, a partir de catálogos reais sorteados por código. A dependência de uma só família de modelos de linguagem para redigir, anotar e julgar é uma limitação registrada (Seção 4.7). Os números de resultado do texto são inseridos por código a partir dos registros de execução, e os da auditoria das 310 consultas vêm das tabelas geradas pela ferramenta de auditoria.

Tabela 8 – Ferramentas de inteligência artificial empregadas como apoio nos processos metodológicos

Processo	Ferramenta	Finalidade	Controle do resultado
Desenvolvimento do <i>software</i> (<i>backend</i> , <i>pipeline</i> de avaliação, especificações v2 e v3)	Claude Code, com os modelos Claude Opus 4.6 e Claude Opus 5.5 (Anthropic)	apoio à escrita e à depuração de parte do código e dos testes, a partir da especificação dos autores, que implementaram muitas partes do sistema	testes automatizados, revisão pelos autores, manifestos de cada rodada e repositório público
Anotação independente das 310 consultas (Seção 4.3.3)	agentes Claude	segunda anotação, às cegas, só com o manual e a definição da ferramenta	concordância medida contra o gabarito; divergências adjudicadas pelos autores; revisão humana de uma amostra
Redação e anotação das consultas do lote 1 (validação) e do lote 2 (teste) (Seção 4.3.4)	agentes Claude	redigir consultas a partir de alvos com gabarito fixado antes; anotá-las às cegas	checagens automáticas, anotação às cegas com filtro de compatibilidade e segunda anotação de uma amostra
Auditoria e análise dos erros das rodadas	agentes Claude	julgar uma amostra das execuções erradas (um único agente) e classificar os erros e propor causas, com as análises verificadas por outros agentes	todos os números recalculados por código; causas não testadas registradas como hipóteses

Fonte: Elaborada pelos autores. Os agentes Claude usaram os modelos Claude Opus 5.5 e Claude Fable 5.1 (Anthropic).

5 RESULTADOS

Os resultados seguem as seis etapas do Quadro 5, nos ambientes da Seção 4.4.1. Numa só chamada, a Saída Estruturada extraiu melhor os parâmetros nos modelos locais, e o *Tool Calling* recusou melhor as consultas fora do domínio. Com a v3, o *Tool Calling* superou o controle no lote 2 (teste) com os dois Gemma 4, mas não com o Qwen 3 4B. Todas as rodadas foram pontuadas contra o gabarito final. As dos dois GPT-OSS, anteriores à adjudicação, foram repontuadas (Seção 4.4.4). Nenhuma execução das rodadas completas terminou em erro de infraestrutura. Os registros de execução, os manifestos e os relatórios de cada rodada estão no repositório (Apêndice C).

5.1 Escolha do Modelo com a Solução v1

Os quatro modelos locais executaram as 310 consultas com a solução v1, em três repetições na T4 (Seção 4.6.1). A Tabela 9 resume as métricas.

Tabela 9 – Comparativo de desempenho entre os modelos avaliados

Modelo	Acurácia	IC 95%	Precisão	Recall	F1	Lat. med. (ms)
Qwen 3 4B	54,2%	48,6%–59,7%	0,697	0,743	0,666	828
Gemma 4 E4B	60,2%	54,7%–65,6%	0,853	0,763	0,793	725
Gemma 4 E2B	56,5%	50,9%–62,0%	0,821	0,760	0,765	397
Mistral Nemo 12B	26,8%	22,1%–32,0%	0,804	0,326	0,451	2391

Fonte: Elaborado pelos autores. IC 95%: intervalo de confiança de Wilson para a acurácia, com n igual ao número de consultas, pois as repetições de uma mesma consulta não são independentes. Precisão, *recall* e F1 ponderados pela frequência de cada campo no gabarito. Latência mediana da chamada de tradução, no ambiente de cada rodada.

Três modelos ficaram no mesmo patamar. O Gemma 4 E4B acertou 60,2% das consultas, o Gemma 4 E2B, 56,5%, e o Qwen 3 4B, 54,2%. Pelo teste de McNemar, com uma observação por consulta, nenhuma diferença entre os três é significativa (Tabela 27, Apêndice D.1). O Mistral Nemo 12B, o maior dos quatro, ficou em 26,8%, com diferença significativa para cada um dos outros três. Entre os modelos locais, o porte não ordenou o desempenho. Boa parte da queda do Mistral Nemo vem de um modo de falha no uso da ferramenta (Seção 5.1.2), mas ele ficou abaixo dos outros três também com a Saída Estruturada (Tabela 10).

O Gemma 4 E4B teve o maior F1 ponderado (0,793), a maior precisão e o maior *recall* dos três. O Qwen 3 4B teve a menor precisão (0,697), porque acrescenta campos que a consulta não pediu. Na T4, o Gemma 4 E2B foi o mais rápido, com mediana de 0,4 s, e o Mistral Nemo 12B o mais lento, com 2,4 s (Tabela 26 e Figura 6, Apêndice D.1).

As três repetições deram a mesma resposta em 287 a 306 das 306 consultas, conforme o modelo. Pelo desempate do F1 (Seção 4.5), o Gemma 4 E4B seguiu para as etapas 3 e 4.

5.1.1 Categorias, Camadas e Campos

As consultas simples e as com código MI ou INOM foram as mais fáceis para os três modelos do patamar superior. As compostas, as de tempo relativo e as de ordenação foram as mais difíceis. Nas compostas, que exigem vários campos certos ao mesmo tempo, nenhum modelo passou de 53,1%. Resolver uma expressão temporal em datas e decidir se, e por qual data, ordenar são os passos que mais dependem de raciocínio além do reconhecimento de nomes.

Na categoria F, o Qwen 3 4B, o Gemma 4 E4B e o Mistral Nemo 12B recusaram as oito consultas fora do domínio. No Mistral Nemo, que também deixou de chamar a ferramenta na maior parte das consultas legítimas, esse acerto é pouco informativo. O Gemma 4 E2B buscou em três delas, com “Marte” como **keyword** em “cartas de Marte”, “Argentina” como **state** em “cartas da Argentina” e a própria frase como **keyword** em “mapa do tesouro pirata”.

Por camada, as consultas do protótipo (camada P), mais longas e com mais campos, foram as mais difíceis. Por campo, os de período e de ordenação concentraram as perdas de F1. O campo **supplyArea** teve F1 alto nos três modelos, embora a normalização dos nomes, que o dicionário do protótipo fazia, tenha ficado a cargo do modelo, a partir das descrições da ferramenta. A Figura 7 e as Tabelas 28, 29 e 30 (Apêndice D.1) trazem os valores.

5.1.2 Modos de Falha

Cada modelo teve um modo de falha dominante, segundo a classificação da Seção 4.4.3.

Mistral Nemo 12B.

O modelo deixou de chamar a ferramenta em 561 das 918 execuções pontuadas. Em 357 delas, a resposta cita **buscar_catalogo** e descreve em texto a chamada que faria. Para “preciso da carta MI 2965-2-NE do segundo cgeo”, respondeu que chamaria a ferramenta com **keyword** “2965-2-NE” e **supplyArea** “2° Centro de Geoinformação”, sem emitir a chamada. A v1 e a v2 contam essa resposta como falha, e a v3 passa a lê-la como chamada (Seção 4.6.4).

Gemma 4 E4B e E2B.

Os dois pediram esclarecimento em vez de buscar em 139 e 72 execuções, respectivamente, contadas por uma lista de expressões de pedido na resposta. Isso ocorreu sobretudo em consultas amplas, com um só critério, como “cartas topográficas” e “ortoimagens disponíveis”. O E4B pediu também a data em consultas de tempo relativo, embora a data de referência estivesse no *prompt* (“ortoimagens de 2 anos atrás”). O E2B copiou para **keyword** palavras comuns da consulta, como “mdt” em “mdt do para em 25k”.

Qwen 3 4B.

O modelo chamou a ferramenta com mais regularidade, mas declarou fora do escopo consultas legítimas em 27 execuções, como “ultima atualizacao do para”. Seu erro mais frequente foi acrescentar ordenação e limite não pedidos. Para “todas as cartas em escala maior que 100k do rio grande do sul”, ordenou por data de publicação, limitou a 100 resultados e omitiu a escala.

Datas relativas.

Os erros de período seguem três padrões comuns aos modelos. Eles tratam “esse ano” como começando na data de referência, e não em 1º de janeiro, reduzem “2 anos atrás” a um único dia e trocam o trimestre-calendário por três meses corridos.

A chamada descrita em texto é uma limitação da integração do modelo com o canal de ferramentas. O pedido de esclarecimento e a recusa indevida dependem da redação do *prompt*. Os erros de período e de ordenação são de raciocínio sobre a consulta. Nenhum modelo produziu argumento com campo inexistente ou tipo inválido.

Nas quatro consultas observacionais, só o Qwen 3 4B chamou a ferramenta nas duas com valor impossível, e com valores substituídos (a escala 1:10.000 para “escala 1:10.000.000” e o estado “Rio Grande do Sul” para “cartas do estado 42”). Nas duas de resposta discutível, os modelos em geral não buscaram.

5.1.3 Estação de Referência

O Qwen 3 4B e o Gemma 4 E2B executaram as 62 consultas P e N na estação, com parte de cada modelo na CPU (Seção 4.4.1). Os dois tiveram acurácias estatisticamente indistinguíveis (49,2% e 47,5%, Tabela 33). A latência os separou. As medianas foram de 2,6 s no Qwen 3 4B e de 0,7 s no Gemma 4 E2B, cerca de 3,7 vezes mais rápido, com respostas mais curtas e apesar da menor parcela na GPU.

Nos dois modelos, a pontuação coincidiu com a da primeira repetição na T4 em 57 das 59 consultas pontuadas. A qualidade praticamente não mudou com o *hardware*, e a latência mudou. Uma segunda execução do Qwen 3 4B na mesma estação, com os mesmos pesos, *prompt*, data de referência e versão do Ollama, repetiu a resposta em 51 das 59 consultas. O manifesto da primeira execução não registra a parcela do modelo na GPU, que pode ter diferido entre as duas. A variação entre sessões, com parte do modelo na CPU, é maior que entre as repetições de uma sessão na T4, e as três repetições das rodadas completas não a capturam. Por isso as diferenças entre modelos se leem pelos intervalos de confiança e pelo McNemar. As Tabelas 31, 32, 35 e 36 estão no Apêndice D.2.

5.1.4 Referência em Nuvem

Os três modelos servidos pelo Groq acertaram mais que os locais nas mesmas consultas. O Qwen 3.8 27B acertou 95,1%, o GPT-OSS 120B 89,9% e o GPT-OSS 20B 89,2%, contra 60,2% do Gemma 4 E4B. O Qwen 3.8 27B, avaliado sem raciocínio como os modelos locais, superou os dois GPT-OSS com diferença significativa. A distância para os modelos locais é maior nas consultas compostas e nas de tempo relativo. A tarefa e o gabarito têm solução com modelos maiores. Servidos pelo Groq, eles não atendem ao RNF1, que exige execução local, e ficam fora da recomendação. Estes dados não separam o efeito do porte do efeito da geração e do ajuste de cada modelo, e não se mediu quanto o raciocínio reduziria a distância nos modelos locais. A latência inclui a rede e não se compara à dos modelos locais. As Tabelas 37 e 38 estão no Apêndice D.3.

5.2 *Tool Calling* v1, Saída Estruturada e Método do Protótipo

As 310 consultas foram executadas também com a Saída Estruturada, nos mesmos modelos, e com o método do protótipo (Seção 4.6.2). A Tabela 10 resume a comparação.

Tabela 10 – Tool Calling e Saída Estruturada sobre as mesmas consultas

Modelo	Parâm.	Abordagem	Acurácia	Sem F	F1	Recusa F	Campo a mais	<i>p</i>	<i>p</i> sem F
Gemma 4 E2B	2B ef.	Tool Calling Saída Estruturada	56,5% 53,9%	56,4% 55,4%	0,765 0,792	62,5% 0,0%	17,1% 26,8%	0,488	0,839
Qwen 3 4B	4B	Tool Calling Saída Estruturada	54,2% 60,1%	53,0% 61,7%	0,666 0,808	100,0% 0,0%	37,6% 27,2%	0,038	0,001
Gemma 4 E4B	4B ef.	Tool Calling Saída Estruturada	60,2% 75,2%	59,2% 77,2%	0,793 0,902	100,0% 0,0%	10,3% 6,7%	< 0,001	< 0,001
Mistral Nemo 12B	12B	Tool Calling Saída Estruturada	26,8% 52,0%	24,8% 53,4%	0,451 0,727	100,0% 0,0%	7,4% 8,7%	< 0,001	< 0,001
GPT-OSS 20B (Groq)	21B (MoE)	Tool Calling Saída Estruturada	89,2% 77,5%	88,9% 79,5%	0,946 0,919	100,0% 0,0%	2,3% 4,7%	< 0,001	< 0,001
Qwen 3.8 27B (Groq)	27B	Tool Calling Saída Estruturada	95,1% 92,8%	95,3% 95,3%	0,984 0,979	87,5% 0,0%	2,0% 1,7%	0,143	1,000
GPT-OSS 120B (Groq)	117B (MoE)	Tool Calling Saída Estruturada	89,9% 87,3%	89,6% 89,6%	0,956 0,964	100,0% 0,0%	4,0% 3,0%	0,268	1,000
Phi-4 14B	14B	Método do protótipo	58,8%	60,4%	0,856	0,0%	28,2%	—	—

Fonte: Elaborado pelos autores. Sem F: acurácia nas consultas das métricas principais fora da categoria F. Recusa F: proporção das execuções da categoria F sem busca; na Saída Estruturada a aplicação sempre busca. Campo a mais: proporção das execuções fora da categoria F com algum campo ausente do gabarito. *p*: teste de McNemar exato entre as duas abordagens do mesmo modelo, com uma observação por consulta (maioria das repetições). Parâm.: parâmetros (ef.: efetivos; MoE: mistura de especialistas, com parte dos parâmetros ativa a cada *token*). Modelos locais e método do protótipo: GPU T4, *Tool Calling* com três repetições e linhas de base com uma, data de referência de 14/09/2026. Modelos (Groq): execução em nuvem, uma repetição, data de referência de 24/09/2026.

Modelos locais.

A Saída Estruturada acertou mais que o *Tool Calling* em três dos quatro modelos locais, com diferença significativa (75,2% contra 60,2% no Gemma 4 E4B). No Gemma 4 E2B, as duas empataram. A vantagem vem em boa parte da liberdade de não buscar que o *Tool Calling* dá ao modelo. Das 62 consultas que só a Saída Estruturada acertou no Gemma 4 E4B, em 32 o modelo com *Tool Calling* não buscou, quase sempre por pedir esclarecimento. No Qwen 3 4B, que quase sempre busca, a vantagem veio da extração, com menos campos acrescentados.

Modelos de maior porte.

No GPT-OSS 20B, o *Tool Calling* foi melhor (89,2% contra 77,5%), também sem as consultas fora do domínio. Com Saída Estruturada, esse modelo omitiu parâmetros que a consulta trazia, e “produtos na escala 1:1000” resultou num objeto vazio. Também acrescentou o estado a partir do município (`state` “Bahia” em “cartas de Salvador”). É o preenchimento para completar a estrutura que a hipótese da Seção 2.2.1 previa. No GPT-OSS 120B e no Qwen 3.8 27B, as duas abordagens empataram fora da categoria F.

A recusa.

Com *Tool Calling*, os modelos não buscaram em nenhuma das oito consultas fora do domínio, salvo o Gemma 4 E2B e o Qwen 3.8 27B, que recusaram 62,5% e 87,5% delas. Com Saída Estruturada, a aplicação buscaria em todas. Os modelos devolveram um objeto vazio em parte delas, mas a aplicação do protótipo busca a partir de qualquer objeto. A Seção 5.3 mede uma regra que trata a resposta vazia como recusa.

O porte.

Nos modelos maiores, o *Tool Calling* não passou a extrair melhor de modo regular. O resultado parece depender de como cada modelo foi ajustado para chamar ferramentas e para responder em JSON.

O método do protótipo.

O método do protótipo acertou 58,8% (IC 95% de 53,2% a 64,2%), acurácia estatisticamente indistinguível da dos três melhores modelos locais com *Tool Calling* (p -valor de 0,805, 0,614 e 0,206 contra o Gemma 4 E4B, o Gemma 4 E2B e o Qwen 3 4B), com F1 de 0,856. Ele usou um modelo de 14 bilhões de parâmetros, com mediana de 12,6 s por consulta na T4, contra 0,4 s a 0,8 s desses três modelos com *Tool Calling*. Em 295 das 306 consultas, a primeira resposta, quase vazia, foi rejeitada pela validação do *schema* e

exigiu nova tentativa. O dicionário alterou o texto de 68 consultas antes de chegarem ao modelo, e o *fallback* por expressões regulares agiu em 10.

A solução v1 chegou, assim, a uma acurácia indistinguível com modelos de 2 a 4 bilhões de parâmetros efetivos, mais de quinze vezes mais rápidos, sem dicionário nem exemplos e capazes de recusar o que o catálogo não atende. A redução de porte e de tempo veio da troca de modelo, e não do *Tool Calling*. O *Tool Calling* de uma chamada não acrescentou acurácia, e com a Saída Estruturada três dos quatro modelos acertaram mais. Toda falha passou a ser registrada e classificada, o que revelou o modo de falha de cada modelo, inclusive o do Mistral Nemo 12B, que um *fallback* teria mascarado. O método do protótipo não foi executado nos lotes. A única comparação da v3 com ele, nas 310, está na Seção 5.4. Na estação, nas 62 consultas P e N, nenhuma diferença entre as abordagens foi significativa, como se espera de uma amostra menor (Tabela 34, Apêndice D.2).

Da v1 à v2.

Nas 310, o *Tool Calling* do Gemma 4 E4B não buscou numa consulta do domínio em 17,5% das execuções, quase sempre para pedir esclarecimento, embora o *prompt* diga que um único parâmetro basta. Também acrescentou o tipo de produto a “cartas” e alterou códigos pelo exemplo da descrição (“2901” virou “2901-2-NE”). A descrição v1 não informava convenções do gabarito, como “última atualização” indicar a data de criação. Esses erros e a necessidade de confirmar a comparação num conjunto maior e novo levaram à especificação v2 e ao lote 1 (validação), descritos nas Seções 4.3.4 e 4.6.3.

5.3 Especificação v2 no Lote 1

O Gemma 4 E4B executou as quatro configurações v1 e v2 no lote 1, que o desenho da v2 não viu (Seção 4.6.3). A Tabela 11 resume o resultado, e a Tabela 39 traz as comparações pareadas (Apêndice D.4).

Tabela 11 – Especificações v1 e v2 com o Gemma 4 E4B no lote de validação e nas 310 consultas

Conjunto	Configuração	Acurácia	IC 95%	F1	Recusa F	Falsa recusa	F1 recusa	Múltiplas leituras
Lote de validação (n=1929)	Tool Calling v1	61,5%	59,3%–63,6%	0,761	100,0%	32,1%	0,592	34,6%
	Saída Estruturada v1	62,2%	60,0%–64,3%	0,892	0,0%	0,0%	0,000	72,0%
	Tool Calling v2	62,8%	60,7%–65,0%	0,840	99,7%	0,9%	0,980	46,5%
	Saída Estruturada v2	72,4%	70,4%–74,4%	0,860	100,0%	17,8%	0,723	61,1%
310 consultas (n=306)	Tool Calling v1	60,1%	54,6%–65,5%	0,793	100,0%	18,8%	0,222	26,9%
	Saída Estruturada v1	75,2%	70,0%–79,7%	0,902	0,0%	0,0%	0,000	52,2%
	Tool Calling v2	47,4%	41,9%–53,0%	0,796	100,0%	0,0%	1,000	40,3%
	Saída Estruturada v2	68,0%	62,6%–73,0%	0,859	100,0%	14,4%	0,271	53,7%

Fonte: Elaborado pelos autores. Gemma 4 E4B, GPU T4. Acurácia por consulta, com IC de Wilson. Recusa F: proporção das consultas fora do domínio sem busca (recall da recusa). Falsa recusa: proporção das consultas do domínio (fora das categorias F e E) sem busca. F1 recusa: média harmônica da precisão e do recall da recusa. Múltiplas leituras: acurácia nas consultas do domínio com mais de uma leitura aceita. Na v1, a Saída Estruturada não tem como recusar. A v2 foi desenhada a partir dos erros nas 310 consultas: nesse conjunto, o resultado da v2 é de dentro da amostra e, mesmo assim, ficou abaixo do da v1 nas duas abordagens.

O empate da v1.

Com a v1, as duas abordagens empataram, com 61,5% no *Tool Calling* e 62,2% na Saída Estruturada (p -valor de 0,656). O empate esconde duas diferenças de sinal contrário. No domínio, a Saída Estruturada acertou 75,5%, e o *Tool Calling*, 48,9%. Fora dele, o *Tool Calling* recusou 100,0% das consultas, e a Saída Estruturada nenhuma. A acurácia geral é uma média das duas partes, ponderada pela proporção de consultas fora do domínio. As abordagens se igualam quando essa proporção vale 18,0% no lote (IC 95% de 16,3% a 19,8%) e 15,3% nas 310. O lote tem 17,4% de consultas fora do domínio, perto desse ponto, e por isso as abordagens empataram. As 310 têm 2,6%, e por isso a Saída Estruturada venceu na Seção 5.2. Com a v1, o *Tool Calling* só acerta mais se mais de 18,0% das consultas reais estiverem fora do catálogo. Se a aplicação tratasse como não busca a resposta sem nenhum campo do *schema*, esse ponto subiria a 51,0% no lote.

A falsa recusa.

No domínio, o *Tool Calling* v1 deixou de buscar em 32,1% das consultas, quase sempre para pedir esclarecimento. Algumas respostas afirmam ao usuário, sem ter buscado, que o acervo não tem o produto. A falsa recusa é maior nas consultas com um só campo (44,5%) e menor nas com quatro ou mais (12,0%). As 310, de consultas mais curtas e diretas, a subestimam (18,8%). A falsa recusa explica 82,3% da diferença entre as abordagens no domínio, e o resto é extração. Na categoria E, a regra de pontuação aceita a não busca (Seção 4.3.4). Contadas como erro as não buscas nas subespecificadas, a acurácia do *Tool Calling* v1 cairia a 54,1%.

A v2 no *Tool Calling*.

Com a v2, a falsa recusa do *Tool Calling* caiu para 0,9%. A acurácia quase não mudou (62,8%; p -valor de 0,277 contra a v1), porque o ganho de buscar onde a v1 não buscava se perdeu em erros de forma. Nas consultas em que as duas versões buscaram, a acurácia caiu de 71,7% para 55,7%. A lista de siglas das UFs, posta na descrição de **state** para evitar confusões, virou formato de saída, e o *Tool Calling* v2 escreveu a sigla em 41,4% das execuções com estado. A regra do singular (“a carta mais recente” → 1) virou **limit** em plurais. A instrução de copiar o código “exatamente como aparece” manteve o prefixo “MI” na **keyword**. Essas causas são hipóteses, porque nenhuma frase da v2 foi retirada para testá-las. Os erros são de forma e reversíveis sem o gabarito. Três normalizações determinísticas (a sigla trocada pelo nome da UF, o prefixo retirado e a **keyword** genérica descartada) levariam o *Tool Calling* v2 a 72,5% e a Saída Estruturada v2 a 76,3%. Nenhuma configuração com essas normalizações foi executada, e os dois valores servem só de diagnóstico.

Nas 310, dentro da amostra, a v2 piorou as duas abordagens. O *Tool Calling* foi de 60,1% para 47,4%, com cada consulta contada pela maioria das três repetições da v1 (Seção 4.4.3). Os erros de forma atingem as construções mais frequentes da camada G, com o nome da UF ou o código MI. Acrescentar instruções a um modelo pequeno não teve efeito monotônico. As regras novas consertaram os erros que as motivaram, e algumas criaram outros. Só o lote 1, que o desenho da v2 não viu, mediu o saldo.

Especificação e mecanismo.

As duas v2 diferem no texto que enquadra a recusa, e a comparação entre elas mede o mecanismo junto com esse texto (Seção 4.6.3). Com o Gemma 4 E4B, a recusa foi melhor no *Tool Calling*. A ferramenta `recusar_consulta` teve precisão de 96,3%, contra 56,7% do campo `fora_do_escopo`. A Saída Estruturada v2 marcou esse campo em 17,8% das consultas do domínio e em todas as subespecificadas. Contadas estas como erro, sua acurácia cairia a 64,9%. A extração foi melhor na Saída Estruturada. Nas consultas do domínio em que as duas buscaram, ela acertou 77,0%, contra 55,8% do *Tool Calling*. Os erros de forma aparecem nas duas abordagens e vêm da especificação, mas o *Tool Calling* os amplificou. Nas consultas com estado em que as duas buscaram, a sigla da UF apareceu em 34,9% das respostas do *Tool Calling* e em 21,0% das da Saída Estruturada. O tipo de produto acrescentado a “cartas” vem do mecanismo. Já na v1, com o mesmo texto nas duas abordagens, o *Tool Calling* o acrescentou em 13,1% das buscas sem tipo no gabarito, contra 0,6% da Saída Estruturada. O canal de ferramentas em si funcionou, e só 13 das 1.929 respostas do *Tool Calling* v2 trouxeram a chamada escrita no texto.

Duas etapas (simulada).

Como o *Tool Calling* recusou melhor e a Saída Estruturada extraiu melhor, o *Tool Calling* v2 pode decidir se busca e, quando busca, a Saída Estruturada v1 pode extrair os parâmetros. Essa combinação, simulada *post hoc* sobre as rodadas (Seção 4.6.3), acertou 79,5% no lote, contra 72,4% da melhor configuração executada, a Saída Estruturada v2 (p -valor $< 0,001$). Nas 310, acertou 77,8%. Ela supera a Saída Estruturada v1 a partir de 0,1% de consultas fora do domínio, e a escolha deixa de depender dessa proporção. O custo é a segunda chamada sempre que há busca, com mediana somada de 1,46 s. A regra do objeto vazio, também simulada, levaria a Saída Estruturada v1 a 75,9%, sem mensagem de recusa ao usuário (Tabela 40, Apêndice D.4).

Auditoria dos erros.

Das 160 execuções erradas do lote 1 que a auditoria sorteou e um agente Claude julgou, sem conferência humana (Seção 4.7), 155 (96,9%; IC 95% de 92,9% a 98,7%) eram

erros reais do modelo, 5 tinham gabarito discutível, e nenhuma tinha gabarito contrário ao manual. Conforme o critério, os discutíveis vão de 3 a 6. No máximo 5,2% das respostas erradas, conforme a configuração, dariam a mesma SQL de uma leitura aceita. Os erros de forma da v2 não são inócuos. Pela busca por *substring*, a sigla “AM” casa Amazonas, Amapá e Pernambuco, e as buscas erradas com o prefixo “MI” não encontram a folha pedida.

O viés que fica penaliza a v1. No lote, 154 consultas dependem de convenções do manual que a descrição v1 não informa, e essas convenções penalizam mais as duas v1. Aceita nelas a leitura natural, a vantagem do *Tool Calling* v2 sobre o v1 cairia de +1,3 para +0,6 p.p., e a Saída Estruturada v1 passaria o *Tool Calling* v2.

Da v2 à v3.

Os erros de forma do *Tool Calling* v2 eram reversíveis por código, ele recusou com mais precisão e a Saída Estruturada extraiu melhor. A v3 testa o que o *Tool Calling* ganha ao chamar ferramentas no meio da resposta e receber o retorno de um validador (Seção 4.6.4).

5.4 Teste da v3 no Lote 2

O Gemma 4 E4B executou a v3 congelada no lote 2, na T4, com uma repetição, e as análises seguem o plano da Seção 4.6.4. Com a correção de Holm nas nove comparações do plano, as significativas continuam significativas. A Tabela 12 traz os degraus, o controle e as referências, a Tabela 13 as comparações pareadas e a Tabela 14 a decomposição entre a primeira decisão e a resposta final.

Tabela 12 – Degraus da v3, controle e referências v1/v2 com o Gemma 4 E4B no lote 2 (teste)

Degrau	Configuração	Acurácia	IC 95%	Domínio	F1 recusa	Falsa recusa	E	F1 campos	Latência (s)	Chamadas
0	Tool Calling v1	58,6%	55,5%–61,7%	45,9%	0,562	35,4%	95,4%	0,731	0,85	1,00
1	Tool Calling v2	62,1%	59,0%–65,2%	53,3%	0,991	0,4%	64,6%	0,842	0,91	1,00
2	Tool Calling v3d (descrições v3)	75,2%	72,4%–77,9%	70,3%	0,985	0,7%	67,7%	0,896	0,90	1,01
3	Tool Calling v3a (+ ferramentas auxiliares)	83,1%	80,5%–85,3%	79,8%	0,943	1,8%	86,2%	0,929	1,37	1,82
4	Tool Calling v3 (+ retorno)	94,4%	92,7%–95,7%	94,4%	0,969	0,3%	92,3%	0,981	1,47	2,06
Controle	Saída Estruturada v3 (controle)	87,8%	85,6%–89,8%	84,4%	0,901	5,0%	95,4%	0,946	0,78	1,23
Referência	Saída Estruturada v1	61,3%	58,1%–64,3%	74,8%	0,000	0,0%	66,2%	0,895	0,72	1,00
Referência	Saída Estruturada v2	73,8%	70,9%–76,5%	65,4%	0,738	16,2%	100,0%	0,857	0,61	1,00
Simulação	Duas etapas (TC v2 decide, SE v1 extrai)	78,6%	75,9%–81,1%	74,6%	0,991	0,4%	69,2%	0,900	1,45	1,81
310 (desenv.)	Tool Calling v3 (+ retorno)	97,7%	95,4%–98,9%	98,3%	0,857	0,0%	—	0,993	1,38	2,14
310 (desenv.)	Saída Estruturada v3 (controle)	94,1%	90,9%–96,2%	94,0%	0,615	3,4%	—	0,974	0,77	1,21

Fonte: Elaborado pelos autores. Gemma 4 E4B (`gemma4:e4b-it-qat`), GPU T4, uma repetição, data de referência 2026-09-24. Lote 2 (n = 945 consultas; conjunto de teste, nenhuma consulta lida no desenvolvimento): rodadas em `results/lote2`, repontuadas contra `lote_validacao_2.json`, uma execução por consulta; n=... ao lado do nome: rodada com menos consultas que o conjunto. Degraus: cada configuração acrescenta uma peça à anterior (0: v1; 1: v2; 2: descrições v3; 3: ferramentas auxiliares e usuário simulado; 4: retorno do validador e recusa contestada). Controle: Saída Estruturada com as descrições v3 e o mesmo retorno, sem as ferramentas no meio da resposta. Duas etapas: simulação *post hoc* com as rodadas do próprio lote 2 (o *Tool Calling* v2 decide se busca; quando busca, valem os parâmetros da Saída Estruturada v1; latência somada). Acurácia por consulta, com IC de Wilson. Domínio: acurácia fora das categorias F e E. F1 recusa: média harmônica da precisão e do recall da recusa em F. Falsa recusa: proporção das consultas do domínio sem busca. E: acurácia nas subespecificadas (buscar sem filtros ou não buscar). F1 campos: F1 ponderado dos campos. Latência: mediana por consulta, com todas as chamadas ao modelo. Chamadas: média de chamadas ao modelo por consulta (v1 e v2: uma por construção; duas etapas: uma ou duas). As linhas 310 (desenv.) são de desenvolvimento: as 310 consultas (n = 306; rodadas em `results/v3_310`) orientaram o desenho das descrições, das ferramentas e do validador, e o resultado nelas é de dentro da amostra, otimista por construção.

Tabela 13 – Comparações pareadas no lote 2 (Gemma 4 E4B)

Comparação	Par (A × B)	n	Só A	Só B	p	B – A, acurácia (IC)	B – A, F1 (IC)
Principal	TC v3 × SE v3	945	95	33	< 0,001	-6,6 p.p. (-8,9 a -4,2)	-0,035 (-0,047 a -0,025)
Degraus	TC v1 × TC v2	945	126	159	0,058	+3,5 p.p. (0,0 a +7,0)	0,111 (0,083 a 0,142)
Degraus	TC v2 × TC v3d	945	26	150	< 0,001	+13,1 p.p. (+10,5 a +15,8)	0,053 (0,042 a 0,066)
Degraus	TC v3d × TC v3a	945	55	129	< 0,001	+7,8 p.p. (+5,1 a +10,5)	0,033 (0,018 a 0,047)
Degraus	TC v3a × TC v3	945	12	119	< 0,001	+11,3 p.p. (+9,1 a +13,8)	0,052 (0,042 a 0,064)
Secundárias	Melhor v1/v2 isolada (SE v2) × TC v3	945	29	224	< 0,001	+20,6 p.p. (+17,8 a +23,7)	0,124 (0,107 a 0,143)
Secundárias	Duas etapas × TC v3	945	25	174	< 0,001	+15,8 p.p. (+13,1 a +18,4)	0,081 (0,068 a 0,096)
Secundárias	Duas etapas × SE v3	945	53	140	< 0,001	+9,2 p.p. (+6,6 a +12,1)	0,046 (0,031 a 0,061)
Secundárias	Melhor v1/v2 isolada (SE v2) × SE v3	945	29	162	< 0,001	+14,1 p.p. (+11,4 a +16,9)	0,089 (0,072 a 0,106)
310 (desenv.)	TC v3 × SE v3	306	15	4	0,019	-3,6 p.p. (-6,5 a -1,0)	-0,018 (-0,031 a -0,007)

Fonte: Elaborado pelos autores. Plano de análise fixado antes da rodada (`docs/v3.md`). Lote 2 (n = 945 consultas; conjunto de teste, nenhuma consulta lida no desenvolvimento): rodadas em `results/lote2`; n: consultas presentes nas duas configurações (as comparações usam só essas). Só A / Só B: consultas em que só uma das configurações acerta. p: McNemar exato, uma observação por consulta. IC: bootstrap pareado (2.000 reamostragens das consultas, semente 42), percentis 2,5 e 97,5; F1: F1 ponderado dos campos. Melhor v1/v2 isolada: a de maior acurácia no lote 2 entre TC v1, SE v1, TC v2 e SE v2 (Saída Estruturada v2). Duas etapas: simulação *post hoc* (TC v2 decide, SE v1 extrai). TC: *Tool Calling*; SE: Saída Estruturada. 310 (desenv.): as 310 consultas de desenvolvimento, dentro da amostra que orientou a v3 (não é resultado de teste).

A comparação principal.

O *Tool Calling* v3 acertou 94,4% das consultas (IC 95% de 92,7% a 95,7%), e o controle, 87,8% (IC 95% de 85,6% a 89,8%). Foram 95 consultas acertadas só pelo *Tool Calling* e 33 só pelo controle (p -valor $< 0,001$). O intervalo de 95% da diferença, pelo *bootstrap* pareado, exclui o zero (Tabela 13). A diferença mede o mecanismo junto com as peças que só o *Tool Calling* v3 recebe (Quadro 5 e Seção 4.6.4). A vantagem vem toda do domínio, em que o *Tool Calling* acertou 94,4%, contra 84,4% do controle. O controle errou mais parâmetros nas consultas que buscou e declarou fora do escopo 5,0% das consultas do domínio, contra 0,3% do *Tool Calling*. Por isso a precisão da recusa foi de 98,7% no *Tool Calling* e de 81,9% no controle. Nas outras categorias, o controle acertou mais. Ele recusou todas as consultas fora do domínio, contra 95,1% do *Tool Calling*. Nas subespecificadas, acertou 95,4%, contra 92,3%, quase sempre declarando-as fora do escopo, o que a pontuação aceita (Seção 4.3.4).

Os degraus.

Da v1 para a v2, o *Tool Calling* foi de 58,6% para 62,1%, sem diferença significativa e com o mesmo padrão do lote 1. As descrições corrigidas levaram ao degrau v3d, com 75,2% (+13,1 p.p.). Foi o maior degrau isolado, obtido só com mudanças no texto das descrições. A sigla no lugar do nome da UF e o prefixo no código praticamente desapareceram. O degrau v3a, que acrescenta as ferramentas auxiliares, o usuário simulado e o pedido para responder chamando uma ferramenta (Quadro 5), levou a 83,1% (+7,8 p.p.). O retorno do validador levou ao *Tool Calling* v3, com 94,4% (+11,3 p.p.). Cada peça da v3 acrescentou acurácia, com diferença significativa sobre o degrau anterior.

Contra as referências.

O *Tool Calling* v3 superou a melhor configuração v1 ou v2 isolada no lote 2, a Saída Estruturada v2 (73,8%), e as duas etapas (simulada), com 78,6%. O controle também superou as duas.

Quanto é do modelo e quanto é do código.

O degrau v3d mede o modelo só com as descrições, numa chamada. As ferramentas auxiliares e o retorno do validador, que trazem a lista do IBGE, o índice do BDGEx e a tabela de datas do manual, acrescentaram o resto. A primeira decisão do *Tool Calling* v3 acertou 83,0%, praticamente o mesmo que o degrau v3a. Ela já inclui o retorno das ferramentas auxiliares e não mede o modelo sem o código (Seção 4.6.4). A primeira decisão do controle acertou 74,6%. Numa leitura exploratória, o degrau v3d ficou perto da primeira decisão do controle, e o que separa as abordagens aparece no degrau v3a.

O retorno acrescentou mais ao controle (+13,2 p.p.) que ao *Tool Calling* (+11,4 p.p.). A vantagem do *Tool Calling* já estava na primeira decisão. Numa comparação exploratória, 146 primeiras decisões estavam certas só no *Tool Calling* e 67 só no controle (p -valor $< 0,001$). Das consultas que o retorno consertou no *Tool Calling*, 53,6% receberam do validador o valor a usar, contra 43,2% no controle. Nessas, o acerto é do código que codifica o manual. Nas demais, o modelo corrigiu a resposta a partir do aviso.

Tabela 14 – Decomposição do acerto no lote 2 entre a primeira decisão do modelo e a correção pelo retorno do código

Medida	TC v3a	TC v3	SE v3	TC v3 (310, desenv.)	SE v3 (310, desenv.)
Consultas com traço	945	945	945	306	306
Acurácia da primeira decisão	83,0%	83,0%	74,6%	90,5%	76,8%
Acurácia final	83,1%	94,4%	87,8%	97,7%	94,1%
Final – primeira (p.p.)	+0,1	+11,4	+13,2	+7,2	+17,3
Consertadas pelo retorno	1	112	125	23	53
dando o valor	0	60	54	13	35
mandando remover um campo	0	19	20	4	6
corrigindo a forma	1	12	4	3	1
apontando o campo, sem o valor	0	11	21	3	6
contestando a recusa	0	10	26	0	5
Estragadas pelo retorno	0	4	0	1	0

Fonte: Elaborado pelos autores. Gemma 4 E4B. Lote 2 ($n = 945$ consultas; conjunto de teste, nenhuma consulta lida no desenvolvimento): rodadas em `results/lote2`. Primeira decisão: os parâmetros da primeira chamada a `buscar_catalogo`, ou a recusa, se veio antes de qualquer busca (no *Tool Calling*, pelo traço gravado; na Saída Estruturada, o primeiro objeto do histórico de tentativas), pontuada com o mesmo gabarito da resposta final. Consertadas: primeira decisão errada e final certa; estragadas: o contrário. Cada consertada é atribuída ao retorno mais informativo que recebeu antes da decisão final, pelas mensagens gravadas do validador: dando o valor (a UF ou o município citados, as datas pela tabela do manual, o código ou a escala na forma canônica, o município do IBGE); mandando remover um campo sem evidência na consulta; corrigindo a forma (valor fora do enumerado, período malformato, objeto fora do *schema*); apontando o campo a preencher ou a trocar, sem o valor; contestando a recusa de uma consulta que cita critério do catálogo. No TC v3a não há validação: o retorno é só o da chamada malformatada. Colunas 310: consultas de desenvolvimento, dentro da amostra que orientou a v3 (não é resultado de teste).

As chamadas escritas como texto.

Em 236 consultas (25,0%), o Gemma 4 E4B escreveu ao menos uma chamada no texto da resposta, em vez de emití-la pelo canal de ferramentas, e a v3 a leu como chamada. Numa contagem exploratória, 97,5% delas terminaram certas. Não se sabe quanto a v3 acertaria sem essa leitura, porque o diálogo seria outro. A leitura faz parte do sistema medido (Seção 4.6.4).

O custo.

O *Tool Calling* v3 fez em média 2,06 chamadas ao modelo por consulta. A latência mediana na T4 foi de 1,47 s (percentil 95 de 4,96 s), contra 0,85 s do *Tool Calling* v1, 0,78 s do controle e 1,45 s das duas etapas. O modelo perguntou ao usuário simulado em

133 consultas (14,1%), mais que as 65 subespecificadas, as únicas a que o *prompt* reserva a pergunta. A recusa contestada agiu em 20 consultas. Em 3 consultas fora do domínio, a recusa estava certa, foi contestada e o modelo passou a buscar. Isso explica parte da queda do *recall* da recusa em relação à v2, que recusava 100,0% delas. A outra parte já aparece no degrau v3a, com *recall* de 96,3%, contra 100,0% no degrau v3d. O desenho não separa essas causas.

Desenvolvimento e teste (exploratório).

Nas 310, dentro da amostra, o *Tool Calling* v3 acertou 97,7%, contra 94,1% do controle e 58,8% do método do protótipo, com mediana de 1,38 s contra 12,6 s. No domínio, o *Tool Calling* v3 foi de 98,3% nas 310 para 94,4% no lote 2, e o controle, de 94,0% para 84,4%. A queda, esperada em regras ajustadas sobre os erros do desenvolvimento, foi maior no controle.

Erros restantes do *Tool Calling* v3 (exploratório).

A leitura dos erros, feita depois do teste e sem alterar a v3, mostra três grupos. O maior é a **keyword** preenchida com o que não é nome de carta, como a região como único lugar (“cartas do Nordeste”), o nome do projeto, a escala (“100k”) ou o município no lugar de **city**. O validador não confere se a **keyword** é região, projeto ou escala, e esses erros passaram sem aviso. O segundo grupo são as consultas fora do domínio em que o modelo buscou. O terceiro são expressões de tempo que a tabela do manual não cobre e estados ou municípios omitidos. Em parte dos erros, o validador avisou, o modelo repetiu os mesmos parâmetros e a busca seguiu com eles, como a regra da Seção 4.6.4 prevê. As lacunas são corrigíveis por código da mesma natureza. Corrigi-las a partir destes erros transformaria o lote 2 em desenvolvimento, e a medida fica para um conjunto novo. A seção seguinte verifica se o resultado se repete com outros modelos.

5.5 Extensão da v3 a Outros Modelos

O Gemma 4 E2B e o Qwen 3 4B executaram a mesma v3 congelada no lote 2, com outro *commit* do código e outra versão do Ollama (Seção 4.6.5).

A v3 melhorou o *Tool Calling* nos dois modelos. Com o Gemma 4 E2B, ele foi de 58,1% para 80,4% (+22,3 p.p.). Com o Qwen 3 4B, foi de 56,6% para 73,5% (+16,9 p.p.). A v3 também melhorou a Saída Estruturada, numa comparação exploratória. O controle acertou 65,4% com o Gemma 4 E2B e 88,3% com o Qwen 3 4B, contra 36,5% e 51,4% da Saída Estruturada v1, em parte pelas consultas fora do domínio, que a v1 não tem como recusar. No domínio, a Saída Estruturada foi de 44,2% para 55,4% com o Gemma 4 E2B e de 62,5% para 84,8% com o Qwen 3 4B.

A comparação principal dependeu do modelo. Com o Gemma 4 E2B, o *Tool Calling* v3 superou o controle, como com o E4B, com 211 consultas acertadas só por ele, contra 69 (p -valor $< 0,001$). Com o Qwen 3 4B, o controle acertou mais, com 185 consultas acertadas só por ele, contra 46 (p -valor $< 0,001$). O controle já estava à frente na primeira decisão (68,3% contra 61,4%), e o retorno ampliou a diferença, com +20,0 p.p. no controle e +12,2 p.p. no *Tool Calling*. Numa leitura exploratória, o Qwen 3 4B acrescentou com o *Tool Calling* ordenações não pedidas e, avisado pelo validador, repetiu os mesmos parâmetros, o que pela regra da v3 confirma a busca. Ele fez 2,86 chamadas por consulta, com mediana de 3,15 s na T4.

Na v1, no lote 2, o *Tool Calling* foi melhor que a Saída Estruturada com os dois modelos, sobretudo pelas consultas fora do domínio. A v3 ajudou as duas abordagens nos três modelos medidos, e o mecanismo que a aproveita melhor depende do modelo.

5.6 Evidências sobre os Ganhos do *Tool Calling* no Teste A/B (Modo A $\times$ Modo B)

A Tabela 15 reúne os 24 pares de rodadas em que o mesmo modelo executou o Modo A (*Tool Calling* nativo) e o Modo B (Saída Estruturada validada pelo Pydantic), definidos na Seção 4.6.6. O teste mede o ganho do Modo A em acurácia e em tempo de processamento. As diferenças são Saída Estruturada menos *Tool Calling*, e valor negativo é vantagem do Modo A.

Tabela 15 – Teste A/B entre o *Tool Calling* (A) e a Saída Estruturada (B), com o mesmo modelo, as mesmas consultas, a mesma especificação e o mesmo ambiente

Conjunto	Modelo	Espec.	n	Acurácia (%) TC / SE	SE – TC, p.p. (IC 95%)	p	Domínio (%) TC / SE	F1 recusa TC / SE	Latência (s) TC / SE	p95 (s) TC / SE	Chamadas TC / SE
310 T4	Gemma 4 E2B	v1	306	56,5 / 53,9	-2,6 (-8,8 a +4,2)	0,488	56,4 / 55,4	0,238 / 0,000	0,40 / 0,47	0,70 / 0,86	1,00 / 1,00
	Qwen 3 4B	v1	306	54,2 / 60,1	+5,9 (+0,7 a +10,8)	0,038	53,0 / 61,7	0,552 / 0,000	0,83 / 0,69	1,40 / 1,97	1,00 / 1,00
	Gemma 4 E4B	v1	306	60,1 / 75,2	+15,0 (+9,8 a +20,6)	< 0,001	59,1 / 77,2	0,222 / 0,000	0,72 / 0,76	1,23 / 1,60	1,00 / 1,00
	Mistral Nemo 12B	v1	306	26,8 / 52,0	+25,2 (+18,3 a +32,0)	< 0,001	24,8 / 53,4	0,079 / 0,000	2,39 / 1,00	5,86 / 3,39	1,00 / 1,00
310 (P e N) Estação	Gemma 4 E2B	v1	59	47,5 / 45,8	-1,7 (-15,3 a +11,9)	1,000	45,6 / 47,4	0,333 / 0,000	0,71 / 0,76	1,20 / 1,55	1,00 / 1,00
	Qwen 3 4B	v1	59	49,2 / 50,8	+1,7 (-13,6 a +16,9)	1,000	47,4 / 52,6	0,400 / 0,000	2,60 / 1,97	5,70 / 5,12	1,00 / 1,00
	Gemma 4 E4B	v1	59	52,5 / 61,0	+8,5 (-3,4 a +20,3)	0,302	50,9 / 63,2	0,222 / 0,000	3,42 / 3,29	6,63 / 7,13	1,00 / 1,00
310 (P e N) Estação	Gemma 4 E2B	v3 [†]	59	78,0 / 55,9	-22,0 (-35,6 a -6,8)	0,007	78,9 / 54,4	0,250 / 0,222	1,75 / 0,80	4,62 / 2,17	2,46 / 1,59
	Gemma 4 E4B	v3 [†]	59	98,3 / 84,7	-13,6 (-22,0 a -5,1)	0,008	98,2 / 84,2	1,000 / 0,444	5,63 / 3,38	15,43 / 13,08	2,17 / 1,24
	Qwen 3 4B	v3 [†]	59	59,3 / 86,4	+27,1 (+13,6 a +42,4)	< 0,001	57,9 / 86,0	0,333 / 0,667	11,33 / 3,21	64,93 / 13,65	3,20 / 1,27
310 Groq	GPT-OSS 20B	v1	306	89,2 / 77,5	-11,8 (-16,7 a -7,2)	< 0,001	88,9 / 79,5	0,889 / 0,000	— / —	— / —	1,00 / 1,00
	Qwen 3.8 27B	v1	306	95,1 / 92,8	-2,3 (-4,9 a +0,3)	0,143	95,3 / 95,3	0,933 / 0,000	— / —	— / —	1,00 / 1,00
	GPT-OSS 120B	v1	306	89,9 / 87,3	-2,6 (-6,5 a +1,3)	0,268	89,6 / 89,6	0,727 / 0,000	— / —	— / —	1,00 / 1,00
310 T4	Gemma 4 E4B	v2 [†]	306	47,4 / 68,0	+20,6 (+14,1 a +27,1)	< 0,001	46,0 / 67,1	1,000 / 0,271	0,81 / 0,71	1,31 / 1,47	1,00 / 1,00
	Gemma 4 E4B	v3 [†]	306	97,7 / 94,1	-3,6 (-6,5 a -1,0)	0,019	98,3 / 94,0	0,857 / 0,615	1,38 / 0,77	2,66 / 2,67	2,14 / 1,21
Lote 1 T4	Gemma 4 E4B	v1	1.929	61,5 / 62,2	+0,7 (-2,4 a +3,8)	0,656	48,9 / 75,5	0,592 / 0,000	0,86 / 0,72	1,48 / 1,45	1,00 / 1,00
	Gemma 4 E4B	v2	1.929	62,8 / 72,4	+9,6 (+7,4 a +11,8)	< 0,001	53,4 / 63,2	0,980 / 0,723	0,94 / 0,61	1,45 / 1,48	1,00 / 1,00
Lote 2 T4	Gemma 4 E4B	v1	945	58,6 / 61,3	+2,6 (-1,6 a +6,9)	0,255	45,9 / 74,8	0,562 / 0,000	0,85 / 0,72	1,41 / 1,44	1,00 / 1,00
	Gemma 4 E4B	v2	945	62,1 / 73,8	+11,6 (+7,9 a +14,9)	< 0,001	53,3 / 65,4	0,991 / 0,738	0,91 / 0,61	1,40 / 1,47	1,00 / 1,00
	Gemma 4 E4B	v3	945	94,4 / 87,8	-6,6 (-8,9 a -4,2)	< 0,001	94,4 / 84,4	0,969 / 0,901	1,47 / 0,78	4,96 / 2,55	2,06 / 1,23
	Gemma 4 E2B	v1	945	58,1 / 36,5	-21,6 (-25,3 a -17,8)	< 0,001	47,8 / 44,2	0,795 / 0,000	0,50 / 0,44	0,88 / 0,91	1,00 / 1,00
	Gemma 4 E2B	v3	945	80,4 / 65,4	-15,0 (-18,3 a -11,9)	< 0,001	79,4 / 55,4	0,869 / 0,767	1,00 / 0,44	2,98 / 1,53	2,37 / 1,62
	Qwen 3 4B	v1	945	56,6 / 51,4	-5,2 (-9,4 a -1,3)	0,014	46,4 / 62,5	0,903 / 0,000	1,05 / 0,89	2,22 / 1,53	1,00 / 1,00
	Qwen 3 4B	v3	945	73,5 / 88,3	+14,7 (+11,7 a +18,0)	< 0,001	67,2 / 84,8	0,864 / 0,863	3,15 / 0,65	11,63 / 2,51	2,86 / 1,33

Fonte: Elaborado pelos autores. Cada linha é um par de rodadas do mesmo modelo, sobre as mesmas consultas, com a mesma especificação e no mesmo ambiente: A, *Tool Calling* (TC); B, Saída Estruturada (SE); na v3, o TC completo (descrições, ferramentas auxiliares e retorno do validador) e o controle SE v3, com as mesmas descrições e o mesmo retorno. Linhas: 310, T4: rodadas completas dos modelos locais na GPU T4 (**results/**<modelo>/ e **results/se-**<modelo>/), *Tool Calling* com três repetições e Saída Estruturada com uma; 310 (P e N), estação: estação de referência (RTX 3050 Laptop, 4096 MiB), camadas P e N (**results/estacao/**); 310, Groq: referência em nuvem (**results/groq-**<modelo>/ e **results/groq-se-**<modelo>/); Lote 1: lote de validação (1.929 consultas pontuadas; **results/lote/**), independente do desenho da v2; Lote 2: conjunto de teste da v3 (945 consultas pontuadas; **results/lote2/**), nenhuma delas lida no desenvolvimento; [†] desenvolvimento: as 310 consultas (**results/v2_310/** e **results/v3_310/**) e as camadas P e N delas na estação (**results/estacao/**) orientaram o desenho da v2 e da v3, e o resultado nelas é de dentro da amostra, otimista por construção. Acurácia por consulta; com repetições, cada consulta vale pela maioria delas. SE – TC: diferença de acurácia, com IC 95% por *bootstrap* pareado (2.000 reamostragens das consultas, semente 42). *p*: McNemar exato, uma observação por consulta. Domínio: acurácia fora das categorias F e E. F1 recusa: média harmônica da precisão e do *recall* da recusa nas consultas fora do domínio (na v1, a SE não tem como recusar). Latência: mediana e percentil 95 da tradução, por execução e com todas as chamadas ao modelo, só nos pares cujas duas rodadas têm, nos manifestos, a mesma GPU, a mesma versão do Ollama e a mesma parcela do modelo na GPU (em quatro deles, TC e SE rodaram em sessões diferentes, com a mesma GPU); —: nuvem, com *hardware* do provedor, não controlado. Chamadas: média de chamadas ao modelo por consulta (v1 e v2: uma, por construção).

Acurácia.

Pelo teste de McNemar, a Saída Estruturada foi melhor em 8 pares, o *Tool Calling* em 8, e os dois empataram em 8. Fora dos conjuntos de desenvolvimento, a Saída Estruturada foi melhor em 6 e o *Tool Calling* em 5 dos 19 pares. Qual modo vence depende da especificação e do modelo. Na v1, numa só chamada, a Saída Estruturada extrai melhor nos modelos locais e o *Tool Calling* recusa (Seções 5.2 e 5.3). A exceção é o GPT-OSS 20B, em que o *Tool Calling* acertou mais também sem as consultas fora do domínio. No lote 2, com o Gemma 4 E2B e o Qwen 3 4B, o *Tool Calling* v1 foi melhor, sobretudo pelas consultas fora do domínio (Seção 5.5). Na v2, a Saída Estruturada venceu nos três conjuntos, com +9,6 p.p. no lote 1 e +11,6 p.p. no lote 2, numa comparação em que o texto de recusa difere entre os modos (Seção 4.6.3). Na v3, o *Tool Calling* venceu com os dois Gemma 4, numa diferença que inclui as peças que só ele recebe (Seção 4.6.4), e perdeu com o Qwen 3 4B (Seção 5.5). Dentro da amostra, nas 310 e nas 62 consultas P e N da estação, o padrão se repete. A Tabela 15 traz os valores de cada par.

Tempo.

Com uma chamada ao modelo por consulta, os dois modos custam o mesmo em ordem de grandeza, com diferenças de décimos de segundo, em geral a favor da Saída Estruturada. A exceção é o Mistral Nemo 12B, com mediana de 2,39 s com *Tool Calling*, contra 1,00 s com Saída Estruturada, porque respondeu com textos longos que descrevem a chamada (Seção 5.1.2). Na v3, com o Gemma 4 E4B no lote 2, o *Tool Calling* fez 2,06 chamadas por consulta, contra 1,23 do controle, e sua mediana foi 1,89 vezes a do controle (Seção 5.4). Na estação de referência, com só parte do modelo na GPU e a GPU por vezes compartilhada com outros programas (Seção 4.4.1), a mediana da v3 foi de 1,75 s com o Gemma 4 E2B, contra 0,80 s do controle, e de 5,63 s com o Gemma 4 E4B, contra 3,38 s do controle. Do E4B, coube na GPU uma parcela menor que a do E2B.

O que a acurácia não mede.

Três diferenças a favor do *Tool Calling* ficam fora da pontuação ou só entram nela junto com outras peças. A primeira é a mensagem de recusa. Com *Tool Calling*, a consulta fora do domínio recebe uma frase dirigida ao usuário (na v2 e na v3, o argumento `motivo de recusar_consulta`), e a Saída Estruturada devolve só o campo `fora_do_escopo`, sem texto para o usuário. A segunda é o canal para perguntar. Na v3, `pedir_esclarecimento` separa a pergunta da busca e da recusa, e ele foi exercitado só com o usuário simulado, de resposta fixa (Seção 4.6.4). A terceira é chamar ferramentas no meio da resposta e receber o retorno do validador como resultado da própria chamada, com cada passo registrado no traço da execução. A Saída Estruturada só recebe o retorno como nova tentativa, depois

de uma resposta completa. A terceira entra na acurácia da v3, junto com o código das ferramentas. Medir o valor da mensagem e da pergunta para o usuário exige o estudo com usuários da Seção 6.4.

O ganho do Modo A.

Em acurácia, numa só chamada, o Modo A só venceu com a v1 no lote 2, com o Gemma 4 E2B e o Qwen 3 4B, em que o Modo B não tinha como recusar, e com o GPT-OSS 20B nas 310. Com o laço da v3, venceu com os dois Gemma 4 e perdeu com o Qwen 3 4B. Na recusa, quando os dois modos podiam recusar, o *Tool Calling* teve o maior F1 em todos os pares fora do desenvolvimento. No lote 2, com o Gemma 4 E4B, o F1 da recusa foi de 0,991 contra 0,738 na v2 e de 0,969 contra 0,901 na v3. Com o Qwen 3 4B, na v3, os dois F1 quase empataram. Em tempo de processamento, não houve ganho, e o *Tool Calling* v3 fez cerca de duas chamadas por consulta. O ganho que o Modo A mostrou fora do desenvolvimento é o da recusa, no F1 da v2 e da v3 e na frase dirigida ao usuário. Na v1, só ele podia recusar.

5.7 Discussão e Recomendação

5.7.1 Recomendação e Implantação

Recomenda-se o *Tool Calling* v3 com o Gemma 4 E4B; em GPU modesta, o Qwen 3 4B com a Saída Estruturada v3 ou o Gemma 4 E2B com o *Tool Calling* v3. A configuração padrão acertou 94,4% das consultas do lote 2, com precisão de recusa de 98,7%, *recall* da recusa de 95,1% e falsa recusa de 0,3%. O Quadro 6 traz o custo dela e as alternativas por cenário.

Como a regra decidiu.

A comparação principal deu diferença significativa, e a acurácia decidiu (Seção 4.5). O *recall* menor da recusa e a média de cerca de duas chamadas por consulta entram como custo declarado, e a latência não reverte uma diferença significativa. Na extensão, a comparação principal de cada modelo escolheu o mecanismo que aproveita melhor a v3. A escolha do modelo com a v3 não passou por teste. Ela se apoia no desempate das 310 com a v1 e na maior acurácia observada no lote 2. A v3 foi desenvolvida com esse modelo, o que pode favorecê-lo.

A regra não ordena as duas opções de GPU modesta, porque a diferença de acurácia entre elas no lote 2 não passou por teste. A escolha fica entre a maior acurácia observada, a do Qwen 3 4B com a Saída Estruturada v3, e a menor latência na estação, a do Gemma

Quadro 6 – Configurações recomendadas por cenário de implantação

Cenário	Configuração	Acurácia no lote 2	Custo medido	Ressalva
Padrão	<i>Tool Calling</i> v3 com Gemma 4 E4B	94,4%	2,06 chamadas; 1,47 s na T4; 5,63 s na estação	v3 desenvolvida com esse modelo; <i>recall</i> da recusa de 95,1%
Latência res- trita	Saída Estruturada v3 com Gemma 4 E4B	87,8%	1,23 chamadas; 0,78 s na T4	falsa recusa de 5,0%
GPU modesta (a)	Saída Estruturada v3 com Qwen 3 4B	88,3%	0,65 s na T4; 3,21 s na estação	as duas opções não foram comparadas por teste
GPU modesta (b)	<i>Tool Calling</i> v3 com Gemma 4 E2B	80,4%	1,00 s na T4; 1,75 s na estação	idem
Uma só cha- mada	degrau v3d com Gemma 4 E4B	75,2%	1,01 chamada; 0,90 s na T4	sem ferramentas au- xiliares nem retorno

Fonte: Elaborado pelos autores.

Nota: Na estação, as medidas vêm das 62 consultas P e N, dentro da amostra, com a GPU por vezes compartilhada. As latências na T4 do Qwen 3 4B e do Gemma 4 E2B vêm de outra versão do Ollama (Seção 4.6.5) e não se comparam às do Gemma 4 E4B.

4 E2B com o *Tool Calling* v3. Com o *Tool Calling* v3, o Qwen 3 4B levou 11,33 s de mediana na estação, o que o desaconselha nessas condições.

Hardware.

Nas consultas P e N com a v1, a qualidade praticamente não mudou entre a T4 e a estação, e a latência dependeu da parcela do modelo na GPU (Seção 5.1.3). A VRAM necessária a cada modelo inteiro não foi medida. Antes de implantar, convém repetir as 62 consultas P e N no *hardware* escolhido. Numa estação com mais VRAM, o candidato a avaliar é o GPT-OSS 20B, distribuído para o Ollama com cerca de 14 GB e executável com cerca de 16 GB de memória (OLLAMA, 2025). Ele só foi medido na nuvem e com a v1 (Seção 6.4).

Implantação.

A API já inicia com a configuração recomendada, e a rota `/api/health` mostra se os *hashes* da especificação em uso são os avaliados (Seção 3.5.1). A leitura das chamadas escritas como texto, as ferramentas e o validador vão para a produção com a v3 e precisam acompanhar o catálogo. Na API, o pedido de esclarecimento ainda é respondido pelo usuário simulado. A própria versão do Ollama mudou durante o projeto. Por isso convém fixar as versões do Ollama e do modelo e rodar uma regressão nas 62 consultas P e N a cada troca.

Alcance.

A recomendação vale para a configuração avaliada, sem raciocínio e sem exemplos no *prompt*, e para consultas sintéticas como as dos lotes. As demais limitações estão na Seção 6.3.

5.7.2 Quando o Acervo Não Tem a Resposta

Há dois casos. Quando a busca é legítima, mas nenhum produto atende aos filtros, a API devolve a lista vazia e uma mensagem fixa com os critérios usados, que sugere retirar ou ampliar algum deles, sem nova chamada ao modelo (Seção 3.4.4). Essa resposta não depende do modelo nem da abordagem e não é pontuada. Quando o pedido não é do acervo, a resposta correta é não buscar. Na v1, com *Tool Calling*, só o Gemma 4 E2B, entre os modelos locais, buscou em consultas F das 310, e só o Qwen 3 4B chamou a ferramenta diante de um valor que ela não representa (Seções 5.1.1 e 5.1.2). Na v3, a recusa passa por `recusar_consulta`, cujo argumento `motivo` é a frase dirigida ao usuário, e `normalizar_codigo` informa se o código citado consta no índice do acervo. No lote 2, o *Tool Calling* v3 com o Gemma 4 E4B recusou 95,1% das consultas fora do domínio (155/163), com precisão de 98,7% (Seção 5.4). No método do protótipo, toda consulta vira busca.

5.7.3 O Que Continua Difícil

Com a v1, datas relativas, ordenação e consultas com muitos campos foram difíceis para todos os modelos locais. Parte da dificuldade é inerente à tarefa, porque a consulta nem sempre diz se a ordem é por publicação ou por criação. A v3, que passa a aritmética de datas ao código, reduziu outra parte. Numa análise exploratória, o Gemma 4 E4B acertou no lote 2 91,4% das consultas de tempo relativo, 97,0% das de ordenação e 93,6% das compostas, contra 22,3%, 27,3% e 49,1% com a v1. O que a v3 ainda erra está na Seção 5.4.

6 CONCLUSÃO

6.1 Síntese e Objetivos Atendidos

O trabalho partiu do protótipo do 1º CGEO, que traduzia a consulta com Saída Estruturada, e construiu a solução v1, com *Tool Calling* nativo e modelos abertos executados localmente. Nas 310 consultas, com gabarito auditado, a v1 foi avaliada com quatro modelos locais e comparada com a Saída Estruturada nos mesmos modelos. Numa só chamada, só o *Tool Calling* recusou os pedidos fora do catálogo, e a Saída Estruturada em geral extraiu melhor. O lote 1 (validação) confirmou esse quadro com consultas novas. Nele, a v2 reduziu a falsa recusa do *Tool Calling*, criou erros de forma e deixou a Saída Estruturada à frente. A v3 acrescentou ferramentas auxiliares e um validador que devolve os erros ao modelo. Congelada, foi testada no lote 2 (teste) contra o controle, a Saída Estruturada v3 com as mesmas descrições e o mesmo validador, repetida com outros dois modelos e reunida às demais rodadas no teste A/B. Nas consultas sintéticas do lote 2, o *Tool Calling* v3 com o Gemma 4 E4B acertou 94,4%.

O objetivo geral foi atingido. A camada de tradução linguística da busca sobre o acervo da DSG foi aprimorada e medida, e os seis entregáveis da Seção 1.5.3 foram concluídos e reunidos no repositório público (Apêndice C). Os marcos técnicos do trabalho são estes:

1. a rearquitetura do *backend* em Python (FastAPI, LangChain e Ollama), que substitui o Node.js do protótipo, reúne as nove configurações avaliadas num registro de abordagens com teste de regressão e integração contínua, é empacotada num *Dockerfile* e já serve pela API a configuração recomendada (Seção 3.5.1);
2. a adoção do *Tool Calling* nativo, que deu ao sistema a recusa explícita dos pedidos fora do catálogo e, na v3, ferramentas auxiliares do domínio que o modelo consulta no meio da resposta (Seções 3.4.2 e 4.6.4);
3. o *dataset* de 310 consultas, com gabarito definido por manual de anotação e auditado por anotação independente e adjudicação, que, com as métricas do protocolo, dá à busca a avaliação formal que o protótipo não tinha (Seções 4.3 e 4.4);
4. os lotes 1 e 2, de 1.929 e 945 consultas, com valores tirados dos metadados públicos do BDGEx e da lista de municípios do IBGE e com gabarito fixado antes da redação. O lote 1 validou as versões, e o lote 2, nunca usado no desenvolvimento, testou a v3, congelada por *hash* e com a comparação principal fixada antes da rodada (Seções 4.3.4 e 4.6.4);

5. o *pipeline* de avaliação automatizado e reproduzível, com o teste A/B entre o Modo A e o Modo B, que compara qualquer novo modelo ou configuração pelo mesmo critério (Seções 3.5 e 4.6.6);
6. o relatório comparativo de quatro modelos locais, com três modelos em nuvem como referência, e a recomendação operacional por cenário de *hardware* (Seção 5.7.1).

Para a DSG, o resultado é uma busca em linguagem natural que roda em *hardware* próprio, com modelo aberto e sem serviço de nuvem, o que preserva o controle sobre os dados. Para a disseminação da informação geoespacial, o ganho é que a consulta escrita sem as nomenclaturas técnicas passa a ser traduzida nos parâmetros do catálogo, o que foi medido em consultas sintéticas e ainda não com usuários (Seção 6.3).

Três requisitos do Quadro 1 ficam com ressalva. O RNF2 (latência) foi reportado por ambiente, sem limiar. O RF3 (busca no PostgreSQL/PostGIS) foi demonstrado sobre dados sintéticos, sem os dados do acervo. O RNF3 (metadados conforme a ET-PCDG e o Perfil MGB) usa o esquema do protótipo, sem verificação à parte.

6.2 Respostas às Questões do Trabalho

As respostas seguem as quatro questões da Seção 1.5.2. A Q1 tem três partes (Q1a a Q1c).

- **Q1a. Em relação ao protótipo, o *Tool Calling* melhorou alguma métrica?** Nas 310, a solução v1, com os três melhores modelos locais, empatou com o método do protótipo, que acertou 58,8%. Os modelos da v1 são menores, rodaram mais de quinze vezes mais rápido e dispensam o dicionário e os exemplos, e toda falha passou a ser registrada, sem *fallback* que a mascarasse. A redução de porte e de tempo veio da troca de modelo, e não do *Tool Calling*. Em acurácia, o *Tool Calling* de uma chamada não trouxe ganho, porque com a Saída Estruturada os mesmos modelos acertaram tanto ou mais. Dele veio a capacidade de recusar o que o catálogo não atende. O protótipo não rodou nos lotes. A única comparação da v3 com ele é a das 310, dentro da amostra, em que o *Tool Calling* v3 acertou 97,7% (Seções 5.2 e 5.4).
- **Q1b. No teste A/B, o Modo A rendeu mais que o Modo B em acurácia e em tempo de processamento?** Em acurácia, só em parte. Nos 24 pares, a Saída Estruturada (Modo B) foi melhor em 8, o *Tool Calling* (Modo A) em 8, e os dois empataram em 8. Fora dos conjuntos de desenvolvimento, a Saída Estruturada foi melhor em 6 e o *Tool Calling* em 5 dos 19 pares. Com a v1, o Modo A venceu alguns pares pela recusa, que a Saída Estruturada v1 não faz, e no lote 1 só acertaria mais se mais de 18,0% das consultas estivessem fora do catálogo (Seção 5.3). Nas 310, o

GPT-OSS 20B, servido em nuvem, já acertava mais com o *Tool Calling* v1, também sem a categoria F (Seção 5.2). Com a v2, o Modo B venceu. Com a v3, o Modo A venceu com os dois Gemma 4 e perdeu com o Qwen 3 4B. O ganho que se repetiu foi o da recusa, com o maior F1 em todos os pares fora do desenvolvimento em que os dois modos podiam recusar. Em tempo de processamento, não houve ganho. Numa chamada, os dois modos custam o mesmo em ordem de grandeza. Com a v3, o *Tool Calling* fez cerca de duas chamadas ao modelo por consulta e levou mais tempo que o controle (Seção 5.6).

- **Q1c. De onde vem o ganho da v3?** No lote 2, com o Gemma 4 E4B, o *Tool Calling* foi de 62,1% na v2 a 75,2% com as descrições corrigidas, a 83,1% com as ferramentas auxiliares e o usuário simulado e a 94,4% com o retorno do validador. Numa comparação exploratória, a vantagem sobre o controle já estava na primeira decisão (83,0% contra 74,6%), que inclui o que as ferramentas devolvem. O desenho não separa o mecanismo dessas peças, que só o *Tool Calling* v3 recebe. Com os outros dois modelos, a v3 também melhorou o *Tool Calling* e, numa comparação exploratória, a Saída Estruturada (Seções 5.4 e 5.5).
- **Q2. Como saber se o gabarito e as consultas são bons?** O gabarito segue regras escritas antes da anotação, com as leituras múltiplas explícitas. Nas 310, uma anotação às cegas, feita do zero, concordou com ele em quase todos os valores de campo e apontou as divergências, cada uma adjudicada com registro, e um dos autores conferiu à mão 40 consultas. Nos lotes, o gabarito foi fixado por código antes de o texto existir, e só entrou a consulta cuja anotação às cegas era compatível com ele. Uma segunda anotação de uma amostra, fora desse filtro, mediu a concordância. Das 160 execuções erradas do lote 1 sorteadas para auditoria, 155 eram erros reais do modelo. O anotador, os redatores e o juiz dos erros são modelos de linguagem da mesma família (Claude), nenhuma pessoa conferiu os lotes, e as consultas são sintéticas (Seções 4.3.3, 4.3.4, 4.7 e 6.3).
- **Q3. O que acontece quando não há carta que atenda ao pedido?** Quando o pedido não é do acervo, o correto é não buscar. No lote 2, o *Tool Calling* v3 recusou 95,1% das consultas fora do domínio, com precisão de 98,7%, e explica ao usuário, numa frase, por que recusou. Quando a busca é legítima e nenhum produto atende aos filtros, a API devolve a lista vazia e uma mensagem fixa com os critérios usados, sem nova chamada ao modelo. No método do protótipo, toda consulta vira busca (Seções 3.4.4 e 5.7.2).
- **Q4. Que modelo e que abordagem recomendar, e em que *hardware*?** Recomenda-se o *Tool Calling* v3 com o Gemma 4 E4B; em GPU modesta, o Qwen 3 4B com a Saída Estruturada v3 ou o Gemma 4 E2B com o *Tool Calling* v3. A

configuração padrão fez, em média, 2,06 chamadas ao modelo por consulta, com mediana de 1,47 s na T4 e de 5,63 s na estação de referência, medida nas 62 consultas P e N com a GPU compartilhada. Entre os modelos locais, o porte não ordenou o desempenho, e o Mistral Nemo 12B, o maior, ficou abaixo dos outros três. Implantar a v3 exige manter o código do domínio junto com o catálogo, e convém fixar as versões do Ollama e do modelo. O Quadro 6 traz as alternativas por cenário.

6.3 Limitações e Lacunas do Trabalho

As Tabelas 6 e 7 listam as ameaças à validade e o tratamento de cada uma. As cinco que mais pesam sobre as conclusões são estas:

1. **Consultas sintéticas.** Nenhuma consulta foi coletada de usuários. A camada G, gerada por modelos de frase e mais regular que a linguagem de usuários, é a maior parte das 310 e pode superestimar o desempenho. A anotação independente das 310 foi feita por um modelo, e a conferência humana cobriu 40 delas. Os lotes foram redigidos e anotados pela mesma família de modelos que julgou os erros, e nenhuma pessoa os conferiu. O lote 2 segue a receita do lote 1 e mede consultas novas, não outra distribuição. A proporção real de consultas fora do catálogo é desconhecida. Dela depende qual abordagem v1 acerta mais, mas a vantagem do *Tool Calling* v3 sobre o controle vem das consultas do domínio e só se inverteria se a maior parte das consultas estivesse fora dele.
2. **O código do domínio na v3.** As ferramentas e o validador codificam o manual que define o gabarito, inclusive a tabela de datas, e o lote 2 sorteou nomes e códigos das mesmas listas que as ferramentas consultam. O alcance fora dessas listas não foi medido. Em 25,0% das consultas, o modelo escreveu a chamada no texto da resposta, fora do canal próprio do *Tool Calling*, e a v3 a leu. Essa leitura faz parte do sistema medido.
3. **Um só modelo no desenvolvimento da v3.** A v3 foi desenvolvida com o Gemma 4 E4B, o que pode favorecê-lo, e a escolha do modelo com a v3 não passou por teste. A explicação da inversão com o Qwen 3 4B é exploratória. Os modelos locais rodaram numa só configuração, sem o modo de raciocínio e sem exemplos no *prompt*, e a extensão usou outra versão do Ollama.
4. **Alcance das medidas.** A latência da v3 na estação vem só das 62 consultas P e N, dentro da amostra, e a VRAM necessária a cada modelo inteiro não foi medida. Os lotes tiveram uma repetição por configuração. O pedido de esclarecimento foi respondido por um usuário simulado de resposta fixa.

5. **Análises *post hoc*.** As duas etapas (simulada), que unem o *Tool Calling* v2 e a Saída Estruturada v1, e a regra do objeto vazio são simulações sobre rodadas existentes (Seção 4.6.3). As causas dos erros da v2 não foram testadas retirando cada instrução em separado, e a comparação entre as duas v2 mede o mecanismo junto com o texto de recusa. Na categoria E (subespecificadas), a pontuação aceita qualquer não busca. O nível de significância e a ordem dos desempates foram escritos depois das rodadas. A leitura dos erros do lote 2 é exploratória, e os subgrupos são pequenos.

As linhas de base e a referência em nuvem rodaram com uma repetição, e o método do protótipo foi reproduzido com temperatura zero e sem a validação de locais no banco. Os resultados valem para as versões registradas nos manifestos. As demais ameaças estão nas duas tabelas e pesam menos.

6.4 Trabalhos Futuros e Pontos de Melhoria

Os itens decorrem das exclusões de escopo (Seção 1.6), das limitações (Seção 6.3), dos erros restantes da v3 (Seção 5.4), do tratamento de falhas da API (Seção 3.4.1) e da referência em nuvem (Seção 5.1.4).

1. Avaliar a recuperação em nível de produto, com um gabarito das folhas que cada consulta deve devolver.
2. Resolver os campos geográficos em geometrias, com a malha do IBGE e serviços de geocodificação.
3. Criar um *fallback* de produção, como encaminhar a consulta à busca textual do PostgreSQL.
4. Fechar as lacunas do validador (**keyword** preenchida com região, nome de projeto ou escala, expressões de tempo fora da tabela e contestação da recusa) e medir o efeito num terceiro conjunto, porque o lote 2 já foi usado.
5. Executar a v3 com o banco do acervo, medir a sua latência em uso real e levar o pedido de esclarecimento ao usuário, em vários turnos.
6. Medir na estação, com a GPU dedicada, as duas opções para GPU modesta e investigar a inversão com o Qwen 3 4B.
7. Avaliar o raciocínio ativado e os exemplos no *prompt*, com o ganho de qualidade e o custo de latência.

8. Avaliar localmente, com a v3, modelos abertos maiores, como o GPT-OSS 20B e o Qwen 3.8 27B, numa GPU de 16 GB ou mais.
9. Coletar consultas reais anotadas por especialistas e avaliar a solução com usuários do catálogo, com interface e integração ao sistema da DSG, incluindo autenticação, controle de acesso e monitoramento.
10. Treinar por ajuste fino um modelo menor para o domínio, para reduzir o requisito de *hardware*.

6.5 O Conhecimento do Engenheiro Cartógrafo como Diferencial Estruturante

Com a mesma v3, o *Tool Calling* acertou de 73,5% a 94,4% das consultas do lote 2, conforme o modelo, e o mecanismo vencedor mudou de um modelo para outro. O que se repetiu nos três modelos foi o ganho da v3, que melhorou o *Tool Calling* e, numa comparação exploratória com os outros dois, também a Saída Estruturada. A v3 é o conhecimento especializado do engenheiro cartógrafo convertido em descrições, ferramentas e validador, e esse conhecimento é o diferencial estruturante da solução. O modelo contribui com a compreensão da linguagem livre do usuário, e a estrutura do domínio vem do especialista. Esse conhecimento definiu o que conta como resposta certa no manual de anotação, com as convenções do INOM e do MI, as escalas do Sistema Cartográfico Nacional, os tipos de produto, os Centros de Geoinformação e as regras de tempo. Fixou os critérios pelos quais os conjuntos de avaliação foram construídos, anotados e auditados. Na v3, virou código, em ferramentas que o modelo consulta (o índice de folhas, a lista de municípios, a normalização de códigos e de escalas, a tabela de datas) e num validador que confere a sua saída, no lugar do dicionário que o protótipo aplicava à consulta antes do modelo. Com o mesmo modelo, as descrições reescritas a partir do manual levaram a acurácia no lote 2 de 62,1% a 75,2%, o maior degrau isolado. As ferramentas e o validador, chamados pelo laço da v3 junto com o usuário simulado, levaram-na a 94,4%, num teste cujo gabarito segue o mesmo manual. Na v2, esse conhecimento entrou como instruções soltas no *prompt* de um modelo pequeno e consertou alguns erros e criou outros. Na v3, entrou nas descrições da ferramenta e em código verificável, testado contra o gabarito, e a acurácia subiu num conjunto que o desenvolvimento não viu.

Para o cliente, o resultado mais duradouro é o instrumento de avaliação. A classificação dos modelos envelhece com o ecossistema, e o resultado da mesma comparação mudou com o conjunto, a especificação e o modelo. O *dataset* tem gabarito justificado por regras escritas e divergências adjudicadas, e o *pipeline* reproduzível permite comparar qualquer novo modelo, *prompt* ou configuração com o mesmo critério.

REFERÊNCIAS

- 1º CENTRO DE GEOINFORMAÇÃO. *Protótipo de busca de geoinformação utilizando Large Language Models*. 2025. Repositório GitHub. Disponível em: <https://github.com/1cgeo/prototipo_busca_llm>. Acesso em: mar. 2026.
- ABDIN, M.; ANEJA, J.; BEHL, H.; BUBECK, S.; ELDAN, R.; GUNASEKAR, S.; HARRISON, M.; HEWETT, R. J.; JAVAHERIPI, M.; KAUFFMANN, P. et al. Phi-4 technical report. *arXiv preprint arXiv:2412.08905*, 2024. Disponível em: <<https://arxiv.org/abs/2412.08905>>.
- ARTSTEIN, R.; POESIO, M. Inter-coder agreement for computational linguistics. *Computational Linguistics*, v. 34, n. 4, p. 555–596, 2008.
- BRASIL. *Decreto-Lei n.º 243, de 28 de fevereiro de 1967: Fixa as Diretrizes e Bases da Cartografia Brasileira e dá outras providências*. Brasília, DF, 1967. Institui o Sistema Cartográfico Nacional e as escalas-padrão da Cartografia Sistemática Terrestre Básica. Disponível em: <https://www.planalto.gov.br/ccivil_03/decreto-lei/1965-1988/del0243.htm>. Acesso em: set. 2026.
- BRASIL. *Decreto n.º 89.817, de 20 de junho de 1984: Estabelece as Instruções Reguladoras das Normas Técnicas da Cartografia Nacional*. Brasília, DF, 1984. Disponível em: <https://www.planalto.gov.br/ccivil_03/decreto/1980-1989/d89817.htm>. Acesso em: set. 2026.
- BRASIL. *Decreto n. 6.666, de 27 de novembro de 2008: Institui, no âmbito do Poder Executivo federal, a Infra-Estrutura Nacional de Dados Espaciais – INDE, e dá outras providências*. Brasília, DF, 2008. Publicado no Diário Oficial da União de 28 nov. 2008; redação alterada pelo Decreto n.º 12.402, de 13 de março de 2025. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2007-2010/2008/decreto/d6666.htm>. Acesso em: set. 2026.
- BRASIL. Comissão Nacional de Cartografia (CONCAR). *Perfil de Metadados Geoespaciais do Brasil (Perfil MGB)*. [S.l.], 2009. Versão homologada em novembro de 2009; atualizada pelo Perfil MGB 2.0 (IBGE; DSG, 2021). Disponível em: <https://inde.gov.br/pdf/Perfil_MGB_homologado_nov2009_v1.pdf>. Acesso em: set. 2026.
- BRASIL. Ministério da Defesa. Exército Brasileiro. Diretoria de Serviço Geográfico. *Especificação Técnica para Produtos de Conjuntos de Dados Geoespaciais (ET-PCDG)*. [S.l.], 2016. Norma EB80-N-72.001, 2.ª edição, aprovada pela Portaria n.º 008-DCT, de 10 de fevereiro de 2016. Disponível em: <<https://geoportal.eb.mil.br/portal/index.php/normas/et-pcdg>>. Acesso em: set. 2026.
- BROWN, T.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J. D.; DHARIWAL, P.; NEELAKANTAN, A.; SHYAM, P.; SASTRY, G.; ASKELL, A. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2020. v. 33, p. 1877–1901. Disponível em: <<https://arxiv.org/abs/2005.14165>>.

- CHASE, H. *LangChain: Building applications with LLMs through composability*. 2022. Disponível em: <<https://github.com/langchain-ai/langchain>>. Acesso em: mar. 2026.
- CHEN, X.; LIN, M.; SCHÄRLI, N.; ZHOU, D. Teaching large language models to self-debug. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 8746–8825. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/2460396f2d0d421885997dd1612ac56b-Abstract-Conference.html>.
- COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.
- COLVIN, S. *Pydantic: Data validation using Python type hints*. 2019. Disponível em: <<https://docs.pydantic.dev>>. Acesso em: mar. 2026.
- DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, v. 10, n. 7, p. 1895–1923, 1998.
- DIRETORIA DE SERVIÇO GEOGRÁFICO DO EXÉRCITO BRASILEIRO. *Acesso ao BDGEx*. 2025a. Geoportal do Exército. Disponível em: <<https://geoportal.eb.mil.br/portal/index.php/bdgex/acesso-ao-bdgex>>. Acesso em: set. 2026.
- DIRETORIA DE SERVIÇO GEOGRÁFICO DO EXÉRCITO BRASILEIRO. *Missão da Diretoria de Serviço Geográfico*. 2025b. Geoportal do Exército. Disponível em: <<https://geoportal.eb.mil.br/portal/index.php/chefia/missao>>. Acesso em: set. 2026.
- DWORK, C.; FELDMAN, V.; HARDT, M.; PITASSI, T.; REINGOLD, O.; ROTH, A. The reusable holdout: Preserving validity in adaptive data analysis. *Science*, v. 349, n. 6248, p. 636–638, 2015. Disponível em: <<https://doi.org/10.1126/science.aaa9375>>.
- FRANTAR, E.; ASHKBOOS, S.; HOEFLER, T.; ALISTARH, D. GPTQ: Accurate post-training quantization for generative pre-trained transformers. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2023. Disponível em: <<https://arxiv.org/abs/2210.17323>>.
- GEMMA TEAM. Gemma 4 technical report. *arXiv preprint arXiv:2607.02770*, 2026. Google DeepMind. Disponível em: <<https://arxiv.org/abs/2607.02770>>.
- GGML CONTRIBUTORS. *GGUF: file format specification*. 2023. Formato introduzido no `llama.cpp` em agosto de 2023. Disponível em: <<https://github.com/ggml-org/ggml/blob/master/docs/gguf.md>>. Acesso em: set. 2026.
- GOU, Z.; SHAO, Z.; GONG, Y.; SHEN, Y.; YANG, Y.; DUAN, N.; CHEN, W. CRITIC: Large language models can self-correct with tool-interactive critiquing. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 57734–57811. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/fef126561bbf9d4467dbb8d27334b8fe-Abstract-Conference.html>.
- GROQ. *Reasoning*. 2026. Documentação do parâmetro `reasoning_effort`. Disponível em: <<https://console.groq.com/docs/reasoning>>. Acesso em: set. 2026.
- HU, Y.; JANOWICZ, K.; PRASAD, S.; GAO, S. Metadata topic harmonization and semantic search for linked-data-driven geoportals: A case study using ArcGIS Online. *Transactions in GIS*, v. 19, n. 3, p. 398–416, 2015. Disponível em: <<https://doi.org/10.1111/tgis.12151>>.

- HUANG, J.; CHEN, X.; MISHRA, S.; ZHENG, H. S.; YU, A. W.; SONG, X.; ZHOU, D. Large language models cannot self-correct reasoning yet. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 32808–32824. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/8b4add8b0aa8749d80a34ca5d941c355-Abstract-Conference.html>.
- HUANG, S.; FANG, Z.; CHEN, Z.; YUAN, S.; YE, J.; ZENG, Y.; CHEN, L.; MAO, Q.; ZHAO, F. CRITICTOOL: Evaluating self-critique capabilities of large language models in tool-calling error scenarios. In: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Suzhou, China: Association for Computational Linguistics, 2025. p. 26672–26704. Disponível em: <<https://aclanthology.org/2025.emnlp-main.1355/>>.
- KHATTAB, O.; SINGHVI, A.; MAHESHWARI, P.; ZHANG, Z.; SANTHANAM, K.; A, S. V.; HAQ, S.; SHARMA, A.; JOSHI, T. T.; MOAZAM, H. et al. DSPy: Compiling declarative language model calls into self-improving pipelines. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 54928–54958. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/f1cf02ce09757f57c3b93c0db83181e0-Abstract-Conference.html>.
- LANGCHAIN AI. *LangGraph: Building stateful, multi-actor applications with LLMs*. 2024. Disponível em: <<https://github.com/langchain-ai/langgraph>>. Acesso em: mar. 2026.
- LI, H.; YUE, P.; WU, H.; TENG, B.; ZHAO, Y.; LIU, C. A question-answering framework for geospatial data retrieval enhanced by a knowledge graph and large language models. *International Journal of Digital Earth*, v. 18, n. 1, 2025. Art. 2510566. Disponível em: <<https://doi.org/10.1080/17538947.2025.2510566>>.
- LI, M.; ZHAO, Y.; YU, B.; SONG, F.; LI, H.; YU, H.; LI, Z.; HUANG, F.; LI, Y. API-Bank: A comprehensive benchmark for tool-augmented LLMs. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, 2023. p. 3102–3116. Disponível em: <<https://aclanthology.org/2023.emnlp-main.187/>>.
- LI, Z.; NING, H. Autonomous GIS: the next-generation AI-powered GIS. *International Journal of Digital Earth*, v. 16, n. 2, p. 4668–4686, 2023. Disponível em: <<https://doi.org/10.1080/17538947.2023.2278895>>.
- LIU, J. *Instructor: Structured outputs for LLMs*. 2023. Disponível em: <<https://python.useinstructor.com>>. Acesso em: mar. 2026.
- LIU, X.; SHEN, S.; LI, B.; MA, P.; JIANG, R.; ZHANG, Y.; FAN, J.; LI, G.; TANG, N.; LUO, Y. A survey of text-to-SQL in the era of LLMs: Where are we, and where are we going? *IEEE Transactions on Knowledge and Data Engineering*, v. 37, n. 10, p. 5735–5754, 2025. Disponível em: <<https://ieeexplore.ieee.org/document/11095853>>.
- LU, J.; HOLLEIS, T.; ZHANG, Y.; AUMAYER, B.; NAN, F.; BAI, H.; MA, S.; MA, S.; LI, M.; YIN, G. et al. ToolSandbox: A stateful, conversational, interactive evaluation benchmark for LLM tool use capabilities. In: *Findings of the Association for Computational Linguistics: NAACL 2025*. Albuquerque, New Mexico: Association for Computational Linguistics, 2025. p. 1160–1183. Disponível em: <<https://aclanthology.org/2025.findings-naacl.65/>>.

- MADAAN, A.; TANDON, N.; GUPTA, P.; HALLINAN, S.; GAO, L.; WIEGREFFE, S.; ALON, U.; DZIRI, N.; PRABHUMOYE, S.; YANG, Y. et al. Self-Refine: Iterative refinement with self-feedback. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2023. v. 36, p. 46534–46594. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/91edff07232fb1b55a505a9e9f6c0ff3-Abstract-Conference.html>.
- MAI, G.; HUANG, W.; SUN, J.; SONG, S.; MISHRA, D.; LIU, N.; GAO, S.; LIU, T.; CONG, G.; HU, Y. et al. On the opportunities and challenges of foundation models for GeoAI (vision paper). *ACM Transactions on Spatial Algorithms and Systems*, v. 10, n. 2, p. 1–46, 2024. Disponível em: <<https://doi.org/10.1145/3653070>>.
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008. Disponível em: <<https://nlp.stanford.edu/IR-book/>>.
- MANVI, R.; KHANNA, S.; MAI, G.; BURKE, M.; LOBELL, D.; ERMON, S. GeoLLM: Extracting geospatial knowledge from large language models. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 38791–38807. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/a87f2df7c4ab0213c6ea228e7b7f0a4d-Abstract-Conference.html>.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MISTRAL AI. *Mistral NeMo*. 2024. Disponível em: <<https://mistral.ai/news/mistral-nemo>>. Acesso em: set. 2026.
- NING, H.; LI, Z.; AKINBOYEWA, T.; LESSANI, M. N. An autonomous GIS agent framework for geospatial data retrieval. *International Journal of Digital Earth*, v. 18, n. 1, 2025. Art. 2458688. Disponível em: <<https://doi.org/10.1080/17538947.2025.2458688>>.
- OLLAMA. *Ollama: Get up and running with large language models locally*. 2023. Disponível em: <<https://ollama.com>>. Acesso em: mar. 2026.
- OLLAMA. *gpt-oss:20b*. 2025. Biblioteca de modelos do Ollama. Disponível em: <<https://ollama.com/library/gpt-oss:20b>>. Acesso em: set. 2026.
- OPEN GEOSPATIAL CONSORTIUM. *OpenGIS Catalogue Services Specification, version 2.0.2 (Corrigendum 2 Release)*. 2007. OGC 07-006r1. Editores: Douglas Nebert, Arliss Whiteside e Panagiotis Vretanos. Disponível em: <<https://docs.ogc.org/is/07-006r1/07-006r1.pdf>>. Acesso em: set. 2026.
- OPENAI. gpt-oss-120b & gpt-oss-20b model card. *arXiv preprint arXiv:2508.10925*, 2025. Disponível em: <<https://arxiv.org/abs/2508.10925>>.
- OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P.; ZHANG, C.; AGARWAL, S.; SLAMA, K.; RAY, A. et al. Training language models to follow instructions with human feedback. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2022. v. 35, p. 27730–27744. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html>.

- PATIL, S. G.; MAO, H.; YAN, F.; JI, C. C.-J.; SURESH, V.; STOICA, I.; GONZALEZ, J. E. The Berkeley function calling leaderboard (BFCL): From tool use to agentic evaluation of large language models. In: *Proceedings of the 42nd International Conference on Machine Learning*. PMLR, 2025. (Proceedings of Machine Learning Research, v. 267), p. 48371–48392. Disponível em: <<https://proceedings.mlr.press/v267/patil25a.html>>.
- PATIL, S. G.; ZHANG, T.; WANG, X.; GONZALEZ, J. E. Gorilla: Large language model connected with massive APIs. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2024. v. 37, p. 126544–126565. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2024/hash/e4c61f578ff07830f5c37378dd3ecb0d-Abstract-Conference.html>.
- POSTGIS DEVELOPMENT TEAM. *PostGIS: Spatial and geographic objects for PostgreSQL*. 2001. Disponível em: <<https://postgis.net>>. Acesso em: mar. 2026.
- QIN, Y.; LIANG, S.; YE, Y.; ZHU, K.; YAN, L.; LU, Y.; LIN, Y.; CONG, X.; TANG, X.; QIAN, B. et al. ToolLLM: Facilitating large language models to master 16000+ real-world APIs. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 9695–9717. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/28e50ee5b72e90b50e7196fde8ea260e-Abstract-Conference.html>.
- QWEN TEAM. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025. Disponível em: <<https://arxiv.org/abs/2505.09388>>.
- QWEN TEAM. *Qwen3.8-27B*. 2026. Model card no Hugging Face (Alibaba Cloud); pesos abertos sob licença Apache 2.0. Disponível em: <<https://huggingface.co/Qwen/Qwen3.8-27B>>. Acesso em: set. 2026.
- RAMÍREZ, S. *FastAPI: Modern, fast web framework for building APIs with Python*. 2018. Disponível em: <<https://fastapi.tiangolo.com>>. Acesso em: mar. 2026.
- ROSS, H.; MAHABALESHWARKAR, A. S.; SUHARA, Y. When2Call: When (not) to call tools. In: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Albuquerque, New Mexico: Association for Computational Linguistics, 2025. p. 3391–3409. Disponível em: <<https://aclanthology.org/2025.naacl-long.174/>>.
- SCHICK, T.; DWIVEDI-YU, J.; DESSÌ, R.; RAILEANU, R.; LOMELI, M.; HAMBRO, E.; ZETTLEMOYER, L.; CANCEDDA, N.; SCIALOM, T. Toolformer: Language models can teach themselves to use tools. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2023. v. 36, p. 68539–68551. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/d842425e4bf79ba039352da0f658a906-Abstract-Conference.html>.
- SHINN, N.; CASSANO, F.; GOPINATH, A.; NARASIMHAN, K.; YAO, S. Reflexion: Language agents with verbal reinforcement learning. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2023. v. 36, p. 8634–8652. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html>.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: *Advances in Neural*

Information Processing Systems. Curran Associates, Inc., 2017. v. 30. Disponível em: <<https://arxiv.org/abs/1706.03762>>.

WEI, J.; TAY, Y.; BOMMASANI, R.; RAFFEL, C.; ZOPH, B.; BORGEAUD, S.; YOGATAMA, D.; BOSMA, M.; ZHOU, D.; METZLER, D. et al. Emergent abilities of large language models. *Transactions on Machine Learning Research*, 2022. Disponível em: <<https://arxiv.org/abs/2206.07682>>.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, v. 22, n. 158, p. 209–212, 1927.

XAVIER, E. M. A.; MEYER, W. S.; LUNARDI, O. A. Banco de dados geográficos do Exército Brasileiro: arquitetura e resultados. In: *Jornadas Ibéricas de Infraestruturas de Dados Espaciais (JIIDE 2014)*. [s.n.], 2014. Disponível em: <https://www.ides.es/resources/presentaciones/JIIDE14/20141106/BancoDatosGeograficos_presentacion.pdf>. Acesso em: set. 2026.

YANG, C.; WANG, X.; LU, Y.; LIU, H.; LE, Q. V.; ZHOU, D.; CHEN, X. Large language models as optimizers. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2024. p. 12028–12068. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2024/hash/3339f19c5fcee3ad74502947a32be9e6-Abstract-Conference.html>.

YAO, S.; SHINN, N.; RAZAVI, P.; NARASIMHAN, K. τ -bench: A benchmark for tool-agent-user interaction in real-world domains. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2025. p. 9965–10017. Disponível em: <https://proceedings.iclr.cc/paper_files/paper/2025/hash/1b126cc38b8638e07bef37e7b2bb72bf-Abstract-Conference.html>.

YAO, S.; ZHAO, J.; YU, D.; DU, N.; SHAFRAN, I.; NARASIMHAN, K.; CAO, Y. ReAct: Synergizing reasoning and acting in language models. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2023. Disponível em: <<https://arxiv.org/abs/2210.03629>>.

YU, T.; ZHANG, R.; YANG, K.; YASUNAGA, M.; WANG, D.; LI, Z.; MA, J.; LI, I.; YAO, Q.; ROMAN, S. et al. Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. Brussels, Belgium: Association for Computational Linguistics, 2018. p. 3911–3921. Disponível em: <<https://aclanthology.org/D18-1425/>>.

ZHANG, Y.; WEI, C.; HE, Z.; YU, W. GeoGPT: An assistant for understanding and processing geospatial tasks. *International Journal of Applied Earth Observation and Geoinformation*, v. 131, 2024. Art. 103976. Disponível em: <<https://doi.org/10.1016/j.jag.2024.103976>>.

ZHAO, A.; HUANG, D.; XU, Q.; LIN, M.; LIU, Y.-J.; HUANG, G. ExpeL: LLM agents are experiential learners. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Association for the Advancement of Artificial Intelligence, 2024. v. 38, n. 17, p. 19632–19642. Disponível em: <<https://ojs.aaai.org/index.php/AAAI/article/view/29936>>.

APÊNDICE A – DATASET DE AVALIAÇÃO

Este apêndice documenta o *dataset* de avaliação da Seção 4.3, com o manual de anotação que define o gabarito, as 310 consultas com as leituras aceitas, o mapeamento das consultas aos requisitos, o registro da auditoria e as tabelas de estrutura, composição e concordância dos conjuntos. O arquivo `data/dataset.json` do repositório (Apêndice C) guarda as mesmas informações em formato legível por máquina. As listagens deste apêndice são geradas das mesmas fontes que produzem esse arquivo (`manual_cases.py` e o gerador da camada G), sem transcrição manual.

Como ler as entradas.

Cada consulta traz o identificador, as categorias (Seção 4.3), o texto exatamente como é enviado ao modelo e as **leituras aceitas** do gabarito, na forma canônica da ferramenta. A notação segue o princípio P3 do manual (Seção A.1). Nela, “**A** ou **B**” indica valor alternativo, e “(opcional)” indica campo que pode faltar sem erro, mas que, se presente, precisa ter o valor indicado. A forma “aceita-se também `city` no lugar de `state`” indica leitura estrutural alternativa. As expressões de tempo relativo aparecem pelo nome da regra (“ano corrente”, “semana passada”) e são resolvidas na data de referência da execução, segundo o Quadro 7. Na camada P, uma nota registra a linha de origem no arquivo do protótipo. Nas camadas P e N, a nota registra também, quando há, a justificativa das leituras alternativas.

Escopo do gabarito.

O gabarito descreve os **parâmetros** que a consulta deve produzir. A recuperação de produtos fica fora do escopo do trabalho (Seção 1.6).

A.1 Manual de anotação

O gabarito de cada consulta foi construído segundo as regras abaixo. Elas são a referência para a redação e a revisão das consultas, para a auditoria automática e para a anotação independente descritas na Seção A.14; qualquer anotação que as contrarie é considerada erro do gabarito, e não do modelo.

Princípios

- P1. Evidência explícita.** O gabarito contém somente parâmetros para os quais existe um trecho da consulta que os justifica. Nada é inferido além do que o texto diz (“cartas de Manaus” não implica `state = "Amazonas"`).
- P2. Forma canônica.** Todo valor é escrito na forma canônica da ferramenta `buscar_catalogo`, com os enumerados exatamente como no *schema*, os estados e municípios por extenso e com acentos, e as datas em ISO 8601.
- P3. Leituras múltiplas explícitas.** Quando a consulta admite mais de uma leitura razoável e nem o texto nem a descrição da ferramenta desempatam, o gabarito lista todas as leituras aceitas, sendo a primeira a preferencial. Há três mecanismos, o *valor alternativo* (o campo aceita mais de um valor), o *campo opcional* (pode faltar, mas, se aparecer, precisa ter o valor indicado) e a *leitura estrutural alternativa* (o mesmo trecho pode ocupar campos diferentes, como estado ou município).
- P4. Fora do domínio.** Consultas sem intenção de busca no acervo cartográfico brasileiro têm como gabarito “não chamar a ferramenta”.
- P5. Consistência.** A mesma expressão recebe a mesma anotação em todo o *dataset*.
- P6. Casos observacionais.** Consultas cujo comportamento correto não é determinável a partir do texto (valor impossível de representar, comportamento esperado discutível) são executadas e reportadas, mas ficam fora das métricas principais. Consultas fora do domínio (P4) não são observacionais, pois o comportamento correto é determinado.

Regras por campo

keyword Código MI com seus sufixos, sem o prefixo “MI”; código INOM na grafia com hífen (grafias compactadas, como “sf22yd”, são normalizadas); nome próprio de carta quando precedido de “carta” ou “folha”. Se o nome da carta coincide com um município, aceita-se também `city`. Havendo dois códigos, aceita-se qualquer um deles, pois o *schema* comporta um só.

scale Escala explícita em qualquer grafia (“1:25.000”, “1:25000”, “25k”, “25 mil”). As convenções informadas na descrição da ferramenta valem como regra (“detalhada” → 1:25.000; “pequena escala” → 1:250.000). Expressões qualitativas não informadas ao modelo aceitam o conjunto de escalas que as satisfazem, como “grande escala” → 1:25.000 ou maior; “média escala” → 1:50.000 ou 1:100.000; “maior que 100k” → 1:50.000 ou maior. Com duas escalas explícitas, aceita-se qualquer uma.

productType Sinônimos informados na ferramenta (“topo” e “topográfica”; “orto” e “ortoimg”; “mdt”) e demais tipos pelo nome. “Cartas”, “mapas”, “produtos” e “folhas” sozinhos não definem tipo.

state, city Siglas e grafias sem acento são normalizadas. “Rio de Janeiro”, “São Paulo” e “rio” sem qualificador admitem as leituras estado ou município; siglas são sempre estado. Regiões (“sul”, “Nordeste”, “Amazônia Legal”) não são estados e não são anotadas, pois o *schema* não tem campo de região.

supplyArea Qualquer menção ao Centro de Geoinformação (“1º CGEO”, “1o cgeo”, “primeiro cgeo”, “dois cgeo”).

project Pelo nome ou pelos apelidos informados na ferramenta, com ou sem acento. A menção explícita a um projeto por um termo que o identifica sem ambiguidade no enumerado também vale como nome (“projeto rondonia” e “BCD de Rondônia”, sigla de Base Cartográfica Digital, para Base Cartográfica Digital de Rondônia). Expressão que designa o projeto só pelo termo distintivo do nome, sem a palavra “projeto”, sem sigla do nome e sem apelido informado (“cartografia sistemática” para Mapeamento Sistemático), torna o campo opcional, porque a consulta sustenta a leitura, mas a ferramenta não a informa.

Períodos Verbo de publicação (“publicad-”) decide **publicationPeriod**; verbo de criação (“criad-”, “feit-”, “elaborad-”, “produzid-”) decide **creationPeriod**; sem verbo que desempate, a leitura preferencial é **publicationPeriod** e **creationPeriod** é leitura estrutural alternativa, com o mesmo intervalo. O intervalo é resolvido com a data de referência da execução, a mesma informada ao modelo, segundo o Quadro 7.

Ordenação “Mais recente(s)”, “último(s)” → **DESC**; “mais antiga(s)”, “primeiro(s)”, “ordem cronológica” → **ASC**. Pista de criação ligada à ordenação (“primeiro mapeamento feito”, “última atualização”, “criadas mais recentemente”) → **creationDate**; pista de publicação (“últimas publicações”, “última carta publicada”) → **publicationDate**; sem pista, aceita-se qualquer dos dois campos. Número explícito → **limit**; singular sem número (“a carta mais recente”) → **limit = 1** opcional; plural sem número → sem **limit**. Ordenação nunca é anotada por padrão.

Consultas fora do domínio

A ferramenta não deve ser chamada quando a consulta trata de outro assunto (clima, preço, ficção), pede território fora do Brasil ou fora da Terra, ou não tem intenção de busca. Essas consultas formam a categoria F (fora do domínio) e entram nas métricas principais. A resposta é correta quando a ferramenta não é chamada. Consultas com

Quadro 7 – Leituras aceitas para as expressões de tempo relativo (D = data de referência da execução)

Expressão	Leituras aceitas (a primeira é a preferencial)
esse ano / este ano / deste ano	ano inteiro; 1º de janeiro até D
ano passado	ano anterior inteiro
2 anos atrás	o ano de dois anos antes, inteiro; D menos 2 anos até D
mês passado	mês anterior inteiro
este mês / deste mês	dia 1 até D; mês inteiro
semana passada	D-7 até D-1; D-7 até D; semana-calendário anterior (segunda a domingo)
esta semana / nesta semana	segunda-feira até D; segunda a domingo
hoje	D a D
últimos 3 (6) meses	D-90 (180) dias até D; mesmo dia, 3 (6) meses antes, até D
últimos 5 anos	D menos 5 anos até D; 1º de janeiro do ano-5 até D
desde AAAA	AAAA-01-01 até D; AAAA-01-01 sem limite final
depois de AAAA	início em AAAA-01-01 ou (AAAA+1)-01-01; fim em D ou sem limite final
antes de AAAA	sem limite inicial até (AAAA-1)-12-31
primeiro trimestre (deste ano)	janeiro a março do ano de D
segundo semestre do ano passado	julho a dezembro do ano anterior
último trimestre do ano passado	outubro a dezembro do ano anterior
trimestre passado	trimestre-calendário anterior ao de D

Fonte: Elaborado pelos autores. Implementado em `relative_time.py` do repositório.

valor impossível de representar (“escala 1:10.000.000”, “estado 42”) ou cujo comportamento esperado é discutível (“cartas do futuro”, “cartas topo no oceano atlântico”) são observacionais.

Rastreabilidade

Cada caso registra a origem. Na camada P, a fonte é o arquivo de testes do protótipo (`backend/evaluation/test-cases.ts`), com a linha da consulta; a anotação original da equipe do 1º CGEO é mantida como leitura preferencial, e as leituras alternativas acrescentadas seguem este manual. Na camada N, a consulta foi redigida pelos autores, e a justificativa de cada leitura alternativa fica registrada em nota. Na camada G, a consulta foi gerada pelo *script* gerador (semente 42), que registra a função geradora e o modelo de frase; o gabarito é conhecido por construção.

Procedimento de auditoria

1. **Checagens automáticas (pfc-auditar).** Procuram consultas duplicadas ou contraditórias, conferem a validade de enumerados e campos, resolvem todas as expressões de tempo em datas diversas e aplicam um anotador baseado em regras, independente do gabarito, que localiza na consulta o trecho que justifica cada campo e aponta campo anotado sem evidência, evidência sem campo anotado e valor divergente.
2. **Anotação independente às cegas:** cada consulta é anotada novamente, sem acesso ao gabarito, a partir apenas deste manual e da definição da ferramenta. A concordância é medida em rigor crescente, na decisão (chamar, não chamar ou observacional, com kappa de Cohen), nas leituras compatíveis nos dois sentidos, na leitura preferencial idêntica, na presença e no valor de cada campo e na detecção de ambiguidade, também com kappa de Cohen.
3. **Adjudicação:** cada consulta com divergência em qualquer das medidas recebe uma decisão registrada (gabarito mantido, corrigido ou ampliado com leitura alternativa), com justificativa por referência a este manual e com o gabarito anterior à decisão, a partir do qual a concordância anterior à adjudicação é recalculada.
4. O processo se repete até não restar divergência sem decisão.
5. **Revisão humana de amostra:** uma amostra estratificada por origem (40 consultas, semente 42) é conferida por uma pessoa, que marca se concorda com as leituras aceitas.

Extensões para os lotes 1 e 2

Os lotes (Seção 4.3.4) cobrem situações que as 310 consultas não tinham. As regras abaixo estendem o manual sem alterar nenhuma anotação das 310.

Consulta subespecificada (categoria E). A consulta pede produtos do acervo, mas não traz nenhum critério representável no *schema* (“quero ver as cartas do acervo”, “cartas do Nordeste”, “mapas para uma trilha”). O gabarito não tem parâmetros e aceita duas respostas, buscar sem filtros ou não buscar (pedir esclarecimento ou recusar). Uma chamada com qualquer parâmetro é erro. Difere de F porque há intenção de busca no acervo (“me ajuda” e “quero um mapa bonito” continuam F) e da categoria S porque não há nenhum critério (“ortoimagens” é consulta simples e exige a busca).

Tempo relativo parametrizado. As regras do Quadro 7 valem para qualquer quantidade e qualquer ano. Os casos são “últimos N meses” ($D-30N$ dias até D ; mesmo

dia, N meses antes, até D); “últimos N anos” (D menos N anos até D ; 1º de janeiro do ano- N até D); “últimos N dias” ($D-N$ até D ; $D-(N-1)$ até D); “desde” e “a partir de AAAA”; “depois de” e “após AAAA”; “antes de” e “anteriores a AAAA”. Ano isolado (“em AAAA”, “de AAAA”) e intervalo de anos (“entre AAAA e BBBB”) têm leitura única, do primeiro ao último dia.

Municípios e UF. Qualquer município da lista oficial do IBGE é **city**; a sigla da UF junto ao município (“Campinas, SP”) anota também **state**. O lote não usa municípios homônimos de UF.

Nomes de folha reais. Nomes de folha do BDGEx precedidos de “carta” ou “folha” são **keyword**; quando coincidem com o nome de um município, vale a leitura estrutural **city**.

Armadilhas de vocabulário. “Carta”, “mapa”, “folha”, “escala” e “projeto” em outro sentido (“carta de vinhos”, “mapa astral”, “folha de pagamento”, “escala de plantão”, “projeto de lei”) não pedem produto cartográfico e são da categoria F.

A.2 Consultas do protótipo (P01–P22)

As 22 consultas do arquivo de testes do protótipo do 1º CGEO (`backend/evaluation/test-cases.ts`) aparecem na ordem do arquivo. A anotação original da equipe do 1º CGEO é a leitura preferencial, e as leituras alternativas acrescentadas seguem o manual. No arquivo original, os períodos relativos estavam fixados em datas calculadas para o início de 2025 (por exemplo, 2024-10-01 a 2024-12-31 para o “último trimestre do ano passado” de P15). Aqui, eles são expressos pelas regras nomeadas do Quadro 7.

ID	P01
Categorias	M · C
Consulta	<i>“preciso da carta MI 2965-2-NE do segundo cgeo”</i>
Leituras aceitas	keyword: "2965-2-NE" supplyArea: "2º Centro de Geoinformação"
Nota	origem: test-cases.ts do protótipo, linha 6

ID	P02
Categorias	M · C
Consulta	<i>“folha MI 2866-3 em escala 50k”</i>
Leituras aceitas	keyword: "2866-3" scale: "1:50.000"
Nota	origem: test-cases.ts do protótipo, linha 16

ID	P03
Categorias	M · C · A
Consulta	<i>“MI 2901 do projeto olimpíadas”</i>
Leituras aceitas	keyword: "2901" project: "Olimpíadas Rio 2016"
Nota	origem: test-cases.ts do protótipo, linha 26

ID	P04
Categorias	M · C · A
Consulta	<i>“carta 530 em pequena escala”</i>
Leituras aceitas	keyword: "530" scale: "1:250.000"
Nota	origem: test-cases.ts do protótipo, linha 36

ID	P05
Categorias	M · C · T
Consulta	<i>“buscar folha SF-22-Y-D-II-4 do RS publicada esse ano”</i>
Leituras aceitas	keyword: "SF-22-Y-D-II-4" state: "Rio Grande do Sul" publicationPeriod: ano corrente
Nota	origem: test-cases.ts do protótipo, linha 48

ID	P06
Categorias	M · C · A
Consulta	<i>“carta SF-22-Y-D do tipo ortoimg”</i>
Leituras aceitas	keyword: "SF-22-Y-D" productType: "SCN Carta Ortoimagem"
Nota	origem: test-cases.ts do protótipo, linha 62

ID	P07
Categorias	M · C · A
Consulta	<i>“inom SF-22-Y-D-II-4-SE criado pelo primeiro cgeo”</i>
Leituras aceitas	keyword: "SF-22-Y-D-II-4-SE" supplyArea: "1° Centro de Geoinformação"
Nota	origem: test-cases.ts do protótipo, linha 72

ID	P08
Categorias	C
Consulta	<i>“carta topográfica Passo da Seringueira em 1:25.000”</i>
Leituras aceitas	keyword: "Passo da Seringueira" scale: "1:25.000" productType: "SCN Carta Topográfica Matricial"
Nota	origem: test-cases.ts do protótipo, linha 84

ID	P09
Categorias	C
Consulta	<i>“folha Porto Velho publicada em 2024”</i>
Leituras aceitas	keyword: "Porto Velho" publicationPeriod: 2024-01-01 a 2024-12-31 aceita-se também city no lugar de keyword
Nota	origem: test-cases.ts do protótipo, linha 95; nome de carta coincide com município: aceita-se também city

ID	P10
Categorias	C · A
Consulta	<i>“carta Vale do Guaporé do projeto rondonia”</i>
Leituras aceitas	keyword: "Vale do Guaporé" project: "Base Cartográfica Digital de Rondônia"
Nota	origem: test-cases.ts do protótipo, linha 108

ID	P11
Categorias	M · C · A
Consulta	<i>“MI 2965-2-NE e SF-22-Y-D do terceiro cgeo em grande escala”</i>
Leituras aceitas	keyword: "2965-2-NE" ou "SF-22-Y-D" supplyArea: "3° Centro de Geoinformação" scale: "1:25.000" ou "1:10.000" ou "1:5.000" ou "1:2.000" ou "1:1.000"
Nota	origem: test-cases.ts do protótipo, linha 120; dois códigos (o schema comporta um): aceita-se qualquer um; 'grande escala' aceita as escalas grandes

ID	P12
Categorias	M · C · T · A
Consulta	<i>“cartas do tipo topo com MI 530 ou SF-22 publicadas esse ano”</i>
Leituras aceitas	keyword: "530" ou "SF-22" productType: "SCN Carta Topográfica Matricial" publicationPeriod: ano corrente
Nota	origem: test-cases.ts do protótipo, linha 131; dois códigos: aceita-se qualquer um

ID	P13
Categorias	C · A
Consulta	<i>“todas as cartas em escala maior que 100k do rio grande do sul”</i>
Leituras aceitas	state: "Rio Grande do Sul" scale: "1:25.000" ou "1:50.000" ou "1:10.000" ou "1:5.000" ou "1:2.000" ou "1:1.000"
Nota	origem: test-cases.ts do protótipo, linha 147; 'maior que 100k' aceita qualquer escala maior que 1:100.000

ID	P14
Categorias	C · A
Consulta	<i>“mapeamento detalhado (25k ou 50k) de brasilia”</i>
Leituras aceitas	scale: "1:25.000" ou "1:50.000" city: "Brasília"
Nota	origem: test-cases.ts do protótipo, linha 156; duas escalas explícitas: aceita-se qualquer uma

ID	P15
Categorias	T · C · A
Consulta	<i>“cartas criadas no último trimestre do ano passado do segundo cgeo”</i>
Leituras aceitas	supplyArea: "2° Centro de Geoinformação" creationPeriod: 4º trimestre do ano anterior
Nota	origem: test-cases.ts do protótipo, linha 167

ID	P16
Categorias	T · C · A
Consulta	<i>“produtos da semana passada do terceiro cgeo”</i>
Leituras aceitas	supplyArea: "3º Centro de Geoinformação" publicationPeriod: semana passada aceita-se também creationPeriod no lugar de publicationPeriod
Nota	origem: test-cases.ts do protótipo, linha 179; sem verbo que decida publicação ou criação

ID	P17
Categorias	C · A
Consulta	<i>“cartas do mapeamento sistematico em goias”</i>
Leituras aceitas	project: "Mapeamento Sistemático" state: "Goiás"
Nota	origem: test-cases.ts do protótipo, linha 193

ID	P18
Categorias	C · A
Consulta	<i>“produtos da copa das confederacoes em fortaleza”</i>
Leituras aceitas	project: "Copa das Confederações" city: "Fortaleza"
Nota	origem: test-cases.ts do protótipo, linha 202

ID	P19
Categorias	O · C · A
Consulta	<i>“primeiro mapeamento feito em cuiaba”</i>
Leituras aceitas	city: "Cuiabá" sortField: "creationDate" sortDirection: "ASC" limit: 1 (opcional)
Nota	origem: test-cases.ts do protótipo, linha 213; singular sem número: limit 1 opcional

ID	P20
Categorias	O · C · A
Consulta	<i>“ultima atualizacao do para”</i>
Leituras aceitas	state: "Pará" sortField: "creationDate" sortDirection: "DESC" limit: 1 (opcional)
Nota	origem: test-cases.ts do protótipo, linha 223; singular sem número: limit 1 opcional

ID	P21
Categorias	O · T · C · A
Consulta	<i>“preciso das 5 cartas mais antigas do tipo ortoimg em escala detalhada do terceiro cgeo em pernambuco publicadas depois de 2020”</i>
Leituras aceitas	limit: 5 productType: "SCN Carta Ortoimagem" scale: "1:25.000" supplyArea: "3° Centro de Geoinformação" state: "Pernambuco" publicationPeriod: depois de 2020 sortField: "creationDate" ou "publicationDate" sortDirection: "ASC"
Nota	origem: test-cases.ts do protótipo, linha 235; 'mais antigas' sem pista ligada à ordenação: aceita-se publicationDate além do creationDate original

ID	P22
Categorias	M · O · T · C
Consulta	<i>“MI 2901 ou SF-22 do quarto cgeo no sudeste em pequena escala criado entre 2022 e 2023 ordem cronologica”</i>
Leituras aceitas	keyword: "2901" ou "SF-22" supplyArea: "4° Centro de Geoinformação" scale: "1:250.000" creationPeriod: 2022-01-01 a 2023-12-31 sortField: "creationDate" ou "publicationDate" sortDirection: "ASC"
Nota	origem: test-cases.ts do protótipo, linha 253; dois códigos; 'sudeste' é região (nada a anotar); ordem cronológica sem pista ligada

A.3 Consultas redigidas pelos autores (N01–N40)

Os autores redigiram estas consultas para preencher lacunas de distribuição, em especial a categoria Simples, ausente na camada P. Elas exercitam também as ambiguidades previstas no manual (estado ou capital, ordenação sem pista, regiões e grafias informais de escala, como “25k” e “cem k”) e a fronteira do domínio. N36 e N37 estão fora do domínio (categoria F), e N38 a N40 são observacionais.

ID	N01
Categorias	S
Consulta	<i>“cartas de São Paulo”</i>
Leituras aceitas	state: "São Paulo" aceita-se também city no lugar de state
Nota	'São Paulo' sem qualificador: estado ou capital

ID	N02
Categorias	S
Consulta	<i>“produtos em escala 1:50.000”</i>
Leituras aceitas	scale: "1:50.000"

ID	N03
Categorias	S
Consulta	<i>“ortoimagens”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem"

ID	N04
Categorias	S · A
Consulta	<i>“mapas do rj”</i>
Leituras aceitas	state: "Rio de Janeiro"

ID	N05
Categorias	S · A
Consulta	<i>“carta 25k”</i>
Leituras aceitas	scale: "1:25.000"

ID	N06
Categorias	S
Consulta	<i>“folha SF-22-Y-D”</i>
Leituras aceitas	keyword: "SF-22-Y-D"

ID	N07
Categorias	S · A
Consulta	<i>“modelos digitais de terreno”</i>
Leituras aceitas	productType: "MDT - RAM"

ID	N08
Categorias	S · A
Consulta	<i>“cartas topográficas”</i>
Leituras aceitas	productType: "SCN Carta Topográfica Matricial"

ID	N09
Categorias	S
Consulta	<i>“produtos do Amazonas”</i>
Leituras aceitas	state: "Amazonas"

ID	N10
Categorias	S · A
Consulta	<i>“mi 2901”</i>
Leituras aceitas	keyword: "2901"

ID	N11
Categorias	C
Consulta	<i>“cartas do 1º CGEO em Minas Gerais”</i>
Leituras aceitas	supplyArea: "1º Centro de Geoinformação" state: "Minas Gerais"

ID	N12
Categorias	C
Consulta	<i>“ortoimagens de Manaus em 1:50.000”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem" city: "Manaus" scale: "1:50.000"

ID	N13
Categorias	C · A
Consulta	<i>“mdt do para em 25k”</i>
Leituras aceitas	productType: "MDT - RAM" state: "Pará" scale: "1:25.000"

ID	N14
Categorias	M · C
Consulta	<i>“folha 2965-2 do Rio Grande do Sul”</i>
Leituras aceitas	keyword: "2965-2" state: "Rio Grande do Sul"

ID	N15
Categorias	M · C
Consulta	<i>“INOM SG-22-X-A”</i>
Leituras aceitas	keyword: "SG-22-X-A"

ID	N16
Categorias	M · C · T
Consulta	<i>“carta MI 3010 publicada em 2023”</i>
Leituras aceitas	keyword: "3010" publicationPeriod: 2023-01-01 a 2023-12-31

ID	N17
Categorias	T · A
Consulta	<i>“produtos publicados nos últimos 3 meses”</i>
Leituras aceitas	publicationPeriod: últimos 3 meses

ID	N18
Categorias	T · C
Consulta	<i>“cartas do ano passado em Roraima”</i>
Leituras aceitas	state: "Roraima" publicationPeriod: ano anterior, inteiro aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N19
Categorias	T · A
Consulta	<i>“atualizações deste mês”</i>
Leituras aceitas	publicationPeriod: mês corrente aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N20
Categorias	T · C · A
Consulta	<i>“cartas dos últimos 5 anos em escala 100k”</i>
Leituras aceitas	scale: "1:100.000" publicationPeriod: últimos 5 anos aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N21
Categorias	T · A
Consulta	<i>“qualquer coisa de hoje”</i>
Leituras aceitas	publicationPeriod: dia da execução aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N22
Categorias	T · C · A
Consulta	<i>“ortoimagens de 2 anos atrás”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem" publicationPeriod: ano de dois anos antes aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N23
Categorias	T · C · A
Consulta	<i>“produtos do trimestre passado do 4º CGEO”</i>
Leituras aceitas	supplyArea: "4º Centro de Geoinformação" publicationPeriod: trimestre anterior aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida publicação ou criação

ID	N24
Categorias	O · C
Consulta	<i>“3 cartas mais recentes de Curitiba”</i>
Leituras aceitas	city: "Curitiba" limit: 3 sortField: "publicationDate" ou "creationDate" sortDirection: "DESC"
Nota	'mais recentes' sem pista: aceita-se publicationDate ou creationDate

ID	N25
Categorias	O · C
Consulta	<i>“10 primeiras ortoimagens do Nordeste”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem" limit: 10 sortField: "publicationDate" ou "creationDate" sortDirection: "ASC"
Nota	'Nordeste' é região (nada a anotar); 'primeiras' sem pista

ID	N26
Categorias	O · C · A
Consulta	<i>“mais antigas em rondonia”</i>
Leituras aceitas	state: "Rondônia" sortField: "publicationDate" ou "creationDate" sortDirection: "ASC"
Nota	'mais antigas' sem pista

ID	N27
Categorias	O · C
Consulta	<i>“últimas 5 publicações”</i>
Leituras aceitas	limit: 5 sortField: "publicationDate" sortDirection: "DESC"

ID	N28
Categorias	O · M · C
Consulta	<i>“carta MI 2901 mais recente”</i>
Leituras aceitas	keyword: "2901" sortField: "publicationDate" ou "creationDate" sortDirection: "DESC" limit: 1 (opcional)
Nota	singular sem número: limit 1 opcional; 'mais recente' sem pista

ID	N29
Categorias	O · C · T
Consulta	<i>“três produtos mais antigos deste ano”</i>
Leituras aceitas	limit: 3 publicationPeriod: ano corrente sortField: "publicationDate" ou "creationDate" sortDirection: "ASC" aceita-se também creationPeriod no lugar de publicationPeriod
Nota	sem verbo que decida o período; 'mais antigos' sem pista

ID	N30
Categorias	A · C
Consulta	<i>“cartas topo do primeiro cgeo”</i>
Leituras aceitas	productType: "SCN Carta Topográfica Matricial" supplyArea: "1° Centro de Geoinformação"

ID	N31
Categorias	A · S
Consulta	<i>“orto banda p”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem Banda P Pol HH"

ID	N32
Categorias	A · C
Consulta	<i>“mapas do rio em cem k”</i>
Leituras aceitas	state: "Rio de Janeiro" scale: "1:100.000" aceita-se também city no lugar de state
Nota	'rio' é ambíguo entre o estado e a capital

ID	N33
Categorias	A · C
Consulta	<i>“cartografia sistematica sp”</i>
Leituras aceitas	project: "Mapeamento Sistemático" (opcional) state: "São Paulo"
Nota	'cartografia sistemática' designa o programa pelo termo distintivo do nome, sem ser nome nem apelido informado na ferramenta: project é opcional (regra de project; adjudicação)

ID	N34
Categorias	A · C
Consulta	<i>“ortos da amazonia legal”</i>
Leituras aceitas	productType: "SCN Carta Ortoimagem"
Nota	'Amazônia Legal' é região (nove estados), não estado: nada a anotar para ela

ID	N35
Categorias	A · M · C
Consulta	<i>“sf22yd do dois cgeo”</i>
Leituras aceitas	keyword: "SF-22-Y-D" supplyArea: "2° Centro de Geoinformação"

ID	N36
Categorias	F
Consulta	<i>“cartas fora do brasil”</i>
Leituras aceitas	não chamar a ferramenta (fora do território brasileiro, P4)

ID	N37
Categorias	F
Consulta	<i>“quero um mapa bonito”</i>
Leituras aceitas	não chamar a ferramenta (sem critério de busca, P4)

ID	N38
Categorias	S · A
Consulta	<i>“escala 1:10.000.000”</i>
Leituras aceitas	não chamar a ferramenta (observacional, P6: escala fora do enumerado da ferramenta)

ID	N39
Categorias	C · A
Consulta	<i>“cartas topo no oceano atlântico”</i>
Leituras aceitas	productType: "SCN Carta Topográfica Matricial" caso observacional (P6): executado e reportado, fora das métricas principais
Nota	área não terrestre: comportamento esperado discutível

ID	N40
Categorias	C · T
Consulta	<i>“cartas do futuro (ano 2050)”</i>
Leituras aceitas	publicationPeriod: 2050-01-01 a 2050-12-31 aceita-se também creationPeriod no lugar de publicationPeriod caso observacional (P6): executado e reportado, fora das métricas principais
Nota	data futura: comportamento esperado discutível

A.4 Geração programática da camada G

O *script* `scripts/generate_dataset_paper.py` do repositório (Apêndice C) produz as 248 consultas da camada G a partir de catálogos fechados do domínio. São as 27

unidades da federação (com preposição, grafias usuais e, exceto para Sergipe, sigla), 12 municípios de referência sem homônimo entre as UFs, as 8 escalas do SCN (com apelidos como “25k”, “25 mil” e as convenções “detalhada” e “pequena escala”), os 9 tipos de produto e os 9 projetos institucionais aceitos pela ferramenta, os 5 CGEOs, 12 códigos MI e 10 códigos INOM, 15 expressões de tempo (14 relativas e o intervalo absoluto “entre 2022 e 2023”) e os padrões de ordenação. Oito funções geradoras, uma por família, combinam esses catálogos em modelos de frase do português corrente.

Três propriedades tornam a camada auditável. A geração é **determinística**, porque um único gerador pseudoaleatório, com semente 42, é consumido em ordem fixa, e a mesma versão do *script* produz sempre as mesmas consultas. O gabarito é conhecido **por construção**, porque a frase é montada a partir dos parâmetros que deve produzir, e cada consulta registra no *dataset* a função geradora e o modelo de frase que a originaram. **Nenhuma consulta se repete** depois da normalização de caixa, acentos e pontuação, dentro da camada e em relação às camadas P e N. Valem as convenções do manual, como as leituras estado ou município para “São Paulo” e “Rio de Janeiro” por extenso e os dois campos de período nas frases sem verbo de publicação ou criação.

As seções seguintes listam as 248 consultas por família. Os identificadores seguem o padrão $G\{\text{família}\}\{\text{sequência}\}$, em que a família é S (simples), C (compostas), M (código MI/INOM), T (tempo relativo), O (ordenação), A (informais), P (amplas, com muitos produtos) ou F (fronteira do domínio).

A.5 Consultas simples geradas por *templates* (G-S)

Total desta família: **61 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GS001	S	cartas do Acre	state: "Acre"
GS002	S · A	cartas de AL	state: "Alagoas"
GS003	S · A	cartas do AP	state: "Amapá"
GS004	S	cartas do Amazonas	state: "Amazonas"
GS005	S · A	cartas da bahia	state: "Bahia"
GS006	S · A	cartas do CE	state: "Ceará"
GS007	S · A	cartas do DF	state: "Distrito Federal"
GS008	S · A	cartas do ES	state: "Espírito Santo"
GS009	S	cartas de Goiás	state: "Goiás"
GS010	S · A	cartas do MA	state: "Maranhão"
GS011	S	cartas de Mato Grosso	state: "Mato Grosso"
GS012	S	cartas de Mato Grosso do Sul	state: "Mato Grosso do Sul"
GS013	S · A	cartas de MG	state: "Minas Gerais"
GS014	S	cartas do Pará	state: "Pará"

ID	Cat.	Consulta	Leituras aceitas
GS015	S · A	cartas da paraíba	state: "Paraíba"
GS016	S · A	produtos na escala 1:1000	scale: "1:1.000"
GS017	S · A	produtos na escala 1:2000	scale: "1:2.000"
GS018	S · A	produtos na escala 1:5000	scale: "1:5.000"
GS019	S · A	produtos na escala 1:10000	scale: "1:10.000"
GS020	S · A	produtos na escala 1:25000	scale: "1:25.000"
GS021	S · A	produtos na escala de 50 mil	scale: "1:50.000"
GS022	S · A	produtos na escala de 100 mil	scale: "1:100.000"
GS023	S · A	produtos em 250k	scale: "1:250.000"
GS024	S · A	cartas topográficas disponíveis	productType: "SCN Carta Topográfica Matricial"
GS025	S · A	cartas vetoriais disponíveis	productType: "SCN Carta Topográfica Vetorial"
GS026	S · A	ortoimagens disponíveis	productType: "SCN Carta Ortoimagem"
GS027	S · A	ortoimagens banda P HH disponíveis	productType: "SCN Carta Ortoimagem Banda P Pol HH"
GS028	S · A	ortoimagens banda X HH disponíveis	productType: "SCN Carta Ortoimagem Banda X Pol HH"
GS029	S · A	MDTs disponíveis	productType: "MDT — RAM"
GS030	S · A	MDSs disponíveis	productType: "MDS — RAM"
GS031	S · A	cartas CIRC disponíveis	productType: "CIRC"
GS032	S · A	mapas temáticos disponíveis	productType: "Cartas Temáticas Não SCN"
GS033	S · A	produtos do primeiro cgeo	supplyArea: "1° Centro de Geoinformação"
GS034	S · A	produtos do 2o cgeo	supplyArea: "2° Centro de Geoinformação"
GS035	S · A	produtos do 3o cgeo	supplyArea: "3° Centro de Geoinformação"
GS036	S · A	produtos do quarto cgeo	supplyArea: "4° Centro de Geoinformação"
GS037	S · A	produtos do 5º CGEO	supplyArea: "5° Centro de Geoinformação"
GS038	S	cartas de Brasília	city: "Brasília"
GS039	S	cartas de Manaus	city: "Manaus"
GS040	S	cartas de Porto Velho	city: "Porto Velho"
GS041	S	cartas de Cuiabá	city: "Cuiabá"
GS042	S	cartas de Fortaleza	city: "Fortaleza"
GS043	S	cartas de Salvador	city: "Salvador"
GS044	S	cartas de Belo Horizonte	city: "Belo Horizonte"
GS045	S	cartas de Curitiba	city: "Curitiba"
GS046	S	cartas de Porto Alegre	city: "Porto Alegre"
GS047	S	cartas de Recife	city: "Recife"
GS048	S · M	carta MI 2965-2-NE	keyword: "2965-2-NE"
GS049	S · M	carta MI 2866-3	keyword: "2866-3"

ID	Cat.	Consulta	Leituras aceitas
GS050	S · M	carta MI 2901	keyword: "2901"
GS051	S · M	carta MI 530	keyword: "530"
GS052	S · M	carta MI 3010	keyword: "3010"
GS053	S · M	carta MI 2965	keyword: "2965"
GS054	S · M	carta MI 2866-2-SO	keyword: "2866-2-SO"
GS055	S · M	carta MI 2901-4-NE	keyword: "2901-4-NE"
GS056	S · M	folha INOM SF-22-Y-D	keyword: "SF-22-Y-D"
GS057	S · M	folha INOM SF-22-Y-D-II	keyword: "SF-22-Y-D-II"
GS058	S · M	folha INOM SF-22-Y-D-II-4	keyword: "SF-22-Y-D-II-4"
GS059	S · M	folha INOM SF-22-Y-D-II-4-SE	keyword: "SF-22-Y-D-II-4-SE"
GS060	S · M	folha INOM SG-22-X-A	keyword: "SG-22-X-A"
GS061	S · M	folha INOM SF-23-V-C	keyword: "SF-23-V-C"

A.6 Consultas compostas geradas por *templates* (G-C)

Total desta família: **55 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GC001	C · A	cartas do amapá na escala 1:2.000	state: "Amapá"; scale: "1:2.000"
GC002	C · A	cartas de Mato Grosso do Sul em 25k	state: "Mato Grosso do Sul"; scale: "1:25.000"
GC003	C · A	cartas de santa catarina na escala 1:2.000	state: "Santa Catarina"; scale: "1:2.000"
GC004	C · A	cartas do Amapá na escala de 25 mil	state: "Amapá"; scale: "1:25.000"
GC005	C · A	cartas do RJ na escala 1:2000	state: "Rio de Janeiro"; scale: "1:2.000"
GC006	C · A	cartas de RO em 25k	state: "Rondônia"; scale: "1:25.000"
GC007	C · A	cartas do ES na escala 1:100000	state: "Espírito Santo"; scale: "1:100.000"
GC008	C · A	cartas da Paraíba em 50k	state: "Paraíba"; scale: "1:50.000"
GC009	C · A	cartas de mato grosso do sul na escala de 10 mil	state: "Mato Grosso do Sul"; scale: "1:10.000"
GC010	C · A	cartas de Goiás na escala 1:2000	state: "Goiás"; scale: "1:2.000"
GC011	C · A	cartas do Piauí na escala 1:10000	state: "Piauí"; scale: "1:10.000"
GC012	C · A	cartas da paraíba na escala 1:25000	state: "Paraíba"; scale: "1:25.000"
GC013	C · A	cartas de rondônia na escala 1:1000	state: "Rondônia"; scale: "1:1.000"
GC014	C · A	cartas do TO na escala 1:50000	state: "Tocantins"; scale: "1:50.000"
GC015	C · A	cartas de GO na escala de 10 mil	state: "Goiás"; scale: "1:10.000"
GC016	C · A	cartas de roraima na escala de 10 mil	state: "Roraima"; scale: "1:10.000"
GC017	C · A	cartas do paraná na escala 1:250000	state: "Paraná"; scale: "1:250.000"
GC018	C · A	cartas do Piauí em escala detalhada	state: "Piauí"; scale: "1:25.000"
GC019	C · A	cartas do rio de janeiro em 50k	state: "Rio de Janeiro"; scale: "1:50.000"; aceita-se também city no lugar de state

ID	Cat.	Consulta	Leituras aceitas
GC020	C · A	cartas da Bahia em 250k	state: "Bahia"; scale: "1:250.000"
GC021	C · A	cartas de SP na escala 1:2000	state: "São Paulo"; scale: "1:2.000"
GC022	C · A	cartas do RS na escala de 100 mil	state: "Rio Grande do Sul"; scale: "1:100.000"
GC023	C · A	cartas do amapá na escala de 100 mil	state: "Amapá"; scale: "1:100.000"
GC024	C · A	cartas da Paraíba em 25k	state: "Paraíba"; scale: "1:25.000"
GC025	C	cartas de Rondônia na escala 1:2.000	state: "Rondônia"; scale: "1:2.000"
GC026	C · A	cartas de São Paulo em 50k	state: "São Paulo"; scale: "1:50.000"; aceita-se também city no lugar de state
GC027	C · A	cartas do maranhão na escala 1:5.000	state: "Maranhão"; scale: "1:5.000"
GC028	C · A	cartas do Acre na escala 1:25000	state: "Acre"; scale: "1:25.000"
GC029	C · A	cartas de PE na escala 1:25000	state: "Pernambuco"; scale: "1:25.000"
GC030	C · A	cartas da bahia na escala 1:5000	state: "Bahia"; scale: "1:5.000"
GC031	C · A	mapas de Recife na escala 1:50000	city: "Recife"; scale: "1:50.000"
GC032	C	mapas de Brasília na escala 1:2.000	city: "Brasília"; scale: "1:2.000"
GC033	C · A	mapas de Fortaleza na escala 1:10000	city: "Fortaleza"; scale: "1:10.000"
GC034	C · A	mapas de Cuiabá na escala 1:2000	city: "Cuiabá"; scale: "1:2.000"
GC035	C · A	mapas de Belém em 250k	city: "Belém"; scale: "1:250.000"
GC036	C · A	mapas de Porto Alegre na escala 1:5000	city: "Porto Alegre"; scale: "1:5.000"
GC037	C · A	mapas de Goiânia na escala 1:250000	city: "Goiânia"; scale: "1:250.000"
GC038	C · A	mapas de Fortaleza em 100k	city: "Fortaleza"; scale: "1:100.000"
GC039	C · A	cartas temáticas de São Paulo	productType: "Cartas Temáticas Não SCN"; state: "São Paulo"; aceita-se também city no lugar de state
GC040	C · A	ortoimagens banda X HH de minas	productType: "SCN Carta Ortoimagem Banda X Pol HH"; state: "Minas Gerais"
GC041	C · A	cartas temáticas da PB	productType: "Cartas Temáticas Não SCN"; state: "Paraíba"
GC042	C · A	ortoimagens banda P HH do amapá	productType: "SCN Carta Ortoimagem Banda P Pol HH"; state: "Amapá"
GC043	C · A	cartas temáticas do Espírito Santo	productType: "Cartas Temáticas Não SCN"; state: "Espírito Santo"
GC044	C · A	cartas topográficas do Amapá	productType: "SCN Carta Topográfica Matricial"; state: "Amapá"
GC045	C · A	produtos do projeto copa das confederacoes no AP	project: "Copa das Confederações"; state: "Amapá"
GC046	C · A	produtos do projeto olimpíadas em PE	project: "Olimpíadas Rio 2016"; state: "Pernambuco"

ID	Cat.	Consulta	Leituras aceitas
GC047	C	produtos do projeto NGA-BECA no Distrito Federal	project: "NGA-BECA"; state: "Distrito Federal"
GC048	C · A	produtos do projeto beca no espírito santo	project: "NGA-BECA"; state: "Espírito Santo"
GC049	C · A	produtos do projeto copa das confederacoes no AM	project: "Copa das Confederações"; state: "Amazonas"
GC050	C · A	produtos do projeto BCD de Rondônia no Pará	project: "Base Cartográfica Digital de Rondônia"; state: "Pará"
GC051	C · A	cartas do 1º CGEO na escala 1:2.000	supplyArea: "1º Centro de Geoinformação"; scale: "1:2.000"
GC052	C · A	cartas do 3º cgeo na escala 1:2000	supplyArea: "3º Centro de Geoinformação"; scale: "1:2.000"
GC053	C · A	cartas do 2º cgeo em pequena escala	supplyArea: "2º Centro de Geoinformação"; scale: "1:250.000"
GC054	C · A	cartas do 2º CGEO na escala 1:25000	supplyArea: "2º Centro de Geoinformação"; scale: "1:25.000"
GC055	C · A	cartas do 1º CGEO em 250k	supplyArea: "1º Centro de Geoinformação"; scale: "1:250.000"

A.7 Consultas com código MI/INOM geradas por *templates* (G-M)

Total desta família: **28 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GM001	C · M	folha MI 2965-2-NE do Rio Grande do Sul	keyword: "2965-2-NE"; state: "Rio Grande do Sul"
GM002	C · M · A	folha MI 2866-3 do TO	keyword: "2866-3"; state: "Tocantins"
GM003	C · M · A	folha MI 2901 do AP	keyword: "2901"; state: "Amapá"
GM004	C · M · A	folha MI 530 do ceará	keyword: "530"; state: "Ceará"
GM005	C · M · A	folha MI 3010 do paraná	keyword: "3010"; state: "Paraná"
GM006	C · M · A	folha MI 2965 do distrito federal	keyword: "2965"; state: "Distrito Federal"
GM007	C · M · A	folha MI 2866-2-SO de AL	keyword: "2866-2-SO"; state: "Alagoas"
GM008	C · M · A	folha MI 2901-4-NE de MG	keyword: "2901-4-NE"; state: "Minas Gerais"

ID	Cat.	Consulta	Leituras aceitas
GM009	C · M · A	folha MI 531-1-NE de minas	keyword: "531-1-NE"; state: "Minas Gerais"
GM010	C · M	folha MI 2965-3 de Sergipe	keyword: "2965-3"; state: "Sergipe"
GM011	C · M · A	folha MI 2866-3-NO do maranhão	keyword: "2866-3-NO"; state: "Maranhão"
GM012	C · M	folha MI 3010-2-SE de Roraima	keyword: "3010-2-SE"; state: "Roraima"
GM013	C · M · A	INOM SF-22-Y-D do tipo temática	keyword: "SF-22-Y-D"; productType: "Cartas Temáticas Não SCN"
GM014	C · M · A	INOM SF-22-Y-D-II do tipo ortoimagem	keyword: "SF-22-Y-D-II"; productType: "SCN Carta Ortoimagem"
GM015	C · M · A	INOM SF-22-Y-D-II-4 do tipo banda X HH	keyword: "SF-22-Y-D-II-4"; productType: "SCN Carta Ortoimagem Banda X Pol HH"
GM016	C · M · A	INOM SF-22-Y-D-II-4-SE do tipo topográfica	keyword: "SF-22-Y-D-II-4-SE"; productType: "SCN Carta Topográfica Matricial"
GM017	C · M · A	INOM SG-22-X-A do tipo MDT	keyword: "SG-22-X-A"; productType: "MDT — RAM"
GM018	C · M · A	INOM SF-23-V-C do tipo topo	keyword: "SF-23-V-C"; productType: "SCN Carta Topográfica Matricial"
GM019	C · M · A	INOM SG-21-Z-B do tipo temática	keyword: "SG-21-Z-B"; productType: "Cartas Temáticas Não SCN"
GM020	C · M · A	INOM SH-22-W-A-III-1-NE do tipo topográfica	keyword: "SH-22-W-A-III-1-NE"; productType: "SCN Carta Topográfica Matricial"
GM021	C · M · A	INOM SG-22-Z-D-II-3 do tipo ortoimagem	keyword: "SG-22-Z-D-II-3"; productType: "SCN Carta Ortoimagem"
GM022	C · M · A	INOM SF-24-Y-A do tipo vetorial	keyword: "SF-24-Y-A"; productType: "SCN Carta Topográfica Vetorial"
GM023	C · M · A	MI 2866-2-SO produzido pelo 1 CGEO	keyword: "2866-2-SO"; supplyArea: "1° Centro de Geoinformação"
GM024	C · M · A	MI 2866-3 produzido pelo quinto cgeo	keyword: "2866-3"; supplyArea: "5° Centro de Geoinformação"
GM025	C · M · A	MI 2965-3 produzido pelo 3o cgeo	keyword: "2965-3"; supplyArea: "3° Centro de Geoinformação"
GM026	C · M · A	MI 530 produzido pelo 3o cgeo	keyword: "530"; supplyArea: "3° Centro de Geoinformação"
GM027	C · M · A	MI 2965-2-NE produzido pelo 3 CGEO	keyword: "2965-2-NE"; supplyArea: "3° Centro de Geoinformação"
GM028	C · M · A	MI 3010 produzido pelo segundo cgeo	keyword: "3010"; supplyArea: "2° Centro de Geoinformação"

A.8 Consultas com tempo relativo geradas por *templates* (G-T)

Total desta família: **41 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GT001	T	cartas publicadas esse ano	publicationPeriod: ano corrente
GT002	T	cartas publicadas no ano passado	publicationPeriod: ano anterior, inteiro
GT003	T	cartas publicadas no mês passado	publicationPeriod: mês anterior, inteiro
GT004	T	cartas publicadas na semana passada	publicationPeriod: semana passada
GT005	T	cartas publicadas nos últimos 3 meses	publicationPeriod: últimos 3 meses
GT006	T	cartas publicadas nos últimos 6 meses	publicationPeriod: últimos 6 meses
GT007	T	cartas publicadas nos últimos 5 anos	publicationPeriod: últimos 5 anos
GT008	T	cartas publicadas desde 2020	publicationPeriod: desde 2020
GT009	T	cartas publicadas depois de 2022	publicationPeriod: depois de 2022
GT010	T	cartas publicadas antes de 2020	publicationPeriod: antes de 2020
GT011	T	cartas publicadas entre 2022 e 2023	publicationPeriod: 2022-01-01 a 2023-12-31
GT012	T	cartas publicadas no primeiro trimestre deste ano	publicationPeriod: 1º trimestre do ano corrente
GT013	T	cartas publicadas no segundo semestre do ano passado	publicationPeriod: 2º semestre do ano anterior
GT014	T	cartas publicadas nesta semana	publicationPeriod: semana corrente
GT015	T	cartas publicadas hoje	publicationPeriod: dia da execução
GT016	C · T · A	cartas de pernambuco publicadas desde 2020	state: "Pernambuco"; publicationPeriod: desde 2020
GT017	C · T · A	cartas da bahia publicadas nos últimos 6 meses	state: "Bahia"; publicationPeriod: últimos 6 meses
GT018	C · T · A	cartas do AP produzidas no segundo semestre do ano passado	state: "Amapá"; creationPeriod: 2º semestre do ano anterior
GT019	C · T · A	cartas do MA publicadas no ano passado	state: "Maranhão"; publicationPeriod: ano anterior, inteiro
GT020	C · T	cartas da Paraíba publicadas esse ano	state: "Paraíba"; publicationPeriod: ano corrente
GT021	C · T · A	cartas de roraima elaboradas hoje	state: "Roraima"; creationPeriod: dia da execução
GT022	C · T · A	cartas de sergipe publicadas no primeiro trimestre deste ano	state: "Sergipe"; publicationPeriod: 1º trimestre do ano corrente
GT023	C · T	cartas de Rondônia publicadas depois de 2022	state: "Rondônia"; publicationPeriod: depois de 2022
GT024	C · T	cartas do Maranhão criadas nos últimos 3 meses	state: "Maranhão"; creationPeriod: últimos 3 meses

ID	Cat.	Consulta	Leituras aceitas
GT025	C · T · A	cartas da bahia publicadas antes de 2020	state: "Bahia"; publicationPeriod: antes de 2020
GT026	C · T · A	produtos do 3o cgeo publicados no ano passado	supplyArea: "3° Centro de Geoinformação"; publicationPeriod: ano anterior, inteiro
GT027	C · T · A	produtos do 3 CGEO publicados hoje	supplyArea: "3° Centro de Geoinformação"; publicationPeriod: dia da execução
GT028	C · T · A	produtos do 3º CGEO criados no primeiro trimestre deste ano	supplyArea: "3° Centro de Geoinformação"; creationPeriod: 1º trimestre do ano corrente
GT029	C · T · A	produtos do quarto cgeo publicados depois de 2022	supplyArea: "4° Centro de Geoinformação"; publicationPeriod: depois de 2022
GT030	C · T · A	produtos do 1º CGEO publicados no mês passado	supplyArea: "1° Centro de Geoinformação"; publicationPeriod: mês anterior, inteiro
GT031	C · T · A	produtos do terceiro cgeo criados nos últimos 3 meses	supplyArea: "3° Centro de Geoinformação"; creationPeriod: últimos 3 meses
GT032	C · T · A	produtos do 2 CGEO publicados antes de 2020	supplyArea: "2° Centro de Geoinformação"; publicationPeriod: antes de 2020
GT033	C · T · A	produtos do 5 CGEO publicados na semana passada	supplyArea: "5° Centro de Geoinformação"; publicationPeriod: semana passada
GT034	C · T	cartas na escala 1:5.000 publicadas depois de 2022	scale: "1:5.000"; publicationPeriod: depois de 2022
GT035	C · T · A	cartas na escala 1:5000 publicadas esse ano	scale: "1:5.000"; publicationPeriod: ano corrente
GT036	C · T · A	cartas na escala de 25 mil criadas no ano passado	scale: "1:25.000"; creationPeriod: ano anterior, inteiro
GT037	C · T · A	cartas em 50k publicadas no segundo semestre do ano passado	scale: "1:50.000"; publicationPeriod: 2º semestre do ano anterior
GT038	C · T · A	cartas na escala de 10 mil publicadas no mês passado	scale: "1:10.000"; publicationPeriod: mês anterior, inteiro
GT039	C · T	cartas na escala 1:2.000 elaboradas hoje	scale: "1:2.000"; creationPeriod: dia da execução
GT040	C · T · A	cartas na escala de 100 mil publicadas nesta semana	scale: "1:100.000"; publicationPeriod: semana corrente
GT041	C · T · A	cartas na escala 1:5000 publicadas nos últimos 6 meses	scale: "1:5.000"; publicationPeriod: últimos 6 meses

A.9 Consultas com ordenação geradas por *templates* (G-O)

Total desta família: **19 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GO001	C · O · A	a carta mais recente do CE	state: "Ceará"; sortField: "publicationDate" ou "creationDate"; sortDirection: "DESC"; limit: 1 (opcional)
GO002	C · O · A	a carta mais antiga do PA	state: "Pará"; sortField: "publicationDate" ou "creationDate"; sortDirection: "ASC"; limit: 1 (opcional)
GO003	C · O	as cartas mais recentes do Ceará	state: "Ceará"; sortField: "publicationDate" ou "creationDate"; sortDirection: "DESC"
GO004	C · O · A	as cartas mais antigas de mato grosso	state: "Mato Grosso"; sortField: "publicationDate" ou "creationDate"; sortDirection: "ASC"
GO005	C · O · A	a primeira carta produzida de sergipe	state: "Sergipe"; sortField: "creationDate"; sortDirection: "ASC"; limit: 1 (opcional)
GO006	C · O · A	a última carta publicada de GO	state: "Goiás"; sortField: "publicationDate"; sortDirection: "DESC"; limit: 1 (opcional)
GO007	C · O · A	as 3 cartas mais antigas de sergipe	state: "Sergipe"; sortField: "publicationDate" ou "creationDate"; sortDirection: "ASC"; limit: 3
GO008	C · O · A	as 5 publicações mais recentes de MG	state: "Minas Gerais"; sortField: "publicationDate"; sortDirection: "DESC"; limit: 5
GO009	C · O · A	as 10 cartas criadas mais recentemente do PR	state: "Paraná"; sortField: "creationDate"; sortDirection: "DESC"; limit: 10
GO010	C · O · A	cartas do distrito federal em ordem cronológica de publicação	state: "Distrito Federal"; sortField: "publicationDate"; sortDirection: "ASC"
GO011	C · O	as cartas temáticas mais recentes	productType: "Cartas Temáticas Não SCN"; sortField: "publicationDate" ou "creationDate"; sortDirection: "DESC"
GO012	C · O	as 3 cartas CIRC mais antigas	productType: "CIRC"; sortField: "publicationDate" ou "creationDate"; sortDirection: "ASC"; limit: 3
GO013	C · O	a última ortoimagem publicada	productType: "SCN Carta Ortoimagem"; sortField: "publicationDate"; sortDirection: "DESC"; limit: 1 (opcional)
GO014	C · O	a primeira carta topográfica vetorial elaborada	productType: "SCN Carta Topográfica Vetorial"; sortField: "creationDate"; sortDirection: "ASC"; limit: 1 (opcional)
GO015	C · O	cartas topográficas da mais nova para a mais antiga	productType: "SCN Carta Topográfica Matricial"; sortField: "publicationDate" ou "creationDate"; sortDirection: "DESC"
GO016	C · T · O	as cartas mais recentes publicadas entre 2022 e 2023	publicationPeriod: 2022-01-01 a 2023-12-31; sortField: "publicationDate" ou "creationDate"; sortDirection: "DESC"

ID	Cat.	Consulta	Leituras aceitas
GO017	C · T · O	a primeira carta criada na semana passada	creationPeriod: semana passada; sortField: "creationDate"; sortDirection: "ASC"; limit: 1 (opcional)
GO018	C · T · O	as 5 cartas mais antigas publicadas nos últimos 5 anos	publicationPeriod: últimos 5 anos; sortField: "publicationDate" ou "creationDate"; sortDirection: "ASC"; limit: 5
GO019	C · T · O	a última carta publicada nos últimos 6 meses	publicationPeriod: últimos 6 meses; sortField: "publicationDate"; sortDirection: "DESC"; limit: 1 (opcional)

A.10 Consultas ambíguas/informais adicionais (G-A)

Total desta família: **24 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GA001	S · A	mapas de pe	state: "Pernambuco"
GA002	S · A	mapas do pr	state: "Paraná"
GA003	S · A	mapas de sc	state: "Santa Catarina"
GA004	S · A	mapas de go	state: "Goiás"
GA005	S · A	mapas do ce	state: "Ceará"
GA006	S · A	mapas do pa	state: "Pará"
GA007	S · A	mapas de goias	state: "Goiás"
GA008	S · A	mapas de rondonia	state: "Rondônia"
GA009	S · A	mapas do piaui	state: "Piauí"
GA010	S · A	mapas do amapa	state: "Amapá"
GA011	S · A	mapas do maranhao	state: "Maranhão"
GA012	S · A	mapas da paraiba	state: "Paraíba"
GA013	S · A	mapas de cuiaba	city: "Cuiabá"
GA014	S · A	mapas de goiania	city: "Goiânia"
GA015	S · A	mapas de belem	city: "Belém"
GA016	S · A	mapas de brasilia	city: "Brasília"
GA017	C · A	cartas do rio em 50k	state: "Rio de Janeiro"; scale: "1:50.000"; aceita-se também city no lugar de state
GA018	C · A	mapas detalhados do Amazonas	scale: "1:25.000"; state: "Amazonas"
GA019	S · A	cartas em pequena escala do sul	scale: "1:250.000"
GA020	S · A	produtos em média escala	scale: "1:50.000" ou "1:100.000"
GA021	C · A	cartas de Goiás em 25k	state: "Goiás"; scale: "1:25.000"
GA022	C · A	cartas do Tocantins em 50k	state: "Tocantins"; scale: "1:50.000"
GA023	C · A	cartas de Mato Grosso do Sul em 100k	state: "Mato Grosso do Sul"; scale: "1:100.000"
GA024	C · A	cartas de Pernambuco em 250k	state: "Pernambuco"; scale: "1:250.000"

A.11 Consultas amplas, com muitos produtos (G-P)

Total desta família: **13 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GP001	S	todas as cartas de Rondônia	state: "Rondônia"
GP002	S	todas as cartas do Tocantins	state: "Tocantins"
GP003	S	todas as cartas do Piauí	state: "Piauí"
GP004	S	todas as cartas de Mato Grosso	state: "Mato Grosso"
GP005	S	todas as cartas do Acre	state: "Acre"
GP006	S	todos os produtos do 1° Centro de Geoinformação	supplyArea: "1° Centro de Geoinformação"
GP007	S	todos os produtos do 2° Centro de Geoinformação	supplyArea: "2° Centro de Geoinformação"
GP008	S	todos os produtos do 3° Centro de Geoinformação	supplyArea: "3° Centro de Geoinformação"
GP009	S	todos os produtos do 4° Centro de Geoinformação	supplyArea: "4° Centro de Geoinformação"
GP010	S	todos os produtos do 5° Centro de Geoinformação	supplyArea: "5° Centro de Geoinformação"
GP011	C	cartas na escala 1:2.000 do Rio Grande do Norte	scale: "1:2.000"; state: "Rio Grande do Norte"
GP012	C	cartas na escala 1:5.000 de Alagoas	scale: "1:5.000"; state: "Alagoas"
GP013	C	cartas na escala 1:250.000 do Rio Grande do Sul	scale: "1:250.000"; state: "Rio Grande do Sul"

A.12 Consultas de fronteira do domínio (G-F)

Total desta família: **7 consultas**, listadas integralmente abaixo (a função geradora e o modelo de frase de cada consulta constam de `dataset.json`).

ID	Cat.	Consulta	Leituras aceitas
GF001	F	me ajuda	não chamar a ferramenta (sem intenção de busca)
GF002	F	cartas de Marte	não chamar a ferramenta (fora da Terra)
GF003	F	cartas da Argentina	não chamar a ferramenta (fora do território brasileiro)
GF004	F	qual a previsão do tempo para amanhã em Manaus?	não chamar a ferramenta (outro assunto)
GF005	F	quanto custa uma carta topográfica?	não chamar a ferramenta (pergunta de preço, não de busca)
GF006	F	mapa do tesouro pirata	não chamar a ferramenta (ficção)
GF007	S	cartas do estado 42	não chamar a ferramenta (observacional, P6: valor impossível de representar)

A.13 Requisitos exercitados pelas consultas

O Quadro 8 relaciona os grupos de consultas aos requisitos da Seção 3.2. Todas as consultas exercitam a tradução (RF2) e o registro dos traços de execução (RF5), pois cada rodada do *pipeline* de avaliação grava um registro por consulta. A troca do modelo entre rodadas, por parâmetro do *pipeline*, exercita a substituição do modelo por configuração (RNF6). A rota REST (RF1), a busca no banco (RF3) e a seleção do modelo por requisição (RF4) ficam fora das métricas, que avaliam a tradução (Quadro 1).

Quadro 8 – Grupos de consultas do *dataset* e aspectos da tradução que exercitam

Grupo de consultas	O que exige do modelo	Requisitos
Todas (310)	Preencher os campos da ferramenta sustentados pela consulta, na forma canônica, sem acrescentar campos	RF2, RF5, RNF6
Com código MI/INOM (M)	Preservar o código em keyword , normalizando grafias compactadas do INOM	RF2
Com tempo relativo (T)	Resolver a expressão em datas ISO a partir da data de referência informada e escolher entre período de publicação e de criação	RF2
Com ordenação (O)	Preencher sortField , sortDirection e, quando pedido, limit , sem ordenar quando a consulta não pede	RF2
Ambíguas/informais (A)	Normalizar siglas, grafias sem acento, apelidos e expressões qualitativas sem dicionário de normalização	RF2
Fora do domínio (F)	Reconhecer que o catálogo não atende ao pedido e não chamar a ferramenta	RF2
Observacionais (4)	Comportamento diante de valores impossíveis ou de pedidos de resposta discutível (reportado, não pontuado)	RF2, RF5

Fonte: Elaborado pelos autores. As contagens por categoria estão na Tabela 18.

A.14 Auditoria do *dataset*

A auditoria segue o procedimento do manual de anotação (Seção A.1, subseção “Procedimento de auditoria”) e é reproduzível a partir do repositório. Os artefatos ficam em `data/auditoria/`. Eles guardam o resultado das checagens automáticas e das medidas de concordância, uma linha por consulta com as evidências e as divergências, a anotação às cegas com a justificativa de cada consulta, as decisões de adjudicação com o gabarito anterior a cada uma e a amostra estratificada de 40 consultas (semente 42) conferida por um dos autores. O comando `pfc-auditar` (Seção C.1) refaz a auditoria e regenera as Tabelas 4 e 16 e o Quadro 9.

A Tabela 16 detalha, por campo, a concordância entre a leitura preferencial do gabarito e a da anotação independente. O Quadro 9 lista todas as decisões de adjudicação. Quatro consultas tiveram leitura preferencial divergente (Tabela 4). Em P13, P21 e P22, a divergência decorre da regra que mantém, na camada P, a anotação original da equipe do 1º CGEO como preferencial. Em N33, o gabarito inclui na leitura preferencial o campo opcional `project`, que o anotador deixou de fora. Nas quatro, a leitura do anotador está entre as leituras aceitas.

Tabela 16 – Concordância por campo entre o gabarito e a anotação independente (leitura preferencial, após a adjudicação)

Campo	Gabarito	Anotador	Ambos	Kappa	Valor igual
<code>keyword</code>	62	62	62	1,000	62/62
<code>scale</code>	84	84	84	1,000	83/84
<code>productType</code>	44	44	44	1,000	44/44
<code>state</code>	130	130	130	1,000	130/130
<code>city</code>	27	27	27	1,000	27/27
<code>supplyArea</code>	40	40	40	1,000	40/40
<code>project</code>	11	10	10	0,951	10/10
<code>publicationPeriod</code>	51	51	51	1,000	51/51
<code>creationPeriod</code>	10	10	10	1,000	10/10
<code>sortField</code>	29	29	29	1,000	27/29
<code>sortDirection</code>	29	29	29	1,000	29/29
<code>limit</code>	21	21	21	1,000	21/21

Fonte: Elaborada pelos autores. Gabarito, Anotador e Ambos: consultas em que o campo está na leitura preferencial de cada um. Kappa de Cohen sobre a presença do campo. Valor igual: entre as consultas em que ambos o anotam; períodos comparados pelos limites, textos livres após normalização.

Quadro 9 – Decisões de adjudicação da auditoria do *dataset*

Consultas	Divergência	Decisão	Justificativa
N36, N37, GF001, GF002, GF003, GF004, GF005, GF006 <i>anotação independente</i>	o gabarito classificava a consulta como observacional; o anotador a tratou como fora do domínio, com gabarito determinado 'não chamar'	corrigido	P4 e seção "Consultas fora do domínio" do manual: consulta sem intenção de busca no acervo brasileiro tem comportamento correto determinado (não chamar); P6 reserva 'observacional' às consultas cujo comportamento correto não é determinável. A consulta passa às métricas principais, na categoria F (fora do domínio).
N33 <i>anotação independente</i>	o gabarito exigia project = Mapeamento Sistemático; o anotador anotou só state = São Paulo e listou project como leitura alternativa, pois 'cartografia sistemática' não é nome nem apelido informado na ferramenta	ampliado	As duas leituras são razoáveis (P3): a expressão designa o programa pelo termo distintivo do nome, mas não consta da descrição da ferramenta. project passa a campo opcional; a regra de project do manual passa a registrar o caso.
GF007 <i>anotação independente</i>	ambos classificam a consulta como observacional; o gabarito indica 'não chamar' e o anotador, 'chamar sem parâmetros'	mantido	Consulta observacional (P6, valor impossível de representar): o comportamento é reportado, mas não pontuado, de modo que a divergência não afeta nenhuma métrica. Mantém-se a indicação 'não chamar', coerente com N38 (escala 1:10.000.000).
P14 <i>consistência</i>	'detalhado' é anotado como 1:25.000 em todo o dataset, mas P14 aceita 1:25.000 ou 1:50.000	mantido	As escalas explícitas '(25k ou 50k)' prevalecem sobre o qualificativo 'detalhado' (regra de scale: duas escalas explícitas, aceita-se qualquer uma).
P13 <i>anotação independente (medida estrita)</i>	leitura preferencial diferente dentro do conjunto aceito: scale 1:25.000 no gabarito, 1:50.000 no anotador (ambas aceitas por 'maior que 100k')	mantido	Na camada P, a anotação original da equipe do 1º CGEO é mantida como leitura preferencial (manual, seção "Rastreabilidade"); a escolha da preferencial não afeta a pontuação.
P21, P22 <i>anotação independente (medida estrita)</i>	leitura preferencial diferente dentro do conjunto aceito: sortField creationDate no gabarito, publicationDate no anotador (ambos aceitos, sem pista ligada à ordenação)	mantido	Na camada P, a anotação original da equipe do 1º CGEO é mantida como leitura preferencial (manual, seção "Rastreabilidade"); a escolha da preferencial não afeta a pontuação.
GO016 <i>anotação independente (medida estrita)</i>	o gabarito aceita sortField publicationDate ou creationDate; o anotador aceitou só publicationDate	mantido	Em 'as cartas mais recentes publicadas entre 2022 e 2023', o verbo qualifica o filtro de período, não a ordenação; sem pista ligada à ordenação, aceitam-se os dois campos (regra de ordenação). É o mesmo raciocínio do anotador em P22.

Fonte: Elaborado pelos autores a partir de `data/auditoria/adjudicacao.json`.

A.15 Estrutura, composição e concordância dos conjuntos

Esta seção reúne as tabelas que descrevem as 310 consultas e os dois lotes (Seção 4.3). Além dos campos da Tabela 17, cada entrada traz os campos **origem** (P, N ou G), **familia** (P, N, GS ... GF) e **trocás**, com as leituras estruturais alternativas que o campo **alternativas** expande. Os valores alternativos e os campos opcionais ficam marcados no próprio **esperado**.

Tabela 17 – Estrutura de cada entrada do *dataset* de avaliação

Campo	Descrição
id	Identificador (P01–P22, N01–N40, GS001 ... GF007)
fonte	Rastreabilidade: arquivo e linha de origem (camada P), autores (camada N) ou função geradora, modelo de frase e semente (camada G)
categorias	Uma ou mais das categorias S, C, M, T, O, A; ou F (fora do domínio), que não se combina com as demais
consulta	Texto em linguagem natural
esperado	Leitura preferencial do gabarito: parâmetros de busca na forma canônica, com períodos relativos expressos por regras nomeadas
alternativas	Demais leituras aceitas, quando a consulta admite mais de uma (Seção 4.3.2)
espera_tool_call	Falso quando o comportamento correto é não chamar a ferramenta
observacional	Verdadeiro quando o caso fica fora das métricas principais
notas	Justificativa das leituras alternativas e observações do anotador

Fonte: Elaborada pelos autores.

Tabela 18 – Consultas por categoria e por camada (métricas principais; uma consulta pode ter mais de uma categoria)

Categoria	P	N	G	Total
Simples (S)	0	11	89	100
Compostas (C)	22	21	137	180
Código MI/INOM (M)	10	5	42	57
Tempo relativo (T)	6	9	45	60
Ordenação (O)	4	6	19	29
Ambíguas/informais (A)	16	19	162	197
Fora do domínio (F)	0	2	6	8

Fonte: Elaborada pelos autores.

O lote 1 (validação) e o lote 2 (teste) foram construídos com a mesma receita (Seção 4.3.4). As Tabelas 20 e 22 dão a composição de cada lote, e as Tabelas 21 e 23, a concordância da anotação às cegas.

Tabela 19 – Frequência de cada campo na leitura preferencial do gabarito (métricas principais)

Campo	Ocorr.	Campo	Ocorr.
keyword	62	project	11
scale	84	publicationPeriod	51
productType	44	creationPeriod	10
state	130	sortField	29
city	27	sortDirection	29
supplyArea	40	limit	21

Fonte: Elaborada pelos autores.

Tabela 20 – Do alvo ao lote final, por família, no lote de validação

Família	Testa	Alvos	Checagens	Anotação às cegas	Lote final
VS	Simples (um critério)	280	-3	0	277
VC	Compostas	360	0	-1	359
VM	Códigos MI/INOM	160	0	0	160
VT	Tempo	260	-1	0	259
VO	Ordenação	200	-1	0	199
VA	Leituras múltiplas	200	-7	0	193
VE	Subespecificadas	150	-4	0	146
VF	Fora do domínio	340	-4	0	336
Total		1.950	-20	-1	1.929

Fonte: Elaborada pelos autores. Checagens: descartadas nas checagens automáticas e na deduplicação. Anotação às cegas: descartadas por incompatibilidade entre o gabarito por construção e a anotação A.

Tabela 21 – Concordância na anotação às cegas do lote de validação

Medida	Construção $\times$ A (n=1.950)	A $\times$ B (n=390)
Decisão (buscar / buscar ou esclarecer / não buscar), kappa	1,000	1,000
Leituras compatíveis nos dois sentidos	99,8%	100,0%
Leitura preferencial idêntica	99,8%	100,0%
Presença dos campos, kappa	0,999	1,000
Valor igual quando ambos preenchem	100,0%	100,0%
Deteção de leituras múltiplas, kappa	0,967	1,000

Fonte: Elaborada pelos autores. Medidas de `audit.concordancia`, as mesmas da auditoria das 310 consultas, sobre todas as consultas redigidas (antes do filtro). A: anotação de todas as consultas; B: segunda anotação independente de uma amostra aleatória de 20%.

Tabela 22 – Do alvo ao lote final, por família, no lote 2 (teste)

Família	Testa	Alvos	Checagens	Anotação às cegas	Lote final
VS	Simples (um critério)	140	−5	−1	134
VC	Compostas	180	0	−3	177
VM	Códigos MI/INOM	80	−1	0	79
VT	Tempo	130	0	0	130
VO	Ordenação	100	−1	0	99
VA	Leituras múltiplas	100	−2	0	98
VE	Subespecificadas	75	−10	0	65
VF	Fora do domínio	170	−7	0	163
Total		975	−26	−4	945

Fonte: Elaborada pelos autores. Checagens: descartadas nas checagens automáticas e na deduplicação. Anotação às cegas: descartadas por incompatibilidade entre o gabarito por construção e a anotação A.

Tabela 23 – Concordância na anotação às cegas do lote 2 (teste)

Medida	Construção × A (n=975)	A × B (n=195)
Decisão (buscar / buscar ou esclarecer / não buscar), kappa	1,000	1,000
Leituras compatíveis nos dois sentidos	99,6%	100,0%
Leitura preferencial idêntica	99,5%	100,0%
Presença dos campos, kappa	0,998	1,000
Valor igual quando ambos preenchem	100,0%	100,0%
Deteção de leituras múltiplas, kappa	0,961	1,000

Fonte: Elaborada pelos autores. Medidas de `audit.concordancia`, as mesmas da auditoria das 310 consultas, sobre todas as consultas redigidas (antes do filtro). A: anotação de todas as consultas; B: segunda anotação independente de uma amostra aleatória de 20%.

APÊNDICE B – ESPECIFICAÇÃO DOS AMBIENTES DE EXECUÇÃO

Este apêndice documenta o *hardware* e o *software* dos ambientes de execução da Seção 4.4.1. Em todos eles, cada rodada grava um manifesto (`results/<modelo>/manifesto.json`; Seção 4.4.4).

B.1 Estação de referência

A estação de referência tem a seguinte configuração:

- **CPU.** Intel Core i7-12700H (12.^a geração, 14 núcleos / 20 *threads*, base 2,3 GHz).
- **RAM.** 32 GB DDR4 a 3200 MHz.
- **GPU dedicada.** NVIDIA GeForce RTX 3050 Laptop GPU com 4 GB de VRAM.
- **Disco.** SSD NVMe de 512 GB.
- **Sistema operacional.** Microsoft Windows 11 Pro (versão 10.0.26200, 64 bits).
- **Software.** Python 3.14.4; Ollama 0.34.0; LangChain 1.x (`langchain-core` 1.6.4, `langchain-ollama` 1.1.0, cliente `ollama` 0.6.2); PostgreSQL 16.4 com PostGIS 3.4 em contêiner Docker, usado apenas na demonstração ponta a ponta.

Os dados foram coletados no próprio equipamento, em setembro de 2026, pelos comandos PowerShell da Seção B.1.1, com o mesmo *driver* NVIDIA das rodadas da estação. A Seção B.1.2 transcreve a saída de forma condensada. A imagem Docker do banco da demonstração, `postgis/postgis:16-3.4`, está definida no `docker-compose.yml` do repositório. O `psql` listado é o cliente instalado na estação.

B.1.1 Comandos PowerShell de coleta

```
# CPU
Get-CimInstance Win32_Processor | Select-Object Name, NumberOfCores,
    NumberOfLogicalProcessors, MaxClockSpeed

# Memória RAM (total em GB e detalhes por pente)
(Get-CimInstance Win32_PhysicalMemory |
    Measure-Object -Property Capacity -Sum).Sum / 1GB
Get-CimInstance Win32_PhysicalMemory | Select-Object Manufacturer,
    Capacity, Speed, ConfiguredClockSpeed, MemoryType, DeviceLocator
```

```
# GPU (geral)
Get-CimInstance Win32_VideoController | Select-Object Name,
    AdapterRAM, DriverVersion, VideoProcessor

# VRAM real (se GPU NVIDIA)
nvidia-smi --query-gpu=name,memory.total,driver_version --format=csv

# Sistema operacional
Get-CimInstance Win32_OperatingSystem | Select-Object Caption,
    Version, BuildNumber, OSArchitecture

# Disco principal
Get-PhysicalDisk | Select-Object FriendlyName, MediaType, Size, BusType

# Versoes de software
python --version
ollama --version
psql --version
docker --version
```

B.1.2 Saída coletada

```
# CPU
Name                                NumberOfCores  NumberOfLogicalProcessors  MaxClockSpeed
12th Gen Intel(R) Core(TM) i7-12700H          14                20                2300

# RAM
RAM total (GB): 32
Pente 1: Kingston, 16 GB DDR4, 3200 MHz (Controller0-ChannelA-DIMM0)
Pente 2: Kingston, 16 GB DDR4, 3200 MHz (Controller1-ChannelA-DIMM0)

# GPU
Name: NVIDIA GeForce RTX 3050 Laptop GPU
    AdapterRAM 4 293 918 720; DriverVersion 32.0.16.1664
    VideoProcessor NVIDIA GeForce RTX 3050 Laptop GPU
Name: Intel(R) Iris(R) Xe Graphics
    AdapterRAM 2 147 479 552; DriverVersion 32.0.101.6790
    VideoProcessor Intel(R) Iris(R) Xe Graphics Family

# nvidia-smi
NVIDIA GeForce RTX 3050 Laptop GPU, 4096 MiB, 616.64

# Sistema operacional
Microsoft Windows 11 Pro, versao 10.0.26200, Build 26200, 64 bits

# Disco principal
INTEL SSDPEKNU512GZ, SSD NVMe, 512 GB

# Software
Python 3.14.4
ollama version is 0.34.0
```


psql (PostgreSQL) 18.3
 Docker version 29.6.1, build 8900f1d

A Tabela 24 transcreve dos manifestos o ambiente das duas rodadas de validação na estação, com o Qwen 3 4B e o Gemma 4 E2B (Seção 5.1.3). As rodadas feitas depois na estação, para o teste A/B, têm as condições de *hardware* nos próprios manifestos, resumidas em `results/ab/ab.md`.

Tabela 24 – Ambiente de execução de cada rodada, na estação de referência (camadas P e N)

Modelo	GPU / máquina	Servidor	Rep.	Exec.	Na GPU	VRAM livre
Qwen 3 4B	RTX 3050 Laptop, 4096 MiB	Ollama 0.34.0	1	62	66%	3,0 GB
Gemma 4 E2B	RTX 3050 Laptop, 4096 MiB	Ollama 0.34.0	1	62	38%	3,1 GB

Fonte: Elaborado pelos autores a partir de `results/<modelo>/manifesto.json`. Na GPU: parcela do modelo carregado (pesos e contexto) alocada na VRAM pelo Ollama, medida após o aquecimento; VRAM livre: no início da rodada, com os demais modelos descarregados. Data de referência: 2026-09-14. Python 3.14.4; langchain-core 1.6.4, langchain-ollama 1.1.0.

B.2 Rodadas completas em GPU de nuvem

As rodadas completas dos quatro modelos locais foram feitas numa máquina virtual do Google Colab com GPU NVIDIA T4 (16 GB nominais de VRAM, dos quais o `nvidia-smi` informa 15.360 MiB; Tabela 25), pelo caderno `notebooks/avaliacao_colab.ipynb` do repositório. O caderno instala o Ollama pelo instalador oficial e baixa os modelos pelas *tags* `qwen3:4b-instruct-2507-q4_K_M`, `gemma4:e4b-it-qat`, `gemma4:e2b-it-qat` e `mistral-nemo:12b`. As *tags* do Qwen 3 4B, do Gemma 4 E4B e do Gemma 4 E2B são as mesmas usadas na estação de referência, com o mesmo *digest* registrado nos manifestos. O caderno recebe o pacote do projeto (`pfc_busca_colab.zip`, gerado por `scripts/empacotar_colab.py`), confere o *hash* SHA-256 do conjunto de consultas gravado no próprio caderno e recusa-se a rodar com outro pacote. Depois, executa `pfc-avaliar` com três repetições por modelo, data de referência fixa (14 de setembro de 2026) e sem execução de SQL, pois a busca no banco não entra nas métricas.

No mesmo ambiente, o caderno `notebooks/linha_de_base_colab.ipynb` executou, com uma repetição e a mesma data de referência, a Saída Estruturada v1 nos quatro modelos locais e o método do protótipo no `phi4:14b`. Os lotes 1 (validação) e 2 (teste) também rodaram nesse ambiente, com o Gemma 4 E4B e uma repetição. O caderno `notebooks/lote_validacao_colab.ipynb` executou as configurações v1 e v2 no lote 1 e as duas v2 nas 310. O `notebooks/lote2_v3_colab.ipynb` conferiu o *hash* da v3 congelada antes de rodar e executou as configurações do plano de análise no lote 2 e a v3 e o controle nas 310. O `notebooks/lote2_v3_modelos_colab.ipynb` executou a extensão

ao Gemma 4 E2B e ao Qwen 3 4B no lote 2. Nenhum serviço de LLM em nuvem é usado nesse ambiente. O Ollama executa dentro da máquina virtual, com os pesos baixados nela, e só a GPU vem da nuvem.

Tabela 25 – Ambiente de execução de cada rodada

Modelo	GPU / máquina	Servidor	Rep.	Exec.	Na GPU	VRAM livre
Qwen 3 4B	Tesla T4, 15360 MiB	Ollama 0.34.4	3	930	100%	14,6 GB
Gemma 4 E4B	Tesla T4, 15360 MiB	Ollama 0.34.4	3	930	100%	14,6 GB
Gemma 4 E2B	Tesla T4, 15360 MiB	Ollama 0.34.4	3	930	100%	14,6 GB
Mistral Nemo 12B	Tesla T4, 15360 MiB	Ollama 0.34.4	3	930	100%	14,6 GB

Fonte: Elaborado pelos autores a partir de `results/<modelo>/manifesto.json`. Na GPU: parcela do modelo carregado (pesos e contexto) alocada na VRAM pelo Ollama, medida após o aquecimento; VRAM livre: no início da rodada, com os demais modelos descarregados. Data de referência: 2026-09-14. Python 3.13.15; langchain-core 1.6.5, langchain-ollama 1.1.0.

B.3 Referência em nuvem (Groq)

A referência em nuvem usa a API do Groq, compatível com a da OpenAI, pela classe `ChatOpenAI` do pacote `langchain-openai` (versão 1.6.6), com `langchain-core` 1.6.4, a partir da estação de referência. O *prompt* de sistema, a definição da ferramenta, a temperatura (zero) e o limite de 1024 *tokens* de saída são os mesmos das rodadas locais. O esforço de raciocínio foi fixado no menor valor aceito por cada modelo, `none` para o `qwen/qwen3.8-27b` e `low` para o `openai/gpt-oss-20b` e o `openai/gpt-oss-120b`. O valor `none` desliga o raciocínio. Cada modelo executou as 310 consultas uma vez, com data de referência de 24 de setembro de 2026 e intervalo mínimo de 11 s entre chamadas.

Quando o provedor sinaliza o esgotamento do limite de taxa do plano gratuito, a execução aguarda o tempo indicado e retoma a mesma consulta, sem contá-la como erro. As falhas transitórias de conexão ou do servidor são repetidas até três vezes antes de contarem como erro de infraestrutura, e só a latência da tentativa respondida é registrada. O servidor valida os argumentos contra o *schema*, e uma chamada de ferramenta rejeitada por argumentos inválidos conta como erro do modelo. Quando os argumentos podem ser recuperados da mensagem de rejeição, eles são avaliados campo a campo, como na execução local. A linha de base com Saída Estruturada usa o mesmo cliente, sem ferramenta, com o modo JSON do provedor (`response_format` do tipo `json_object`), a mesma data de referência e o mesmo esforço de raciocínio de cada modelo.

APÊNDICE C – REPOSITÓRIO DE CÓDIGO E REPRODUÇÃO DOS EXPERIMENTOS

O código-fonte, o *dataset*, o manual de anotação, os registros de auditoria, os registros de execução de todas as rodadas e as fontes deste texto estão no repositório público do projeto, <<https://github.com/vhenequim/bdgex-busca-tool-calling>>. O código, o *dataset* e os artefatos de avaliação estão sob a licença MIT. As partes derivadas do protótipo do 1º CGEO mantêm a licença MIT original, como registra o arquivo `THIRD_PARTY_NOTICES.md`. O texto deste trabalho segue os termos de uso do IME impressos no verso da folha de rosto. A estrutura principal do repositório aparece abaixo.

```
bdgex-busca-tool-calling/
  pyproject.toml      dependencias e comandos pfc e pfc-*
  src/pfc_busca/
    abordagens.py     registro unico das abordagens (familia, versao,
                      prefixo, tradutor e hashes do manifesto)
    cli.py            comando pfc (avaliar, relatorio, conferir, lote,
                      lote2, ab, abordagens, api, entre outros)
    schema.py         definicao da ferramenta buscar_catalogo (12 campos)
    prompts.py        prompt de sistema (com a data de referencia)
    agent.py          traducao via ChatOllama.bind_tools() (modelos locais)
    agent_groq.py     traducao via ChatOpenAI (referencia em nuvem)
    agent_estruturado.py linhas de base com Saida Estruturada e metodo
                      do prototipo
    prototipo_termos.py dicionario do prototipo (so na linha de base)
    v2.py             especificacao v2 (descricaoes e recusar_consulta)
    v3.py             v3 (laco de chamadas, retorno, recusa contestada
                      e controle com Saida Estruturada)
    ferramentas.py   ferramentas auxiliares e validador da v3
    dados/            municipios do IBGE e indice de folhas do BDGEx
                      (o indice nao e versionado)
    tools.py, db.py   busca no PostgreSQL/PostGIS (psycopg)
    pipeline.py       ciclo completo (traducao, busca e resposta)
    api.py            rotas POST /api/search e GET /api/health (FastAPI)
    evaluation/
      manual_cases.py camadas P e N, com rastreabilidade e notas
      gabarito.py     leituras multiplas (valor alternativo, opcional, trocas)
      relative_time.py regras de tempo relativo (leituras aceitas)
      dataset_builder.py pfc-dataset, constroi e valida data/dataset.json
      audit.py        pfc-auditar, auditoria do dataset
      run_evaluation.py pfc-avaliar, execucao, manifesto, repontuacao
      metrics.py      acuracia, P/R/F1 por campo, latencia
      report.py       pfc-relatorio, tabelas, figuras, Wilson, McNemar
```

conferencia.py	pfc-conferir, conferencia das rodadas
comparacao.py	Tool Calling x Saida Estruturada (tabela e macros)
lote.py	analise do lote 1 (tabelas e macros)
lote2.py	analise do lote 2 (plano de analise da v3)
ab.py	pfc ab, teste A/B, Modo A (TC) x Modo B (SE)
scripts/generate_dataset_paper.py	gerador da camada G (semente 42)
scripts/gerar_tabelas_texto.py	tabelas e macros (Ap. A, auditoria, 310)
scripts/empacotar_colab.py	pacote dos cadernos, com os hashes
scripts/lote_validacao/	coleta, alvos, redacao, anotacao e montagem
scripts/v3/	ciclos, autoteste do validador, decomposicao
docs/manual_de_anotacao.md	manual de anotacao
docs/lote_validacao.md	metodologia dos lotes
docs/v3.md, docs/v3_desenvolvimento.md	desenho, plano e ciclos da v3
docs/como_estender.md	guia para acrescentar uma versao
data/dataset.json	dataset (310 consultas)
data/lote_validacao.json	lote 1
data/lote_validacao_2.json	lote 2 (teste da v3)
data/auditoria/	artefatos da auditoria
db/	esquema do prototipo e dados sinteticos
results/	registros e manifestos das rodadas
results/ab/	teste A/B (ab.md e ab.json)
notebooks/avaliacao_colab.ipynb	rodadas completas em GPU de nuvem
notebooks/linha_de_base_colab.ipynb	linhas de base em GPU de nuvem
notebooks/lote_validacao_colab.ipynb	rodadas do lote 1 (v1 e v2)
notebooks/lote2_v3_colab.ipynb	rodadas do lote 2 (confere o hash da v3)
notebooks/lote2_v3_modelos_colab.ipynb	lote 2 com Gemma 4 E2B e Qwen 3 4B
experimentos/orientacoes/	variante descartada da v3
tests/	testes automatizados (pytest)
Dockerfile, docker-compose.yml	imagem da API; servicos postgis e api
.github/workflows/testes.yml	integracao continua (ruff, pytest, imagem)
texto/	fontes LaTeX e PDF deste trabalho

Os passos abaixo, com os comandos descritos na Seção C.1, reproduzem os resultados num ambiente com Python 3.12 ou superior, o Ollama e, para o banco da demonstração, o Docker.

```
git clone https://github.com/vhenequim/bdgex-busca-tool-calling.git pfc_busca
cd pfc_busca
pip install -e ".[dev]"          # pacote, comandos pfc e pfc-*, pytest e ruff
pytest -q tests/                 # sem Ollama, sem Groq e sem banco
pfc dataset                      # reconstrói data/dataset.json (mesmo hash)
pfc auditar --anotacao-independente data/auditoria/anotacao_independente.json
ollama pull qwen3:4b-instruct-2507-q4_K_M
pfc avaliar --modelo qwen3:4b-instruct-2507-q4_K_M --repeticoes 3 \
    --hoje 2026-09-14 --sem-sql
pfc conferir                     # rodadas das 310, da estacao e do lote 1
pfc conferir results/lote2/*-* results/v2_310/* results/v3_310/*
```

```
# tabelas e macros do texto, relidas de results/ (sem nova rodada)
python scripts/gerar_tabelas_texto.py --texto texto
pfc lote --paper texto # lote 1 e v2
pfc lote2 --paper texto # lote 2 e v3
pfc lote2 --modelo gemma4:e2b-it-qat --paper texto # extensao da v3
pfc lote2 --modelo qwen3:4b-instruct-2507-q4_K_M --paper texto
pfc ab --estrito --paper texto # teste A/B
python scripts/v3/validador_no_gabarito.py --tex # autoteste do validador
# API com a abordagem recomendada, sobre os dados sinteticos
docker compose up -d postgres
pfc api
```

Os comandos de análise releem os registros de execução e reaplicam o gabarito vigente, lido de `data/dataset.json` ou do arquivo do lote. Assim, as tabelas e os valores dos Capítulos 5 e 6 podem ser regenerados sem nova execução dos modelos. Num clone, o autoteste do validador grava as suas macros só em `data/v3/numeros_v3.tex`, que deve ser copiado à mão para `texto/tabelas/`.

O índice de folhas do BDGEx que as ferramentas da v3 consultam é gerado por `scripts/v3/gerar_dados_ferramentas.py` a partir da coleta do catálogo. Nem o índice nem a coleta são versionados, porque a política do BDGEx não trata de redistribuição. O índice entra no *hash* da configuração da v3 gravado em cada manifesto. Uma coleta de outra data, com o catálogo já alterado, gera outro índice e outro *hash*, e a v3 deixa de coincidir com a configuração avaliada. O `pfc conferir` acusa a diferença, e o `/api/health` não encontra nenhuma rodada avaliada com o mesmo *hash*. Sem o índice, a API sobe em modo degradado, com aviso no *log*, no `/api/health` e em cada resposta, e as ferramentas deixam de reconhecer nomes de folha e de conferir códigos no acervo. A reprodução exata da v3 exige o índice da coleta de 28/09/2026, cujas páginas têm o *hash* SHA-256 registrado em `data/lote_validacao/bdgex_resumo.json`. A repontuação a partir dos registros não depende dele.

O repositório guarda também os relatórios que detalham o Capítulo 5. O `results/consolidado/erros_representativos.md` traz até quatro erros sorteados de cada tipo por modelo, nas rodadas completas. O `results/ab/ab.md` lista, para cada par do teste A/B, as pastas das duas rodadas, as consultas e repetições e as condições de *hardware* que decidem se a latência é comparável. O `results/lote2/consolidado/lote2.md` traz as medidas do plano do lote 2 que não estão nas tabelas, como os efeitos de forma. A pasta `results/_descartados/estacao_14set_vram_disputada/` guarda a rodada do Qwen 3 4B feita na estação em 14 de setembro de 2026 e depois substituída, que a Tabela 36 compara com a rodada final. O manifesto dessa rodada, anterior ao registro da VRAM livre, não informa a parcela do modelo na GPU, que pode ter sido outra na rodada de 24 de setembro.

Os artefatos do lote 1 (validação; Seções 4.3.4 e 5.3) ficam em `data/lote_validacao/`, com a metodologia em `docs/lote_validacao.md`. Eles incluem os alvos, a redação e a anotação, as consultas descartadas com o motivo e a auditoria dos erros. O `pfc lote` calcula também, sem chamada nova ao modelo, as configurações simuladas da Tabela 40. Os artefatos do lote 2 (teste; Seção 4.3.4) ficam em `data/lote_validacao_2/`, e as rodadas e o relatório do teste da v3, em `results/lote2/`. Os ciclos de desenvolvimento da v3 estão em `docs/v3_desenvolvimento.md` e `results/dev_v3/`.

C.1 Comandos do *pipeline* de avaliação

Esta seção completa as Seções 3.5 e 3.5.1. Os comandos `pfc-dataset`, `pfc-auditar`, `pfc-avaliar`, `pfc-relatorio`, `pfc-conferir` e `pfc-ab` são pontos de entrada do pacote. O `pfc` os reúne em subcomandos com os mesmos argumentos e acrescenta `pfc abordagens`, que lista o registro e os *hashes*, `pfc api`, que sobe a API, e `pfc lote` e `pfc lote2`, que analisam os lotes.

As checagens do `pfc-auditar` cobrem estrutura, rastreabilidade, evidência pelo anotador por regras e consistência. O `pfc-avaliar` grava os registros em JSON Lines. A opção `--abordagem` escolhe a configuração (`saida_estruturada`, `prototipo`, `tool_calling_v2`, `saida_estruturada_v2`, `tool_calling_v3d`, `tool_calling_v3a`, `tool_calling_v3` e `saida_estruturada_v3`), e o padrão é o *Tool Calling* v1 (`tool_calling`). A opção `--dataset` aponta para o arquivo de cada lote, e `--provedor` `groq` troca o ChatOllama pelo ChatOpenAI apontado para o *endpoint* compatível do Groq (Seção B.3). O `pfc-relatorio` extrai também uma amostra de erros representativos por tipo.

Na API, as variáveis `PFC_ABORDAGEM` e `PFC_MODELO_PADRAO` escolhem a abordagem e o modelo, e `PFC_ABORDAGEM=tool_calling` volta à v1. Um nome fora do registro impede a subida. Com a v3, a SQL é executada uma vez, com os parâmetros da busca que encerra o laço de chamadas. O Docker Compose sobe a API com o banco, com o Ollama no *host*.

A integração contínua (`.github/workflows/testes.yml`) roda o `ruff` e o `pytest` em Python 3.12 a cada *push* e *pull request* e constrói a imagem da API, que precisa subir e responder o `/api/health` sem Ollama e sem banco. Os testes cobrem também o tempo relativo, as invariantes do *dataset* e os relatórios, e a API é testada com tradutores falsos.

O guia `docs/como_estender.md` descreve, para a próxima versão, os passos que a v3 seguiu (módulo novo, entrada no registro, congelamento pelo *hash*, plano de análise gravado antes da rodada e números levados ao texto por macros geradas).

APÊNDICE D – RESULTADOS COMPLEMENTARES

Este apêndice reúne as tabelas e as figuras que detalham o Capítulo 5.

D.1 Rodadas completas das 310 consultas

Os quatro modelos locais executaram as 310 consultas na T4, com três repetições (Seção 5.1). Na Figura 7, a acurácia da categoria F é a taxa de recusa correta, porque o gabarito dessas consultas não tem campos.

Tabela 26 – Latência da tradução, em milissegundos, por modelo

Modelo	n	Mín.	Mediana	Média	p95	Máx.
Qwen 3 4B	918	66	828	868	1403	3117
Gemma 4 E4B	918	405	725	813	1230	4849
Gemma 4 E2B	918	224	397	420	703	1242
Mistral Nemo 12B	918	316	2391	2651	5860	16085

Fonte: Elaborado pelos autores. Tempo da chamada de tradução, medido no ambiente de cada rodada (Tabela 25); execuções com erro de infraestrutura excluídas.




Figura 6 – Distribuição da latência da tradução nas rodadas completas, em escala logarítmica, por modelo

Fonte: Elaborado pelos autores.

Tabela 27 – Teste de McNemar exato entre pares de modelos

Modelo A	Modelo B	Só A acerta	Só B acerta	<i>p</i> -valor
Qwen 3 4B	Gemma 4 E4B	45	63	0,1014
Qwen 3 4B	Gemma 4 E2B	52	59	0,5692
Qwen 3 4B	Mistral Nemo 12B	108	24	< 0,0001
Gemma 4 E4B	Gemma 4 E2B	53	42	0,3049
Gemma 4 E4B	Mistral Nemo 12B	125	23	< 0,0001
Gemma 4 E2B	Mistral Nemo 12B	118	27	< 0,0001

Fonte: Elaborado pelos autores. Consultas discordantes entre os dois modelos nas métricas principais, com o resultado de cada consulta dado pela maioria das suas repetições; *p*-valor bicaudal exato.

Tabela 28 – F1-score por categoria de consulta e por modelo

Categoria	Qwen 3 4B	Gemma 4 E4B	Gemma 4 E2B	Mistral Nemo 12B
Simples (n=100)	0,691	0,874	0,844	0,443
Compostas (n=180)	0,654	0,794	0,763	0,431
Código MI/INOM (n=57)	0,949	0,878	0,929	0,362
Tempo relativo (n=60)	0,725	0,547	0,645	0,450
Ordenação (n=29)	0,775	0,650	0,691	0,530
Ambíguas/informais (n=197)	0,640	0,825	0,744	0,429
Média ponderada	0,666	0,793	0,765	0,451

Fonte: Elaborado pelos autores. Uma consulta pode pertencer a mais de uma categoria; n = consultas distintas da categoria nas métricas principais (cada uma pontuada em todas as repetições). As consultas fora do domínio (categoria F), cujo gabarito é não chamar a ferramenta, não têm campos e aparecem na Figura de acurácia por categoria.




Figura 7 – Acurácia por consulta, por categoria e por modelo, nas rodadas completas dos modelos locais

Fonte: Elaborado pelos autores.

Tabela 29 – Acurácia por camada de origem das consultas

Camada	Consultas	Qwen 3 4B	Gemma 4 E4B	Gemma 4 E2B	Mistral Nemo 12B
Protótipo (P)	22	45,5%	37,9%	40,9%	9,1%
Autores (N)	37	51,4%	55,9%	51,4%	29,7%
Geradas (G)	247	55,5%	62,9%	58,7%	27,9%

Fonte: Elaborado pelos autores. Consultas distintas das métricas principais; acurácia sobre todas as repetições.

Tabela 30 – F1-score por campo do *schema* de busca, por modelo

Campo	Ocorr.	Qwen 3 4B	Gemma 4 E4B	Gemma 4 E2B	Mistral Nemo 12B
keyword	186	0,776	0,883	0,713	0,430
scale	252	0,526	0,875	0,841	0,415
productType	132	0,684	0,635	0,871	0,554
state	390	0,818	0,920	0,795	0,489
city	81	0,412	1,000	0,892	0,667
supplyArea	120	0,950	0,897	0,947	0,431
project	33	0,541	0,806	0,909	0,000
publicationPeriod	153	0,693	0,424	0,548	0,455
creationPeriod	30	0,625	0,378	0,429	0,462
sortField	87	0,400	0,641	0,513	0,377
sortDirection	87	0,400	0,641	0,651	0,314
limit	42	0,358	0,794	0,824	0,444

Fonte: Elaborado pelos autores. Ocorr. = ocorrências do campo no gabarito das execuções pontuadas (consultas × repetições).

D.2 Estação de referência

Na validação na estação de referência, o Qwen 3 4B e o Gemma 4 E2B executaram as 62 consultas das camadas P e N (Seção 5.1.3). O teste de McNemar entre os dois está na Tabela 33. Na estação, a comparação entre as abordagens confirmou o empate no Gemma 4 E2B. Nessa amostra menor, ela não mostrou diferença significativa no Qwen 3 4B nem no Gemma 4 E4B, dois modelos em que a vantagem da Saída Estruturada na T4 era significativa (Tabela 34).

Tabela 31 – Comparativo de desempenho entre os modelos avaliados, na estação de referência (camadas P e N)

Modelo	Acurácia	IC 95%	Precisão	Recall	F1	Lat. med. (ms)
Qwen 3 4B	49,2%	36,8%–61,6%	0,741	0,762	0,733	2596
Gemma 4 E2B	47,5%	35,3%–60,0%	0,795	0,722	0,719	709

Fonte: Elaborado pelos autores. IC 95%: intervalo de confiança de Wilson para a acurácia, com n igual ao número de consultas, pois as repetições de uma mesma consulta não são independentes. Precisão, *recall* e F1 ponderados pela frequência de cada campo no gabarito. Latência mediana da chamada de tradução, no ambiente de cada rodada.

Tabela 32 – Latência da tradução, em milissegundos, por modelo, na estação de referência (camadas P e N)

Modelo	n	Mín.	Mediana	Média	p95	Máx.
Qwen 3 4B	59	1251	2596	2857	5702	8098
Gemma 4 E2B	59	372	709	777	1198	1439

Fonte: Elaborado pelos autores. Tempo da chamada de tradução, medido no ambiente de cada rodada (Tabela 24); execuções com erro de infraestrutura excluídas.

Tabela 33 – Teste de McNemar exato entre pares de modelos, na estação de referência (camadas P e N)

Modelo A	Modelo B	Só A acerta	Só B acerta	<i>p</i>-valor
Qwen 3 4B	Gemma 4 E2B	8	7	1,0000

Fonte: Elaborado pelos autores. Consultas discordantes entre os dois modelos nas métricas principais, com o resultado de cada consulta dado pela maioria das suas repetições; *p*-valor bicaudal exato.

Tabela 34 – Tool Calling e Saída Estruturada sobre as mesmas consultas, na estação de referência (camadas P e N)

Modelo	Parâm.	Abordagem	Acurácia	Sem F	F1	Recusa F	Campo a mais	<i>p</i>	<i>p</i> sem F
Gemma 4 E2B	2B ef.	Tool Calling	47,5%	45,6%	0,719	100,0%	15,8%	1,000	1,000
		Saída Estruturada	45,8%	47,4%	0,782	0,0%	28,1%		
Qwen 3 4B	4B	Tool Calling	49,2%	47,4%	0,733	100,0%	31,6%	1,000	0,629
		Saída Estruturada	50,8%	52,6%	0,815	0,0%	22,8%		
Gemma 4 E4B	4B ef.	Tool Calling	52,5%	50,9%	0,702	100,0%	8,8%	0,302	0,092
		Saída Estruturada	61,0%	63,2%	0,875	0,0%	5,3%		

Fonte: Elaborado pelos autores. Sem F: acurácia nas consultas das métricas principais fora da categoria F. Recusa F: proporção das execuções da categoria F sem busca; na Saída Estruturada a aplicação sempre busca. Campo a mais: proporção das execuções fora da categoria F com algum campo ausente do gabarito. *p*: teste de McNemar exato entre as duas abordagens do mesmo modelo, com uma observação por consulta (maioria das repetições). Parâm.: parâmetros (ef.: efetivos; MoE: mistura de especialistas, com parte dos parâmetros ativa a cada *token*).

Tabela 35 – Mesmo modelo nas rodadas completas e na estação de referência (camadas P e N, primeira repetição)

Modelo	n	Resposta idêntica	Mesma pontuação	Acurácia (rodada completa)	Acurácia (estação)
Qwen 3 4B	59	50	57	49,2%	49,2%
Gemma 4 E4B	59	55	57	49,2%	52,5%
Gemma 4 E2B	59	53	57	47,5%	47,5%

Fonte: Elaborado pelos autores. Resposta idêntica: mesmos parâmetros emitidos (ou nenhuma chamada nos dois ambientes).

Tabela 36 – Qwen 3 4B executado duas vezes na estação de referência, com os mesmos pesos, prompt, ferramenta e data de referência (camadas P e N)

Modelo	n	Resposta idêntica	Mesma pontuação	Acurácia (24/set)	Acurácia (14/set)
Qwen 3 4B	59	51	56	49,2%	47,5%

Fonte: Elaborado pelos autores. Resposta idêntica: mesmos parâmetros emitidos (ou nenhuma chamada nos dois ambientes).

D.3 Referência em nuvem

Os três modelos servidos pelo Groq executaram as 310 consultas uma vez (Seção 5.1.4).

Tabela 37 – Comparativo de desempenho entre os modelos avaliados, na referência em nuvem (Groq)

Modelo	Acurácia	IC 95%	Precisão	Recall	F1	Lat. med. (ms)
Qwen 3.8 27B (Groq)	95,1%	92,1%–97,0%	0,974	0,994	0,984	695
GPT-OSS 20B (Groq)	89,2%	85,2%–92,2%	0,959	0,945	0,946	530
GPT-OSS 120B (Groq)	89,9%	86,0%–92,8%	0,965	0,951	0,956	655

Fonte: Elaborado pelos autores. IC 95%: intervalo de confiança de Wilson para a acurácia, com n igual ao número de consultas, pois as repetições de uma mesma consulta não são independentes. Precisão, *recall* e F1 ponderados pela frequência de cada campo no gabarito. Latência mediana da chamada de tradução, no ambiente de cada rodada.

D.4 Lote 1 (validação)

As Tabelas 39, 40, 41 e 42 detalham a etapa 3 no lote 1, com o Gemma 4 E4B (Seção 5.3).

Tabela 38 – F1-score por categoria de consulta e por modelo, na referência em nuvem (Groq)

Categoria	Qwen 3.8 27B (Groq)	GPT-OSS 20B (Groq)	GPT-OSS 120B (Groq)
Simples (n=100)	0,985	0,985	0,979
Compostas (n=180)	0,983	0,937	0,950
Código MI/INOM (n=57)	1,000	0,985	0,986
Tempo relativo (n=60)	0,979	0,938	0,933
Ordenação (n=29)	0,982	0,837	0,926
Ambíguas/informais (n=197)	0,983	0,952	0,951
Média ponderada	0,984	0,946	0,956

Fonte: Elaborado pelos autores. Uma consulta pode pertencer a mais de uma categoria; n = consultas distintas da categoria nas métricas principais (cada uma pontuada em todas as repetições). As consultas fora do domínio (categoria F), cujo gabarito é não chamar a ferramenta, não têm campos e aparecem na Figura de acurácia por categoria.

Tabela 39 – Comparações pareadas no lote 1 e nas 310 consultas (Gemma 4 E4B)

Conjunto	Par (A × B)	Só A	Só B	<i>p</i>	B – A, acurácia (IC)	B – A, F1 (IC)
Lote	TC v1 × SE v1	419	433	0,656	+0,7 p.p. (-2,4 a +3,8)	0,131 (0,114 a 0,148)
Lote	TC v2 × SE v2	153	338	< 0,001	+9,6 p.p. (+7,4 a +11,8)	0,020 (0,006 a 0,033)
Lote	TC v1 × TC v2	251	277	0,277	+1,3 p.p. (-0,8 a +3,7)	0,079 (0,061 a 0,098)
Lote	SE v1 × SE v2	271	468	< 0,001	+10,2 p.p. (+7,5 a +13,0)	-0,032 (-0,044 a -0,020)
Lote	TC v1 × SE v2	146	357	< 0,001	+10,9 p.p. (+8,9 a +13,2)	0,099 (0,081 a 0,119)
310	TC v1 × SE v1	16	62	< 0,001	+15,0 p.p. (+9,8 a +20,6)	0,106 (0,072 a 0,147)
310	TC v2 × SE v2	30	93	< 0,001	+20,6 p.p. (+14,1 a +27,1)	0,063 (0,024 a 0,098)
310	TC v1 × TC v2	82	43	< 0,001	-12,7 p.p. (-19,9 a -6,2)	0,001 (-0,044 a 0,052)
310	SE v1 × SE v2	66	44	0,045	-7,2 p.p. (-13,4 a -0,7)	-0,043 (-0,076 a -0,011)
310	TC v1 × SE v2	49	73	0,037	+7,8 p.p. (+1,0 a +14,4)	0,064 (0,023 a 0,110)

Fonte: Elaborado pelos autores. Só A / Só B: consultas em que só uma das configurações acerta. *p*: McNemar exato, uma observação por consulta. IC: bootstrap pareado (2.000 reamostragens das consultas), percentis 2,5 e 97,5. TC: *Tool Calling*; SE: Saída Estruturada.

Tabela 40 – Arquitetura em duas etapas e regra do objeto vazio, simuladas com as rodadas do Gemma 4 E4B, ao lado das quatro configurações executadas

Conjunto	Configuração	Acurácia	IC 95%	Domínio	Recusa F	Precisão da recusa	Falsa recusa	Latência (s)
Lote de validação (n=1929)	Tool Calling v1	61,5%	59,3%–63,6%	48,9%	100,0%	42,0%	32,1%	0,86
	Saída Estruturada v1	62,2%	60,0%–64,3%	75,5%	0,0%	—	0,0%	0,72
	Tool Calling v2	62,8%	60,7%–65,0%	53,4%	99,7%	96,3%	0,9%	0,94
	Saída Estruturada v2	72,4%	70,4%–74,4%	63,2%	100,0%	56,7%	17,8%	0,61
	SE v1, objeto vazio como não busca	75,9%	74,0%–77,8%	75,5%	78,9%	97,4%	0,5%	0,72
	Duas etapas (TC v2 decide, SE v1 extrai)	79,5%	77,7%–81,3%	75,3%	99,7%	96,3%	0,9%	1,46
310 consultas (n=306)	Tool Calling v1	60,1%	54,6%–65,5%	59,1%	100,0%	12,5%	18,8%	0,72
	Saída Estruturada v1	75,2%	70,0%–79,7%	77,2%	0,0%	—	0,0%	0,76
	Tool Calling v2	47,4%	41,9%–53,0%	46,0%	100,0%	100,0%	0,0%	0,81
	Saída Estruturada v2	68,0%	62,6%–73,0%	67,1%	100,0%	15,7%	14,4%	0,71
	SE v1, objeto vazio como não busca	77,1%	72,1%–81,5%	77,2%	75,0%	100,0%	0,0%	0,76
	Duas etapas (TC v2 decide, SE v1 extrai)	77,8%	72,8%–82,1%	77,2%	100,0%	100,0%	0,0%	1,61

Fonte: Elaborado pelos autores. Gemma 4 E4B, GPU T4. As duas últimas linhas de cada conjunto são simulações *post hoc* sobre as rodadas existentes, sem chamada nova ao modelo. Duas etapas: o *Tool Calling* v2 decide se busca; quando busca, valem os parâmetros da Saída Estruturada v1 na mesma consulta, e a latência é a soma das duas chamadas. Objeto vazio como não busca: a resposta da Saída Estruturada v1 sem nenhum campo do *schema* conta como recusa (regra definida depois de ver os dados). Acurácia com IC de Wilson. Domínio: acurácia fora das categorias F e E. Recusa F: proporção das consultas fora do domínio sem busca. Precisão da recusa: proporção de consultas fora do domínio entre as que ficaram sem busca (—: nenhuma ficou). Falsa recusa: proporção das consultas do domínio sem busca. Latência: mediana. TC: *Tool Calling*; SE: Saída Estruturada.

Tabela 41 – Acurácia por categoria no lote de validação (Gemma 4 E4B)

Categoria	n	Tool Calling v1	Saída Estruturada v1	Tool Calling v2	Saída Estruturada v2
Simple	389	53,0%	79,2%	60,2%	55,5%
Compostas	955	52,4%	73,7%	49,9%	65,4%
Código MI/INOM	281	77,9%	78,3%	50,5%	76,5%
Tempo relativo	278	22,7%	65,8%	37,4%	61,2%
Ordenação	199	39,2%	77,4%	52,8%	73,4%
Ambíguas/informais	927	48,1%	72,9%	50,3%	61,1%
Subespecificadas	146	97,3%	74,0%	71,9%	100,0%
Fora do domínio	336	100,0%	0,0%	99,7%	100,0%
Todas	1929	61,5%	62,2%	62,8%	72,4%

Fonte: Elaborado pelos autores. Uma consulta pode pertencer a mais de uma categoria. Subespecificadas: buscar sem filtros ou não buscar são ambos corretos.

Tabela 42 – F1 por campo no lote de validação (Gemma 4 E4B)

Campo	Ocorr.	Tool Calling v1	Saída Estruturada v1	Tool Calling v2	Saída Estruturada v2
keyword	492	0,869	0,773	0,743	0,850
scale	415	0,821	0,969	0,963	0,925
productType	386	0,689	0,962	0,733	0,882
state	307	0,794	0,865	0,651	0,709
city	211	0,601	0,649	0,803	0,437
supplyArea	346	0,882	0,999	0,999	0,979
project	181	0,925	0,978	0,964	0,943
publicationPeriod	214	0,415	0,839	0,829	0,830
creationPeriod	106	0,538	0,545	0,829	0,845
sortField	199	0,699	0,941	0,959	0,977
sortDirection	199	0,748	0,977	0,959	0,980
limit	150	0,800	0,972	0,721	0,924
Ponderado		0,761	0,892	0,840	0,860
Macro		0,732	0,872	0,846	0,857

Fonte: Elaborado pelos autores. Ocorr.: ocorrências do campo no gabarito (a maior entre as configurações, porque os campos opcionais contam quando emitidos).

Registros e leituras múltiplas.

Nas consultas do domínio, a Saída Estruturada v1 foi a melhor configuração nos oito registros de linguagem. As vantagens aparentes do *Tool Calling* em registros como “direto” e “sem acento” vêm da concentração das consultas fora do domínio nesses registros. Os registros sem acento e telegráfico ficaram abaixo dos demais nas quatro configurações (na Saída Estruturada v1, 66,6% contra 77,8%). Todas as configurações acertaram menos nas consultas com mais de uma leitura aceita, e nelas a vantagem da Saída Estruturada cresceu (+16,1 p.p. na v1 e +7,1 p.p. na v2, na diferença entre as diferenças). A ambiguidade em si não explica esse aumento. As leituras múltiplas se concentram em algumas famílias, e, comparadas as abordagens dentro de cada família, a diferença desaparece na v2. Na v1, ela vem sobretudo da não busca do *Tool Calling*, mais frequente nessas consultas.